

1 Vetor Aleatório Discreto Bidimensional (X,Y).

Seja (X, Y) um vetor aleatório discreto bidimensional com função densidade de probabilidade conjunta dada por $f(x, y)$ com suporte A , isto é,

$$A = \{(x, y) \in \mathbb{R}^2 \mid f(x, y) > 0\}.$$

. Sejam $f_X(x)$ e $f_Y(y)$ as marginais.

A função $f(x, y)$ satisfaz as seguintes propriedades:

i. $f(x, y) = P(X = x, Y = y) \geq 0$

ii. $\sum_{(x,y) \in A} f(x, y) = 1.$

iii Seja E um evento então

$$P(E) = \sum_{(x,y) \in E} f(x, y).$$

1.1 Função de Probabilidade marginal de X.

$$f_X(x) = \sum_y f(x, y) \quad I_{A_X}(x),$$

onde $A_X = \{x \in R \mid f_X(x) > 0\}.$

1.2 Função de Probabilidade marginal de Y.

$$f_Y(y) = \sum_x f(x, y) \quad I_{A_Y}(y),$$

onde $A_Y = \{y \in R \mid f_Y(y) > 0\}.$

1.3 Independência entre X e Y.

Dizemos que X e Y são independentes se e só se a conjunta puder ser fatorada no produto das marginais, isto é,

$$f(x, y) = f_X(x) \times f_Y(y), \quad \forall (x, y) \in \mathbf{R}^2.$$

1.4 Distribuição Condicional de X dado Y=y.

Seja $y \in A_Y$ então a distribuição condicional de $X | Y = y$ é dada por:

$$f(x|Y = y) = P(X = x|Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)} = \frac{f(x, y)}{f_Y(y)} I_{A_{XY}}(x),$$

onde $A_{XY} = \{x \in \mathbf{R} \mid f(x|y) > 0\}$.

1.5 Distribuição Condicional de Y dado X=x.

Seja $x \in A_X$ então a distribuição condicional de $Y | X = x$ é dada por:

$$f(y|X = x) = P(Y = y|X = x) = \frac{P(X = x, Y = y)}{P(X = x)} = \frac{f(x, y)}{f_X(x)} I_{A_{YX}}(y),$$

onde $A_{YX} = \{y \in \mathbf{R} \mid f(y|x) > 0\}$.

Com as definições das condicionais temos uma outra definição de independência entre X e Y . Dizemos que X e Y são independentes se e só se

$$f(y|x) = f_Y(y) \quad e \quad f(x|y) = f_X(x).$$

1.6 Valor Esperado de g(X,Y).

Seja $g(x, y)$ uma função do \mathbf{R}^2 em \mathbf{R} com esperança finita, então

$$E(g(X, Y)) = \sum_{(x, y) \in A} g(x, y) \times f(x, y).$$

1.7 Covariância entre Duas Variáveis Aleatórias X e Y.

Sejam X e Y variáveis aleatórias com momentos de segunda ordem em relação à origem finitos, isto é, $E(X^2) < \infty$, $E(Y^2) < \infty$ e $E(XY) < \infty$. A covariância entre elas é definida por:

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - E(X)E(Y).$$

Definição: Quando $Cov(X, Y) = 0$ dizemos que X e Y são não correlacionadas.

Fato: Se X e Y forem independentes $Cov(X, Y) = 0$. Mas a recíproca não é verdadeira

Propriedades da Covariância:

1. $Cov(X, c) = 0$, onde c é uma constante.
2. $Cov(X, X) = V(X)$.
3. $Cov(X, Y) = Cov(Y, X)$.
4. $Cov(aX + b, cY + d) = ac Cov(X, Y)$, onde a, b, c, d são constantes.
5. $Cov(X + Y, Z + W) = Cov(X, Z) + Cov(X, W) + Cov(Y, Z) + Cov(Y, W)$.

Fato: Para duas variáveis aleatórias X e Y quaisquer temos:

$$V(X + Y) = V(X) + V(Y) + 2 \operatorname{Cov}(X, Y),$$

e se elas forem independentes:

$$V(X + Y) = V(X) + V(Y).$$

Prova:

$$\begin{aligned} V(X + Y) &= \operatorname{Cov}(X + Y, X + Y) \\ &= \operatorname{Cov}(X, X) + \operatorname{Cov}(X, Y) + \operatorname{Cov}(Y, X) + \operatorname{Cov}(Y, Y) \\ &= V(X) + \operatorname{Cov}(X, Y) + \operatorname{Cov}(X, Y) + V(Y) \\ &= V(X) + V(Y) + 2 \operatorname{Cov}(X, Y). \end{aligned}$$

Fato: Para duas variáveis aleatórias X e Y quaisquer temos:

$$V(X - Y) = V(X) + V(Y) - 2 \operatorname{Cov}(X, Y),$$

1.8 Correlação entre Duas Variáveis Aleatórias X e Y .

Para medir o grau da associação linear entre X e Y usamos o coeficiente de correlação que é definido por:

$$\rho(X, Y) = \rho = \frac{\operatorname{Cov}(X, Y)}{\sigma(X) \times \sigma(Y)}.$$

Propriedades do coeficiente de correlação.

1. $-1 \leq \rho(X, Y) \leq 1$, ou $|\rho(X, Y)| \leq 1$.
2. $\rho(X, X) = 1$ e $\rho(X, -X) = -1$.
3. Ele é adimensional.
4. $\rho(X + a, Y + b) = \rho(X, Y)$, onde a, b são constantes.
5. $\rho(aX, bY) = \operatorname{sign}(ab)\rho(X, Y)$, onde $\operatorname{sign}(c) = 1$ se c for positivo, $\operatorname{sign}(c) = -1$ se c for negativo e $\operatorname{sign}(c) = 0$ quando $c = 0$.

Quando $\rho = 1$ há uma relação linear crescente entre $Y = a + bX$ com $b > 0$. Quando $\rho = -1$ há uma relação linear decrescente entre $Y = c + dX$ com $d < 0$.

1.9 Esperança Condicional de $Y|X = x$.

Ela é definida por

$$E(Y|X = x) = \sum_y y f(y|x).$$

Perceba que $E(Y|x)$ é uma função de x , isto é, $E(Y|x) = g(x)$ e é denominada curva de regressão de Y sobre x . Na realidade $E(Y|x)$ é um valor da variável aleatória $V = E(Y|X)$.

Assim,

a.

$$E(V) = E[E(Y|X)] = E(Y).$$

b.

$$V(Y) = E[Var(Y|X)] + Var[E(Y|X)].$$

c.

$$Cov(X, Y) = Cov(X, V) = cov(X, E(Y|X)).$$

Na realidade podemos calcular a esperança de qualquer função de Y , $h(Y)$, através da condicional, isto é,

$$E[h(Y)] = E[E(h(Y)|X)] = \sum_y h(y) f(y|x).$$

Note que $h(Y) = t^Y$ temos que:

$$G_Y(t) = E(t^Y) = E[E(t^Y|X)] = E[G_{Y|X}(t)] = \sum_y t^y f(y|x).$$

1.10 Esperança Condicional de $X|Y = y$.

Ela é definida por

$$E(X|Y = y) = \sum_x x f(x|y).$$

Perceba que $E(X|y)$ é uma função de y , isto é, $E(X|y) = h(y)$ e é denominada curva de regressão de X sobre y . Na realidade $E(X|y)$ é um valor da variável aleatória $W = E(X|Y)$.

Assim,

a.

$$E(W) = E[E(X|Y)] = E(X).$$

b.

$$V(X) = E[Var(X|Y)] + Var[E(X|Y)].$$

c.

$$Cov(X, Y) = Cov(X, V) = cov(X, E(Y|X)).$$

Na realidade podemos calcular a esperança de qualquer função de X , $h(X)$, através da condicional, isto é,

$$E[h(X)] = E[E(h(X)|Y)] = \sum_x h(x) f(x|y).$$

Note que $h(X) = e^{tX}$ temos que:

$$M_X(t) = E(e^{tX}) = E[E(e^{tX}|Y)] = E[M_{X|Y}(t)] = \sum_y e^{tx} f(x|y).$$

Vamos enunciar um teorema do Meyer-página 178:

Seja (X, Y) um vetor aleatório bidimensional e suponha que:

$$E(X) = \mu_x, \quad E(Y) = \mu_y, \quad V(X) = \sigma_x^2, \quad e \quad V(Y) = \sigma_y^2.$$

Seja ρ o coeficiente de correlação entre X e Y . Se a regressão de Y em X for linear teremos:

$$E(Y|x) = \mu_y + \rho \frac{\sigma_y}{\sigma_x} (x - \mu_x). \quad (1)$$

Se a regressão de X em Y for linear teremos:

$$E(X|y) = \mu_x + \rho \frac{\sigma_x}{\sigma_y} (y - \mu_y). \quad (2)$$

Fato: Se b_1 for o coeficiente angular da regressão linear de Y em X e se b_2 for o coeficiente angular da regressão linear de X em Y então

$$b_1 \times b_2 = \rho^2,$$

e o sinal de ρ e' o mesmo sinal de b_1 e b_2 .

1.11 Função Geradora de probabilidades Bivariada de (X,Y).

Ela é definida por:

$$G_{(X,Y)}(t_1, t_2) = E(t_1^X \times t_2^Y) = \sum_{(x,y) \in A} t_1^x \times t_2^y f(x, y).$$

Propriedades:

- a. $G_X(t) = G_{(X,Y)}(t, 1)$.
- b. $G_Y(t) = G_{(X,Y)}(1, t)$
- c. Se X e Y forem independentes então $G_{(X,Y)}(t_1, t_2) = G_X(t_1) \times G_Y(t_2)$.
- d. A função geradora de probabilidades de $S = X + Y$ é dada por:

$$G_S(t) = E(t^S) = E(t^{X+Y}) = E(t^X \times t^Y) = G_{(X,Y)}(t, t),$$

note que não precisa de independência.

- e. A derivada parcial de primeira ordem de G com relação a t_1 é dada por

$$\frac{\partial G}{\partial t_1}(t_1, t_2) = E[X \times t_1^{X-1} \times t_2^Y].$$

Assim,

$$E(X) = \frac{\partial G}{\partial t_1}(t_1, t_2) \Big|_{(1,1)}.$$

- f. A derivada parcial de primeira ordem de G com relação a t_2 é dada por

$$\frac{\partial G}{\partial t_2}(t_1, t_2) = E[t_1^X \times Y \times t_2^{Y-1}].$$

Assim,

$$E(Y) = \frac{\partial G}{\partial t_2}(t_1, t_2) \Big|_{(1,1)}.$$

- g. A derivada parcial de segunda ordem de G com relação a t_1 é dada por

$$\frac{\partial^2 G}{\partial t_1^2}(t_1, t_2) = E[X(X-1) \times t_1^{X-2} \times t_2^Y].$$

Assim,

$$E(X(X-1)) = \frac{\partial^2 G}{\partial t_1^2}(t_1, t_2) \Big|_{(1,1)}.$$

h. A derivada parcial de segunda ordem de G com relação a t_2 é dada por

$$\frac{\partial^2 G}{\partial t_2^2}(t_1, t_2) = E \left[t_1^X \times Y(Y-1)t_2^{Y-2} \right].$$

Assim,

$$E(Y(Y-1)) = \frac{\partial^2 G}{\partial t_2^2}(t_1, t_2) \Big|_{(1,1)}.$$

i. A derivada parcial de segunda ordem de G com relação a t_1 e t_2 é dada por

$$\frac{\partial^2 G}{\partial t_1 \partial t_2}(t_1, t_2) = E \left[XY \times t_1^{X-1} \times t_2^{Y-1} \right].$$

Assim,

$$E(XY) = \frac{\partial^2 G}{\partial t_1 \partial t_2}(t_1, t_2) \Big|_{(1,1)}.$$

1.12 Função Geradora de Momentos Bivariada de (X,Y).

Ela é definida por:

$$M_{(X,Y)}(t_1, t_2) = E(e^{t_1 X + t_2 Y}) = \sum_{(x,y) \in A} e^{t_1 x + t_2 y} \times f(x, y).$$

Propriedades:

- a. $M_X(t) = M_{(X,Y)}(t, 0)$.
- b. $M_Y(t) = M_{(X,Y)}(0, t)$
- c. Se X e Y forem independentes então $M_{(X,Y)}(t_1, t_2) = M_X(t_1) \times M_Y(t_2)$.
- d. A função geradora de momentos de $S = X + Y$ é dada por:

$$M_S(t) = E(e^{tS}) = E(e^{t(X+Y)}) = E(e^{tX+tY}) = M_{(X,Y)}(t, t),$$

note que não precisa de independência.

e. A derivada parcial de primeira ordem de M com relação a t_1 é dada por

$$\frac{\partial M}{\partial t_1}(t_1, t_2) = E \left[X \times e^{t_1 X + t_2 Y} \right].$$

Assim,

$$E(X) = \frac{\partial M}{\partial t_1}(t_1, t_2) \Big|_{(0,0)}.$$

f. A derivada parcial de primeira ordem de M com relação a t_2 é dada por

$$\frac{\partial M}{\partial t_2}(t_1, t_2) = E \left[Y \times e^{t_1 X + t_2 Y} \right].$$

Assim,

$$E(Y) = \frac{\partial M}{\partial t_2}(t_1, t_2) \Big|_{(0,0)}.$$

g. A derivada parcial de segunda ordem de M com relação a t_1 é dada por

$$\frac{\partial^2 M}{\partial t_1^2}(t_1, t_2) = E[X^2 \times e^{t_1 X + t_2 Y}].$$

Assim,

$$E(X^2) = \frac{\partial^2 M}{\partial t_1^2}(t_1, t_2) \Big|_{(0,0)}.$$

h. A derivada parcial de segunda ordem de M com relação a t_2 é dada por

$$\frac{\partial^2 M}{\partial t_2^2}(t_1, t_2) = E[Y^2 \times e^{t_1 X + t_2 Y}].$$

Assim,

$$E(Y^2) = \frac{\partial^2 M}{\partial t_2^2}(t_1, t_2) \Big|_{(0,0)}.$$

i. A derivada parcial de segunda ordem de M com relação a t_1 e t_2 é dada por

$$\frac{\partial^2 M}{\partial t_1 \partial t_2}(t_1, t_2) = E[XY \times e^{t_1 X + t_2 Y}].$$

Assim,

$$E(XY) = \frac{\partial^2 M}{\partial t_1 \partial t_2}(t_1, t_2) \Big|_{(0,0)}.$$

Calculados estes momentos podemos calcular as variâncias e a covariância e apresentá-los em forma matricial através do vetor de médias $\mu' = (E(X), E(Y))$ e da matriz de variâncias e covariâncias Σ .

1.13 Função de Distribuição Acumulada Bivariada

Seja (X, Y) um vetor aleatório discreto bidimensional com função densidade conjunta dada por $f_{(X,Y)}(x, y)$. A Função de Distribuição Conjunta Bidimensional Discreta do vetor aleatório (X, Y) é definida por:

$$F : R^2 \rightarrow [0, 1]$$

$$F(x, y) = P(X \leq x, Y \leq y) = \sum_{(u,v) \in E} f_{(X,Y)}(u, v),$$

onde

$$E = \{(u, v) \in R^2 | u \leq x, v \leq y\}.$$

Propriedades da Função de Distribuição Acumulada Bivariada de Qualquer Tipo.

- a. $F(x, y)$ é uma função não decrescente de x . $F(x, y)$ é uma função não decrescente de y .
- b. $F(x, y)$ é uma função contínua à direita de x . $F(x, y)$ é uma função contínua à direita de y . Isto é:

$$\lim_{0 < h \rightarrow 0} F(x + h, y) = \lim_{0 < h \rightarrow 0} F(x, y + h) = F(x, y).$$

$$c. \lim_{x \rightarrow -\infty} F(x, y) = 0, \quad \lim_{y \rightarrow -\infty} F(x, y) = 0, \quad \lim_{\substack{x \rightarrow -\infty \\ y \rightarrow -\infty}} F(x, y) = F(-\infty, -\infty) = 0$$

$$e. \lim_{\substack{x \rightarrow \infty \\ y \rightarrow \infty}} F(x, y) = F(\infty, \infty) = 1.$$

d. Se $x_1 < x_2$ e $y_1 < y_2$, então:

$$P(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) \geq 0.$$

Além disso:

a. $F_X(x) = \lim_{y \rightarrow \infty} F_{(X,Y)}(x, y).$

b. $F_Y(y) = \lim_{x \rightarrow \infty} F_{(X,Y)}(x, y).$

c. Se X e Y são independentes então: $F_{(X,Y)}(x, y) = F_X(x)F_Y(y), \forall (x, y) \in \mathbb{R}^2.$

Vamos exercitar teoricamente os conceitos apresentados:

Prove a seguinte desigualdade:

$$F_X(x) + F_Y(y) - 1 \leq F_{(X,Y)}(x, y) \leq \sqrt{F_X(x)F_Y(y)}, \quad \forall (x, y) \in \mathbb{R}^2.$$

Seja $F_0 : \mathbb{R}^2 \rightarrow \mathbb{R}$ uma função definida por:

$$F_0(x, y) = \begin{cases} 1 & \text{se } x \geq 0 \text{ e } y \geq 0 \text{ e } x + y \geq 1 \\ 0 & \text{caso contrário} \end{cases}$$

Será que F_0 é uma função de distribuição de um vetor aleatório (X, Y) ?

Mostre que $P(0 < X \leq 1, 0 < Y \leq 1) = -1$. E aí? A propriedade d é fundamental? As outras são verdadeiras!!!!!!!!!!!!!!!!!!!!!!?

Exemplo: Seja (X, Y) um vetor aleatório discreto com

$$f(x, y) = \frac{1}{4} I_A(x, y), \quad A = \{(1, 1), (1, 2), (2, 1), (2, 2)\}.$$

calcule a função de de distribuição acumulada de (X, Y) .

Solução: Vamos calcular inicialmente

$$\begin{aligned} F(1, 1) &= P(X \leq 1, Y \leq 1) = P(X = 1, Y = 1) = \frac{1}{4} \\ F(1, 2) &= P(X \leq 1, Y \leq 2) = P(X = 1, Y = 1) + P(X = 1, Y = 2) = \frac{1}{2} \\ F(2, 1) &= P(X \leq 2, Y \leq 1) = P(X = 1, Y = 1) + P(X = 2, Y = 1) = \frac{1}{2} \\ F(2, 2) &= P(X \leq 2, Y \leq 2) = P(X = 1, Y = 1) + P(X = 1, Y = 2) + \\ &\quad P(X = 2, Y = 1) + P(X = 2, Y = 2) = 1. \end{aligned}$$

Outros valores de (x, y) o valor da acumulada é obtido assim:

$$\begin{aligned} F(3/2, 3/2) &= P(X \leq 3/2, Y \leq 3/2) = P(X \leq 1, Y \leq 1) = F(1, 1) = \frac{1}{4} \\ F(1, 4; , 2, 7) &= P(X \leq 1, 4; Y \leq 2, 7) = P(X \leq 1, Y \leq 2) = F(1, 2) = \frac{1}{2} \\ F(3; 1, 9) &= P(X \leq 3, Y \leq 1, 9) = P(X \leq 2, Y \leq 1) = F(2, 1) = \frac{1}{2} \\ F(4, 5) &= P(X \leq 4, Y \leq 5) = P(X \leq 2, Y \leq 2) = F(2, 2) = 1. \end{aligned}$$

A acumulada bivariada é dada para qualquer ponto $(x, y) \in \mathbb{R}^2$:

$$F(x, y) = \begin{cases} 0 & \text{se } x < 1 \text{ ou } y < 1 \\ \frac{1}{4} & \text{se } 1 \leq x < 2, 1 \leq y < 2 \\ \frac{1}{2} & \text{se } 1 \leq x < 2, y \geq 2 \\ \frac{1}{2} & \text{se } x \geq 2, 1 \leq y < 2 \\ 1 & \text{se } x \geq 2 \text{ e } y \geq 2 \end{cases}$$

1.14 Distribuição Trinomial

Seja (X, Y) com distribuição bivariada (trinomial) de parâmetros n , p_1 e p_2 .

A função de probabilidade conjunta de (X, Y) é dada por:

$$f(x, y) = \frac{n!}{x!y!(n-x-y)!} p_1^x p_2^y (1-p_1-p_2)^{n-x-y} I_{\{0,1,\dots,n\}}(x) I_{\{0,1,\dots,n-x\}}(y).$$

Sua função geradora de probabilidades bivariada é dada por:

$$G_{(X,Y)}(t_1, t_2) = (p_1 t_1 + p_2 t_2 + 1 - p_1 - p_2)^n$$

onde t_1 e t_2 são reais.

As marginais de X e de Y são dadas por:

$$\begin{aligned} G_X(t) &= G_{(X,Y)}(t, 1) = (p_1 t + p_2 + 1 - p_1 - p_2)^n \\ &= (p_1 t + 1 - p_1)^n, \end{aligned}$$

assim $X \sim \text{Bin}(n, p_1)$ e $Y \sim \text{Bin}(n, p_2)$.

A função geradora de momentos bivariada de $(X, Y) \sim \text{Trinomial}(n, p_1, p_2)$, é dada por:

$$M(t_1, t_2) = (p_1 e^{t_1} + p_2 e^{t_2} + 1 - p_1 - p_2)^n$$

onde t_1 e t_2 são reais.

As condicionais de $X|Y = y$ e de $Y|X = x$ são dadas por:

$$\begin{aligned} X|Y = y &\sim \text{Bin}\left(n - y, p = \frac{p_1}{1 - p_2}\right) \\ Y|X = x &\sim \text{Bin}\left(n - x, p = \frac{p_2}{1 - p_1}\right) \end{aligned}$$

A esperança de XY é dada por:

$$E(XY) = n(n-1)p_1 p_2.$$

A covariância entre X e Y é dada por:

$$\text{Cov}(X, Y) = -np_1 p_2.$$

A correlação entre X e Y é dada por:

$$\rho = -\sqrt{\frac{p_1 p_2}{(1-p_1)(1-p_2)}}.$$

A distribuição de $S = X + Y$ é dada por:

$$\begin{aligned} G_S(t) &= E[t^S] \\ &= E[t^X t^Y] \\ &= G_{(X,Y)}(t, t) \\ &= (p_1 t + p_2 t + 1 - p_1 - p_2)^n \\ &= ((p_1 + p_2)t + 1 - p_1 - p_2)^n, \end{aligned}$$

que é a função geradora de probabilidades da Binomial $(n, p_1 + p_2)$.

1.15 Distribuição HiperGeométrica Bivariada

A função de probabilidade conjunta de (X, Y) é dada por:

$$f(x, y) = P(X = x, Y = y) = \frac{\binom{A_1}{x} \binom{A_2}{y} \binom{N-A_1-A_2}{n-x-y}}{\binom{N}{n}},$$

com $0 \leq x + y \leq n$.

$$X \sim \text{Hipergeométrica}(N, A_1, n).$$

$$Y \sim \text{Hipergeométrica}(N, A_2, n).$$

$$Y|X = x \sim HG(N - A_1, A_2, n - x).$$

$$X|Y = y \sim HG(N - A_2, A_1, n - y).$$

$$E(XY) = \frac{n(n-1)}{N(N-1)} \frac{A_1}{N} \frac{A_2}{N}.$$

$$\text{Cov}(X, Y) = -n \frac{A_1}{N} \frac{A_2}{N} \frac{N-n}{N-1}.$$

$$\rho = -\sqrt{\frac{A_1 A_2}{(N-A_1)(N-A_2)}}.$$

$$S = X + Y \sim HG(N, A_1 + A_2, n).$$

1.16 Desigualdade de Cauchy -Schwarz

Desigualdade de Cauchy-Schwarz: Para quaisquer duas variáveis aleatórias com variâncias finitas,

$$E^2(XY) \leq E(X^2)E(Y^2),$$

ou

$$|E(XY)| \leq \sqrt{E(X^2)E(Y^2)}.$$