

Universidade Federal do Ceará

Centro de Ciências

Departamento de Estatística e Matemática Aplicada

{Coordenação do Curso de Estatística } Professor: Maurício Mota

Lista - Função Escore-Informação de Fisher- CC0288-Inferência I - 30/03/2023

1. Seja X uma variável aleatória com função de probabilidade ou função densidade de probabilidade $f(x | \theta)$ e suporte $A = \{x \in \mathbf{R} \mid f(x | \theta) > 0\}$ que não depende de θ . A notação \log significa logaritmo neperiano.

A quantidade

$$V = \frac{\partial \log f(X|\theta)}{\partial \theta},$$

é uma variável aleatória chamada função escore. Pode-se mostrar que

$$E(V) = 0 \text{ e } Var(V) = I_F(\theta).$$

A quantidade

$$I_F(\theta) = E \left[\left(\frac{\partial \log f(X|\theta)}{\partial \theta} \right)^2 \right] = E(V^2),$$

é chamada de Informação de Fisher.

Seja a variável aleatória

$$W = \frac{\partial^2 \log f(X|\theta)}{\partial \theta^2},$$

um resultado importante que ajuda no cálculo de $I_F(\theta)$ pois:

$$I_F(\theta) = E(V^2) = E(-W).$$

Vamos aplicar essa teoria !!!!!!!A primeira coisa a verificar é se o suporte depende do parâmetro desconhecido. Não esqueça!!!!

2. Seja $X \sim N(\mu, \sigma^2)$ em que σ^2 é conhecido. Mostre que:

a. $\log[f(X | \mu)] = -\frac{1}{2}\log(2\pi) - \frac{1}{2}\log(\sigma^2) - \frac{(X-\mu)^2}{2\sigma^2}.$

b. $V = \frac{\partial \log f(X|\mu)}{\partial \mu} = \frac{X - \mu}{\sigma^2}.$

c. $E(V) = 0$ e $I_F(\theta) = \frac{1}{\sigma^2}.$

d. $W = -\frac{1}{\sigma^2}$ e $I_F(\theta) = E(-W) = \frac{1}{\sigma^2}.$

3. Seja $X \sim \text{Exp}(\theta)$, $\theta > 0$. Mostre que:

a. $\log[f(X | \theta)] = \log(\theta) - \theta X.$

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = \frac{1}{\theta} - X = -(X - \frac{1}{\theta}).$

c. $E(V) = 0$ e $I_F(\theta) = \frac{1}{\theta^2}.$

d. $W = -\frac{1}{\theta^2}$ e $I_F(\theta) = E(-W) = \frac{1}{\theta^2}.$

4. Seja $X \sim \text{Poisson}(\theta)$, $\theta > 0$. Mostre que:

a. $\log[f(X | \theta)] = -\log(X!) + X\log(\theta) - \theta.$

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = \frac{X}{\theta} - 1.$

c. $E(V) = 0$ e $I_F(\theta) = \frac{1}{\theta}.$

d. $W = -\frac{X}{\theta^2}$ e $I_F(\theta) = E(-W) = \frac{1}{\theta}.$

5. Seja $X \sim \text{Beta}(\theta, 1)$, $\theta > 0$. Mostre que:

a. $\log[f(X | \theta)] = (\theta - 1)\ln(X) + \log(\theta)$.

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = \frac{1}{\theta} + \log(X)$.

c. $Y = -\log X \sim \text{Exp}(\theta)$.

d. $E(V) = 0$ e $I_F(\theta) = \frac{1}{\theta^2}$.

e. $W = -\frac{1}{\theta^2}$ e $I_F(\theta) = E(-W) = \frac{1}{\theta^2}$.

6. Seja $X \sim N(0, \sigma^2)$. Mostre que:

a. $\log[f(X | \sigma^2)] = -\frac{1}{2}\log(2\pi) - \frac{1}{2}\log(\sigma^2) - \frac{X^2}{2\sigma^2}$.

b. $V = \frac{\partial \log f(X | \sigma^2)}{\partial \sigma^2} = \frac{-1}{2\sigma^2} + \frac{X^2}{2\sigma^4} = \frac{Z^2 - 1}{2\sigma^2}$.

c. $Z = \frac{X}{\sigma} \sim N(0, 1)$ e $Z^2 = \frac{X^2}{\sigma^2} \sim \chi^2(1)$.

Portanto $E(X^2) = \sigma^2$ e $\text{Var}(X) = 2\sigma^4$.

d. $E(V) = 0$ e $I_F(\sigma^2) = \frac{1}{2\sigma^4}$.

e. $W = \frac{1}{2\sigma^4} - \frac{X^2}{\sigma^6}$ e $I_F(\sigma^2) = E(-W) = \frac{1}{2\sigma^4}$.

7. Seja $X \sim \text{Bin}(r, \theta)$, $0 < \theta < 1$, r conhecido. Mostre que:

a. $\log[f(X | \theta)] = \log\left(\binom{r}{X}\right) + X \log(\theta) + (r - X) \log(1 - \theta)$.

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = \frac{X - r\theta}{\theta(1 - \theta)}$.

c. $E(V) = 0$ e $I_F(\theta) = \frac{r}{\theta(1 - \theta)}$.

d. $W = -\frac{X}{\theta^2} + \frac{r - X}{(1 - \theta)^2}$ e $I_F(\theta) = E(-W) = \frac{r}{\theta(1 - \theta)}$.

8. Dizemos que uma variável aleatória tem distribuição $X \sim \text{Gumbel}(\theta, 1)$ se sua f.d.p. é da forma:

$$f(x | \theta) = \exp\left(-(x - \theta) - e^{-(x - \theta)}\right),$$

em que x e θ são reais. Mostre que:

a. $\log[f(X | \theta)] = -(X - \theta) - e^{-(X - \theta)} = \theta - X - e^{-X}e^\theta$.

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = 1 - e^{-X}e^\theta$.

c. $Y = e^{-X} \sim \text{Exp}(e^\theta)$.

d. $E(V) = 0$ e $I_F(\theta) = 1$.

e. $W = -e^\theta e^{-X}$ e $I_F(\theta) = E(-W) = 1$.

9. Seja X uma variável aleatória com distribuição geométrica e suporte $A = \{0, 1, \dots\}$. Sua f.p. é dada por:

$$f(x | \theta) = \theta(1 - \theta)^x I_A(x).$$

a. $\log[f(X | \theta)] = \log(\theta) + X \log(1 - \theta)$.

b. $V = \frac{\partial \log f(X | \theta)}{\partial \theta} = \frac{1}{\theta} - \frac{X}{1 - \theta}$.

c. $E(V) = 0$ e $I_F(\theta) = \frac{1}{\theta(1 - \theta)}$.

d. $W = -\frac{1}{\theta^2} + \frac{X}{(1 - \theta)^2}$ e $I_F(\theta) = E(-W) = \frac{1}{\theta(1 - \theta)}$.

10. Nos exercícios vimos que $E(V) = 0$. Vamos provar? Suponha que X seja uma variável aleatória contínua com densidade $f(x | \theta)$ e suporte A que não depende de θ .

$$E(V) = \int_A \frac{\partial \log f(x | \theta)}{\partial \theta} f(x | \theta) dx,$$

mas

$$\frac{\partial \log f(x | \theta)}{\partial \theta} = \frac{\frac{\partial f(x | \theta)}{\partial \theta}}{f(x | \theta)},$$

portanto

$$\frac{\frac{\partial f(x | \theta)}{\partial \theta}}{f(x | \theta)} f(x | \theta) = \frac{\partial f(x | \theta)}{\partial \theta},$$

Logo,

$$E(V) = \int_A \frac{\partial \log f(x | \theta)}{\partial \theta} f(x | \theta) dx = \int_A \frac{\partial f(x | \theta)}{\partial \theta} dx = \frac{\partial}{\partial \theta} \int_A f(x | \theta) dx = \frac{\partial}{\partial \theta} 1 = 0,$$

pois como A não depende de θ podemos inverter as ordens de integração e derivação.

11. Mostre que

$$I_F(\theta) = E \left[\left(\frac{\partial \log f(X|\theta)}{\partial \theta} \right)^2 \right] = E \left(-\frac{\partial^2 \log f(X|\theta)}{\partial \theta^2} \right),$$

no caso em que X é uma v.a.c.

12. Segundo Heleno e Mônica, uma outra importante propriedade estabelece que para uma amostra aleatória X_1, X_2, \dots, X_n , da variável aleatória X com f.d.p. ou f.p. $f(x | \theta)$ e informação total de Fisher de θ correspondente à amostra observada é a soma da informação de Fisher das n observações da amostra. Considere a distribuição conjunta da amostra

$$f(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta).$$

Note que

$$\log[f(x_1, x_2, \dots, x_n | \theta)] = \sum_{i=1}^n \log[f(x_i | \theta)].$$

Assim

$$E \left[\left(\frac{\partial \log f(X_1, X_2, \dots, X_n | \theta)}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \log f(X_1, X_2, \dots, X_n | \theta)}{\partial \theta^2} \right].$$

Mas

$$-E \left[\frac{\partial^2 \log f(X_1, X_2, \dots, X_n | \theta)}{\partial \theta^2} \right] = \sum_{i=1}^n E \left[-\frac{\partial^2 \log f(X_i | \theta)}{\partial \theta^2} \right] = n I_F(\theta),$$

pois X_i , $i = 1, 2, \dots, n$ possuem a mesma informação que X .

Seja T um estimador não viciado de θ . A informação da amostra de Fisher nos fornece um limitante inferior para a variância de T . Vamos enunciar agora a Desigualdade da Informação.

Ela nos diz que, sob determinadas condições de regularidade,

$$\text{Var}(T) \geq \frac{1}{n I_F(\theta)} = LI(\theta).$$

As condições de regularidade são basicamente duas:

- a. O suporte $A = \{x, f(x | \theta) > 0\}$ não depende de θ .
- b. Ser possível a troca das ordens das operações de derivação e integração sob a distribuição da variável aleatória X .

Uma outra propriedade nos fala sobre a eficiência de um estimador T não viciado para um parâmetro θ que é definida por:

$$e(T) = \frac{LI(\theta)}{Var(T)}.$$

Se $e(T) = 1$ o estimador T é dito ser eficiente. Nem sempre esse limite inferior é atingido. A Desigualdade da Informação foi inicialmente chamada de desigualdade de Cramer-Rao.

13. Mostre que \bar{X} é um estimador eficiente de θ quando uma amostra aleatória de tamanho n é retirada de $X \sim Poisson(\theta)$.
14. Seja X_1, X_2, \dots, X_n uma amostra aleatória da variável aleatória X com com f.d.p. ou f.p. $f(x | \theta)$ e informação total de Fisher de θ para a qual as condições de regularidade estão satisfeitas. Seja T um estimador não viciado para $g(\theta)$. Uma versão da desigualdade da Informação nos diz:

$$Var(T) \geq \frac{[g'(\theta)]^2}{nI_F(\theta)}.$$

Considere $g(\theta) = \theta^2$ para a questão 13. Qual o limite inferior para a variância dos estimadores não viciados de θ^2 ?

15. Seja X_1, X_2, \dots, X_n uma amostra aleatória da variável aleatória $X \sim N(\mu, 1)$. Seja \bar{X} , a média amostral.

- a. Mostre que \bar{X} é um estimador não viciado de μ .
- b. Mostre que $T = \bar{X}^2 - 1/n$ é um estimador não viciado de $g(\mu) = \mu^2$.
- c. Ache o limite inferior da variância dos estimadores não viciados de μ^2 e verifique se T é eficiente.
- d. Existe ENVVUM (UMVUE) para μ^2 ? Que lição isso nos traz?

16. Seja X_1, X_2, \dots, X_n , $n > 2$, uma amostra aleatória da variável aleatória $X \sim Exp(\beta)$. Sejam \bar{X} , a média amostral, e $S = \sum_{i=1}^n X_i$.

- a. Mostre que \bar{X} é um estimador não viciado de β .

- b. Mostre que $S \sim \text{Gama}(n, \beta)$ e $\bar{X} \sim \text{Gama}(n, n\beta)$.
- c. Mostre que $Y = 1/S$ tem uma distribuição Gama Inversa. Além disso $E(S) = \frac{n-1}{\beta}$ e $Var(S) = \frac{\beta^2}{(n-1)^2(n-2)}$
- d. Mostre que $I_F(\beta) = 1/\beta^2$.
- e. Ache o limite inferior da variância dos estimadores não viciados de β ?
- f. Ache o limite inferior da variância dos estimadores não viciados de $1/\beta$ e verifique se \bar{X} é eficiente.
- g. Mostre que $T = \frac{n-1}{S}$ é um estimador não viciado de β e que $Var(T) = \frac{\beta^2}{(n-2)}$
- h. Existe ENVVUM (UMVUE) para β ? Que lição isso nos traz?

17. Descubra o que há de errado no seguinte argumento:

Seja $X \sim Unif[0, \theta]$. Assim

$$f(X | \theta) = \frac{1}{\theta} I_A(x),$$

logo,

$$\log[f(X | \theta)] = -\log(\theta),$$

e

$$\frac{\partial \log f(X|\theta)}{\partial \theta} = -\frac{1}{\theta}.$$

Logo

$$I_F(\theta) = \frac{1}{\theta^2}.$$

Seja T um estimador não viciado de θ e pela desigualdade da Informação temos que:

$$\text{Var}(T) \geq 1/I_F(\theta) = \theta^2.$$

Por outro lado $E(X) = \theta/2$ e $E(2X) = \theta$. Logo $T_1 = 2X$ é um estimador não viciado de θ . Mas

$$\text{Var}(T_1) = 4\text{Var}(X) = 4\theta^2/12 = \theta^2/3$$

.

Mas

$$\text{Var}(T_1) = \theta^2/3 \geq \text{Var}(T) = \theta^2,$$

que implica $1/3 \geq 1$. Explique o absurdo!!!!

18. Seja X_1, X_2, \dots, X_n uma amostra aleatória da variável aleatória X com com f.d.p. ou f.p. $f(x | \theta)$ e informação total de Fisher de θ para a qual as condições de regularidade estão satisfeitas. Para responder à pergunta: Existe alguma função de θ , $g(\theta)$, para a qual exista um estimador não viciado cuja variância coincida com o limite inferior de Cramer-Rao?

Para responder vai-se utilizar o seguinte resultado encontrado nas páginas 315 a 320 do livro do Mood, Graybill & Boes.

$$\sum_{i=1}^n \frac{\partial \log f(X_i|\theta)}{\partial \theta} = K(\theta, n) [t(X_1, X_2, \dots, X_n) - g(\theta)].$$

Assim $g(\theta)$ é a função procurada e $T = t(X_1, X_2, \dots, X_n)$ é seu estimador com $\text{Var}(T) = LICR$.

Para cada uma das distribuições apresentadas responda : Existe alguma função de θ , $g(\theta)$, para a qual exista um estimador não viciado cuja variância coincida com o limite inferior de Cramer-Rao?

a. $X \sim \text{Geom}(\theta)$, $A = \{0, 1, 2, \dots\}$.

b. $X \sim \text{Binomial}(2, \theta)$. Se não houver justifique.

c. $X \sim \text{Gumbel}(\theta, 1)$.

d. $f(x | \theta) = \frac{\log(\theta)}{\theta - 1} \theta^x I_{(0,1)}(x)$, $\theta > 1$.