

Vamos estudar agora o capítulo 11:Estimação:

## 11.1 Primeiras Ideias.

Vimos que a Inferência Estatística tem por objetivo fazer generalizações sobre uma população, com base nos dados de uma amostra. Salientamos que dois problemas básicos nesse processo são:

- (a) estimação de parâmetros; e
- (b) teste de hipóteses sobre parâmetros.

Lembremos que parâmetros são funções de valores populacionais, enquanto estatísticas são funções de valores amostrais.

O problema do teste de hipóteses sobre parâmetros de uma população será tratado no Capítulo 12. Neste capítulo, iremos discutir as ideias básicas sobre estimação. Para ilustrar, consideremos o exemplo seguinte.

**Exemplo 11.1** Uma amostra de  $n = 500$  pessoas de uma cidade é escolhida, e a cada pessoa da amostra é feita uma pergunta a respeito de um problema municipal, para o qual foi apresentada uma solução pela prefeitura. A resposta à pergunta poderá ser SIM (favorável à solução) ou NÃO (contrária à solução). Deseja-se estimar a proporção de pessoas na cidade favoráveis à solução apresentada.

Se 300 pessoas responderam SIM à pergunta, então uma estimativa natural para essa proporção seria

$$\frac{300}{500} \quad \text{ou} \quad 60\%.$$

Nossa resposta é baseada na suposição de que a amostra é representativa da população. Sabemos, também, que outra amostra poderia levar a outra estimativa. Conhecer as propriedades desses estimadores é um dos propósitos mais importantes da Inferência Estatística. Vejamos o que pode ser feito nesse caso particular.

Definamos as v.a.  $X_1, X_2, \dots, X_n$ , tais que:

$$X_i = \begin{cases} 1, & \text{se a } i\text{-ésima pessoa na amostra responder SIM} \\ 0, & \text{se a } i\text{-ésima pessoa na amostra responder Não,} \end{cases}$$

logo,

$$X \sim \text{Ber}(p)$$

e seja  $p = P(\text{sucesso})$ , em que sucesso significa resposta **SIM** à questão formulada.

Portanto, se

$$S_n = \sum_{i=1}^n X_i,$$

sabemos que  $S_n$  tem distribuição binomial com parâmetros  $n$  e  $p$ , e o problema consiste em estimar  $p$ . É claro que  $S_n$  representa o número de pessoas na amostra que responderam SIM; portanto, um possível estimador de  $p$  é

$$\hat{p} = \frac{S_n}{n} = \frac{\sum_{i=1}^n X_i}{n} = \frac{\text{número de SIM}}{\text{número de indivíduos}} \quad (11.1)$$

Então, se  $S_n = k$ , isto é, observarmos o valor  $k$  da variável  $S_n$ , obteremos

$$\hat{p} = \frac{k}{n},$$

como uma estimativa de  $p$ . Observe que  $\hat{p}$ , dado por (11.1), é uma v.a., ao passo que  $\frac{k}{n}$  é um número, ou seja, um valor da v.a. No exemplo acima, uma estimativa é 0,6 ou 60%.

O estimador teve sua distribuição amostral estudada na Seção 10.9. De lá podemos concluir que tem distribuição aproximadamente normal, com parâmetros:

$$E(\hat{p}) = p, \quad (11.2)$$

e

$$Var(\hat{p}) = \frac{p(1-p)}{n} \quad (11.3)$$

Esses resultados nos ajudam a avaliar as qualidades desse estimador. Por exemplo, o resultado (11.2) indica que o estimador, em média, “acerta”  $p$ . Dizemos que é um estimador não viesado (ou não viciado) de  $p$ . Ou ainda, o resultado (11.3) indica que para amostras grandes, a diferença entre  $\hat{p}$ , e  $p$  tende a ser pequena, pois para  $n \rightarrow \infty$

$$Var(\hat{p}) \rightarrow 0$$

. Nesse caso, dizemos que é um estimador consistente de  $p$ . Observe que essas propriedades são válidas para o estimador no conjunto de todas as amostras que poderiam ser extraídas da população. Para uma particular amostra, pode estar distante de  $p$ .

Em algumas situações, podemos ter mais de um estimador para um mesmo parâmetro, e desejamos saber qual deles é “melhor”. O julgamento pode ser feito analisando as propriedades desses estimadores.

Vejam um exemplo.

**Exemplo 11.2** Desejamos comprar um rifle e, após algumas seleções, restaram quatro alternativas, que chamaremos de rifles A, B, C e D. Foi feito um teste com cada rifle, que consistiu em fixá-lo num cavalete, mirar o centro de um alvo e disparar 15 tiros. Os resultados estão ilustrados na Figura 11.1.

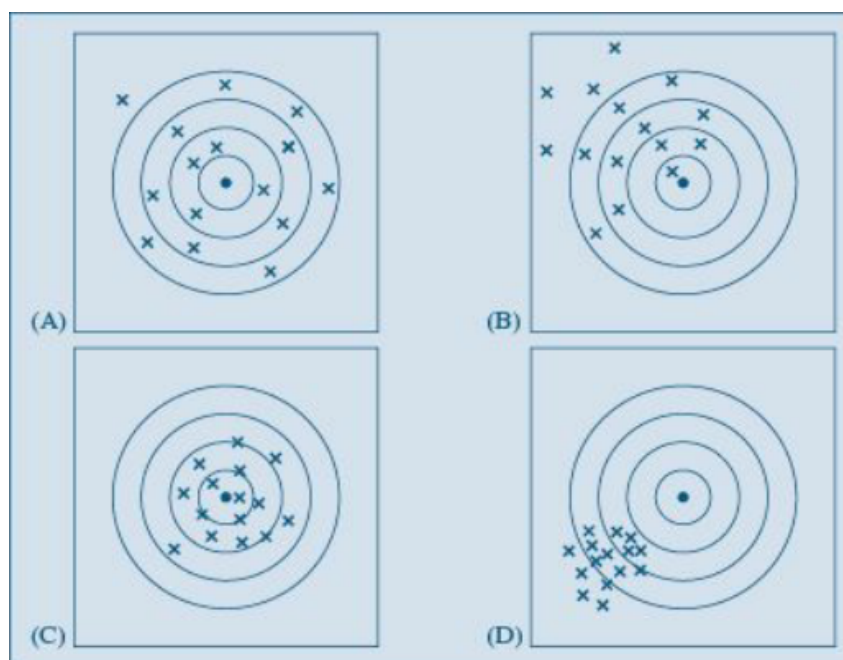


Figura 1:

Para analisar qual a melhor arma, podemos fixar critérios. Por exemplo, segundo o critério de “em média acertar o alvo”, escolheríamos as armas A e C. Segundo o critério de “não ser muito dispersivo” (variância pequena), a escolha recairia nas armas C e D. A arma C é aquela que reúne as duas propriedades e, segundo esses critérios, seria a melhor arma. Mas, se outro critério fosse introduzido (por exemplo, menor preço), talvez não fosse a arma escolhida. Muitas vezes, a solução deve ser um compromisso entre as propriedades. Esse exemplo também nos permite introduzir os conceitos de acurácia e precisão.

A acurácia mede a proximidade de cada observação do valor alvo que se procura atingir.

A precisão mede a proximidade de cada observação da média de todas as observações.

Desse modo, podemos descrever cada arma da seguinte maneira:

Arma A: não viesada, pouco acurada e baixa precisão.

Arma B: viesada, pouco acurada e baixa precisão.

Arma C: não viesada, muito acurada e boa precisão.

Arma D: viesada, pouco acurada e alta precisão.

Do exposto acima, notamos a importância de se definir propriedades desejáveis para estimadores. Trataremos desse assunto na próxima seção. Outro problema que aparece em inferência é como obter um estimador de deter-

minado parâmetro. Nem sempre temos uma sugestão para um estimador, como no caso da proporção, no Exemplo 11.1. Nas Seções 11.3, 11.4 e 11.5, trataremos de três desses métodos.

## 11.2: Propriedades de Estimadores

Inicialmente, vejamos a questão da estimação de um modo mais geral. Consideremos uma amostra  $(X_1, X_2, \dots, X_n)$  de uma v.a. que descreve uma característica de interesse de uma população. Seja  $\theta$  um parâmetro que desejamos estimar, por exemplo, a média  $\mu E(X)$  ou a variância  $\sigma^2 = Var(X)$ .

1cm

**Definição.** Um estimador  $T$  do parâmetro  $\theta$  é qualquer função das observações da amostra, ou seja,

$$T = g(X_1, \dots, X_n).$$

Notemos que, segundo essa definição, um estimador é o que chamamos antes de estatística, porém associando-o a um parâmetro populacional.

O problema da estimação é, então, determinar uma função  $T = g(X_1, X_2, \dots, X_n)$  que seja “próxima” de  $\theta$ , segundo algum critério. O primeiro critério que iremos abordar é dado a seguir.

**Definição.** O estimador  $T$  é não viesado para  $\theta$  se

$$E(T) = \theta \text{ para todo } \theta, \quad (11.4)$$

Se (11.4) não valer  $T$  diz-se viesado e a diferença

$$V(T) = E(T) - \theta$$

é chamado o viés de  $T$ .

Notemos que a esperança de  $T$  em (11.4) é calculada sobre a distribuição amostral de  $T$ , como tratada no capítulo anterior.

**Definição.** Estimativa é o valor assumido pelo estimador em uma particular amostra. Assim, no Exemplo 11.1, é um estimador de  $p$ , enquanto 0,6 é uma estimativa de  $p$ .

**Exemplo 11.3** Vimos que a média amostral  $\bar{X}$  é um estimador não viesado de  $\mu = E(X)$ , colhida uma amostra  $(X_1, \dots, X_n)$  da v.a.  $X$ . Do mesmo modo, como vimos na Seção 10.9, a proporção amostral é um estimador não viesado da proporção  $p$  de indivíduos de uma população que tem certa característica comum.

**Exemplo 11.4** Considere uma população com  $N$  elementos e a variância populacional

$$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \mu)^2}{N} \quad (11.5)$$

em que

$$\mu = \frac{\sum_{i=1}^N X_i}{N}$$

é a média populacional. Um possível estimador para  $\sigma^2$  baseado numa AAS de tamanho  $n$  extraída dessa população, é

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} \quad (11.6)$$

Mostremos que esse estimador é viesado. Pela fórmula (3.11), temos que

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2,$$

logo

$$E(\hat{\sigma}^2) = \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\bar{X}^2),$$

Mas, pela definição de AAS e definição de variância de uma v.a.,

$$E(X_i^2) = Var(X_i) + [E(X_i)]^2 = \sigma^2 + \mu^2$$

.

Também, usando o Teorema 10.1, temos que

$$E(\bar{X}^2) = Var(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2$$

Segue-se que

$$E(\hat{\sigma}^2) = \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) - \frac{\sigma^2}{n} - \mu^2$$

ou seja,

$$E(\hat{\sigma}^2) = \frac{1}{n} n (\sigma^2 + \mu^2) - \frac{\sigma^2}{n} - \mu^2 = \sigma^2 \left(1 - \frac{1}{n}\right)$$

Finalmente,

$$E(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2 \quad (11.7)$$

De (11.7) vemos que  $\hat{\sigma}^2$  é viesado para  $\sigma^2$  e o viés é dado por

$$V = E(\hat{\sigma}^2) - \sigma^2 = -\frac{\sigma^2}{n} \quad (11.8)$$

Como esse viés é negativo, o estimador  $\hat{\sigma}^2$  em geral subestima o verdadeiro parâmetro  $\sigma^2$ . Por outro lado, por (11.8), o viés diminui com  $n$ , ou seja, formalmente, para  $n \rightarrow \infty$ , o viés de  $\sigma^2$  tende a zero. Note também que o viés de  $\sigma^2$  uma função de  $\sigma^2$ . Uma estimativa do viés seria dada por

$$\hat{V} = -\frac{\hat{\sigma}^2}{n}$$

ou seja, substituímos o valor desconhecido de  $\sigma^2$  por uma estimativa, como por exemplo 2.

É fácil ver que para obter um estimador não viesado de  $\sigma^2$  basta considerar

$$\frac{n}{n-1} \hat{\sigma}^2$$

, pois de (11.7) segue-se que

$$E\left(\frac{n}{n-1} \hat{\sigma}^2\right) = \frac{n}{n-1} \frac{n-1}{n} \sigma^2 = \sigma^2.$$

Logo, se definirmos

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} \quad (11.9)$$

então  $E(S^2) = \sigma^2$  e  $S^2$  é um estimador não viesado para  $\sigma^2$ .

Essa é a razão para se usar  $n-1$ , em vez de  $n$ , como denominador da variância da amostra. No Capítulo 3, usamos sempre  $n$  como denominador, porque não havia preocupação em saber se estávamos trabalhando com uma população ou uma amostra. Daqui por diante, será feita essa distinção.

Vimos que o estimador  $\hat{p}$  é não viesado e tem variância que tende a zero, quando  $n \rightarrow \infty$ . Ver (11.2) e (11.3). Dizemos que  $\hat{p}$  é consistente. Esse conceito de consistência é um pouco mais difícil de se definir.

Vejamos um exemplo para motivar a definição que será dada.

Considere a média  $\bar{X}$  calculada para diversos tamanhos de amostras; obtemos, na realidade, uma sequência de estimadores  $\{\bar{X}_n, n = 1, 2, \dots\}$ .

À medida que  $n$  cresce, a distribuição de  $\bar{X}_n$  torna-se mais concentrada ao redor da verdadeira média  $\mu$ . Veja, por exemplo, a Figura 10.4 do Capítulo 10.

Dizemos que  $\{\bar{X}_n\}$  é uma sequência consistente de estimadores de  $\mu$ .

**Definição.** Uma sequência  $\{T_n\}$  de estimadores de um parâmetro  $\theta$  é consistente se, para todo  $\epsilon > 0$ ,

$$P(|T_n - \theta| > \epsilon) \rightarrow 0, \quad n \rightarrow \infty. \quad (11.10)$$

Não é muito difícil ver que essa condição está satisfeita para  $\{\bar{X}_n\}$ . Veja o Problema 33.

Em vez de usar (11.10) para verificar se uma sequência de estimadores é consistente, podemos usar o seguinte resultado.

**Proposição.** Uma sequência  $\{T_n\}$  de estimadores de  $\theta$  é consistente se

$$\lim_{n \rightarrow \infty} E(T_n) = \theta, \quad (11.11)$$

e

$$\lim_{n \rightarrow \infty} V(T_n) = 0, \quad (11.12).$$

Se  $T_n$  for não viesado, a primeira condição estará, obviamente, satisfeita. Usando esse resultado, vemos que  $\hat{p}$  e  $\bar{X}_n$  são estimadores consistentes de  $p$  e  $\mu$ , respectivamente, nos Exemplos 11.1 e 11.3.

**Exemplo 11.5** Vimos que  $S^2$ , dado por (11.9), é não viesado para  $\sigma^2$ . É possível demonstrar, no caso que  $X_1, X_2, \dots, X_n$  são observações de uma distribuição  $N(\mu, \sigma^2)$ , que

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}, \quad (11.13)$$

Como  $E(S^2) = \sigma^2$ , e  $\lim_{n \rightarrow \infty} V(S^2) = 0$  segue-se que  $S^2$  é um estimador consistente para  $\sigma^2$ .

Dado o que foi dito acima, talvez fosse melhor escrever  $S_n^2$ .

**Exemplo 11.6** Vimos que

$$E(\hat{\sigma}^2) = \sigma^2 \left(1 - \frac{1}{n}\right)$$

, de modo que

$$\lim_{n \rightarrow \infty} E(\hat{\sigma}^2) = \sigma^2.$$

Também, de (11.6) e (11.13) e supondo que as observações são de uma distribuição normal  $N(\mu, \sigma^2)$ , temos que

$$V(\hat{\sigma}^2) = \frac{(n-1)^2}{n^2} \text{Var}(S^2) = \frac{2(n-1)}{n^2} \sigma^4, \quad (11.14)$$

o que mostra que

$$V(\hat{\sigma}^2) \rightarrow 0, \text{ quando } n \rightarrow \infty$$

, logo também é consistente para  $\sigma^2$ .

Como

$$n > n-1$$

temos que

$$n^2 > (n-1)^2$$

e

$$\frac{1}{n^2} < \frac{1}{(n-1)^2}$$

Multiplicando por  $2(n-1)\sigma^4$  temos:

$$\frac{2(n-1)\sigma^4}{n^2} < \frac{2(n-1)\sigma^4}{(n-1)^2}$$

$$\frac{2(n-1)\sigma^4}{n^2} < \frac{2\sigma^4}{n-1}$$

ou

De (11.14) obtemos , também, que

$$\text{Var}(\hat{\sigma}^2) < \text{Var}(S^2), \quad (11.15).$$

Portanto, usando-se somente o critério de “ter menor variância”,  $\hat{\sigma}^2$  seria um “melhor” estimador de  $\sigma^2$ . Mas observe que estamos nos referindo a amostras de uma distribuição normal.

Vejamos agora um critério que nos permite escolher entre dois estimadores do mesmo parâmetro.

**Definição.** Se  $T$  e  $T'$  são dois estimadores não viesados de um mesmo parâmetro  $\theta$ , e ainda

$$\text{Var}(T) < \text{Var}(T'), \quad (11.16)$$

então  $T$  diz-se mais eficiente do que  $T'$ .



**Exemplo 11.7** Consideremos uma população normal  $X$ , com parâmetros  $\mu$  e  $\sigma^2$ . Queremos estimar a mediana dessa população. Por ser uma distribuição simétrica, sabemos que  $\mu = Md(X)$ . Definindo como  $\bar{X}$  a média e como  $md$  a mediana de uma amostra de tamanho  $n$  dessa população, qual dos dois estimadores é o melhor para estimar a mediana populacional? Pelo que vimos no capítulo anterior,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad (11.17)$$

Pode-se demonstrar que a distribuição da mediana amostral pode ser aproximada por uma normal, especificamente,

$$md \sim N\left(Md(X), \frac{\pi \sigma^2}{2n}\right) \quad (11.18)$$

Vemos, portanto, que os dois estimadores são não viesados, mas  $\bar{X}$  é mais eficiente, pois Conclui-se que, para estimar a mediana dessa população, é preferível usar a média da amostra como estimador, o que contraria um pouco a nossa intuição.

Para precisar o conceito de estimador acurado, discutido na seção anterior, vamos agora introduzir o conceito de erro quadrático médio.

Chamemos de

$$e = T - \theta,$$

o erro amostral que cometemos ao estimar o parâmetro  $\theta$  da distribuição da v.a.  $X$  pelo estimador  $T = g(X_1, \dots, X_n)$ , baseado na amostra  $(X_1, \dots, X_n)$ .

**Definição .** Chama-se erro quadrático médio (EQM) do estimador  $T$  ao valor

$$EQM(T; \theta) = E((T - \theta)^2) \quad (11.19)$$

De (11.19) temos

$$\begin{aligned} EQM(T; \theta) &= E(T - E(T) + E(T) - \theta)^2 \\ &= E((T - E(T))^2) + 2[E(T) - \theta][E(T - E(T))] + [E(T) - \theta]^2 \\ &= Var(T) + V^2, \end{aligned}$$

já que  $E(T) - \theta$  é uma constante e  $E(T - E(T)) = E(T) - E(T) = 0$ . Podemos, pois, escrever,

$$EQM(T; \theta) = Var(T) + V^2 \quad (11.20)$$

em que  $V = V(T) = E(T) - \theta$  indica, como vimos, o viés de  $T$ . A Figura 11.2

ilustra essas duas medidas, usando o caso das armas discutido no Exemplo 11.2.




Figura 2:

Vemos, portanto, que um estimador preciso tem variância pequena, mas pode ter EQM grande.

### Problemas

1. Obtenha a distribuição de  $\hat{p}$  quando  $p = 0,2$  e  $n = 5$ . Depois calcule  $E(\hat{p})$  e  $Var(\hat{p})$ .
2. Encontre um limite superior para  $Var(\hat{p})$  quando  $n = 10, 25, 100$  e  $400$ . Faça o gráfico em cada caso.
3. Suponha um experimento consistindo de  $n$  provas de Bernoulli, com probabilidade de sucesso  $p$ . Seja  $X$  o número de sucessos, e considere os estimadores

(a)  $\hat{p}_1 = \frac{X}{n}$ ;

(b)

$$\hat{p}_2 = \begin{cases} 1, & \text{se a primeira prova resultar sucesso,} \\ 0, & \text{caso contrário.} \end{cases}$$

Determine a esperança e a variância de cada estimador. Por que  $\hat{p}_2$  não é um “bom” estimador?

4. Verifique se  $\hat{p}_1$  e  $\hat{p}_2$  do Problema 3 são consistentes.

5. Tem-se duas fórmulas distintas para estimar um parâmetro populacional  $\theta$ . Para ajudar a escolher a melhor, simulou-se uma situação em que  $\theta = 100$ . Dessa população retiraram-se 1.000 amostras de dez unidades cada uma, e aplicaram-se ambas as fórmulas às dez unidades de cada amostra. Desse modo, obtêm-se 1.000 valores para a primeira fórmula  $t_1$  e outros 1.000 valores para a segunda fórmula  $t_2$ , cujos estudos descritivos estão resumidos abaixo. Qual das duas fórmulas você acha mais conveniente para estimar  $\theta$ . Por quê?

Fórmula 1	Fórmula 2
Média=102	Média=100
Variância=5	Variância=10
Mediana=100	Mediana=100
Moda=98	Moda=100

## 11.3 Estimadores de Momentos

Neste capítulo e em anteriores, temos usado certos estimadores de parâmetros populacionais, como a média e a variância, simplesmente tentando “imitar” na amostra o que acontece na população. Foi assim que construímos  $\bar{X}$ , por exemplo.

A média populacional é um caso particular daquilo que chamamos de momento. Na realidade, ela é o primeiro momento. Se  $X$  for uma v.a. contínua, com densidade

$$f(x; \theta_1, \theta_2, \dots, \theta_r),$$

dependendo de  $r$  parâmetros, então

$$\mu_1 = E(X) = \int_{-\infty}^{\infty} x f(x; \theta_1, \theta_2, \dots, \theta_r) dx, \quad (11.21)$$

Essa média dependerá, genericamente, dos parâmetros desconhecidos  $\theta_1, \theta_2, \dots, \theta_r$ . Por exemplo, suponha que  $X$  tenha distribuição normal, com parâmetros  $\mu$  e  $\sigma^2$ . Aqui,

$$\theta_1 = \mu, \theta_2 = \sigma^2, \quad r = 2.$$

Temos, nesse caso, que  $E(X) = \mu$ . Podemos, em geral, definir o  $k$ -ésimo momento de  $X$  por

$$\mu_k = E(X^k) = \int_{-\infty}^{\infty} x^k f(x; \theta_1, \theta_2, \dots, \theta_r) dx, \quad (11.22)$$

Assim, para  $k = 2$ , obtemos o segundo momento

$$\mu_2 = E(X^2) = \int_{-\infty}^{\infty} x^2 f(x; \theta_1, \theta_2, \dots, \theta_r) dx$$

No caso acima da normal, temos que

$$E(X^2) = Var(X) + [E(X)]^2 = \sigma^2 + \mu^2.$$

Suponha, agora, que colhemos uma amostra de tamanho  $n$  da população  $(X_1, \dots, X_n)$ . Definimos o chamado  $k$ -ésimo momento amostral por

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad (11.23)$$

Temos, portanto, que

$$m_1 = \bar{X} \quad e \quad m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

**Definição.** Dizemos que  $\theta_1, \theta_2, \dots, \theta_r$  são estimadores obtidos pelo método dos momentos se eles forem soluções das equações

$$m_k = \mu_k, \quad k = 1, 2, \dots, r. \quad (11.24)$$

O procedimento consiste em substituir os momentos teóricos pelos respectivos momentos amostrais.

**Exemplo 11.8** Se  $X$  tem média  $\mu$  e variância  $\sigma^2$ , teremos as seguintes relações válidas para os dois primeiros momentos populacionais:

$$E(X) = \mu, \quad E(X^2) = \sigma^2 + \mu^2,$$

do que obtemos

$$\mu = E(X), \quad \sigma^2 = E(X^2) - E^2(X).$$

Temos, também, os dois primeiros momentos amostrais:

$$m_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Os estimadores obtidos pelo método dos momentos serão

$$\hat{\mu}_M = m_1 = \bar{X}.$$

$$\hat{\sigma}_M^2 = m_2 - m_1^2 = \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

Ou seja, obtemos os já mencionados estimadores  $\bar{X}$  e  $\hat{\sigma}^2$ .

Na realidade, podemos ter, às vezes, mais de um estimador de momentos. Suponha, por exemplo, que a v.a.  $Y$  tenha uma distribuição de Poisson com parâmetro  $\lambda > 0$ . Vimos que

$$E(Y) = Var(Y) = \lambda,$$

de modo que  $\lambda$  pode ser estimado por  $\bar{Y}$  ou por

$$\hat{\lambda} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n}$$

ou seja

$$\hat{\lambda}_M = \bar{Y} \text{ ou } \hat{\lambda}_M = \hat{\sigma}_M^2.$$

Veja o Problema 46.

## 11.4 Estimadores de Mínimos Quadrados

Um dos procedimentos mais usados para obter estimadores é aquele que se baseia no princípio dos mínimos quadrados, introduzido por Gauss em 1794, mas que primeiro apareceu com esse nome no apêndice do tratado de Legendre, *Nouvelles Méthodes pour la Détermination des Orbites des Comètes*, publicado em Paris em 1806. Gauss somente viria a publicar seus resultados em 1809, em Hamburgo. Ambos utilizaram o princípio em conexão com problemas de Astronomia e Física.

Vejamos o procedimento por meio de um exemplo simples.

**Exemplo 11.9** Um engenheiro está estudando a resistência  $Y$  de uma fibra em função de seu diâmetro  $X$  e notou que as variáveis são aproximadamente proporcionais, isto é, elas obedecem à relação

$$Y \approx \theta X, \quad (11.25).$$

em que  $\theta$  é o coeficiente de proporcionalidade. Agora ele deseja estimar o parâmetro  $\theta$ , baseado numa amostra de cinco unidades, que, submetidas a mensuração e testes, produziram os resultados:

X:	1,2	1,5	1,7	2	2,6	$\bar{X} = 1,8$
Y	3,9	4,7	5,6	5,8	7,0	$\bar{Y} = 5,4$

Inspecionando os

resultados, conclui-se que  $\hat{\theta} = 3$  parece ser um valor razoável. Como verificar a qualidade dessa estimativa? Podemos utilizar o modelo

$$\hat{Y} = 3X$$

e ver como esse prevê os valores de  $Y$ , para os dados valores de  $X$ , e como são as discrepâncias entre os valores observados e os estimados pelo modelo.

Essa análise está resumida na Tabela 11.1

X	Y	$\hat{Y} = 3X$	$e = Y - \hat{Y}$	$e^2 = (Y - \hat{Y})^2$
1,2	3,9	3,6	0,3	0,09
1,5	4,7	4,5	0,2	0,04
1,7	5,6	5,1	0,5	0,25
2,0	5,8	6	-0,2	0,04
2,6	7,0	7,8	-0,8	0,64
		Total	0	1,06

Os valores da coluna  $(Y - 3X) = (Y - \hat{Y})$  medem a inadequação do modelo para cada observação da amostra, enquanto o valor é uma tentativa de medir

“o erro quadrático total da amostra”. Como em situações anteriores, elevou-se ao quadrado para evitar o problema do sinal. Quanto menor for o erro quadrático total, melhor será a estimativa.

Isso nos sugere procurar a estimativa que torne mínima essa soma de quadrados. Matematicamente, o problema passa a ser o de encontrar o valor de  $\theta$  que minimize a função

$$S(\theta) = \sum_{i=1}^5 (Y_i - \theta X_i)^2, \quad (11.26)$$

O mínimo da função é obtido derivando-a em relação a  $\theta$ , e igualando o resultado a zero (ver Morettin et al., 2005), o que resulta

$$\begin{aligned} S'(\theta) &= 2 \sum_{i=1}^5 (Y_i - \theta X_i)(-X_i), \\ S'(\theta) &= -2 \sum_{i=1}^5 (X_i Y_i - \theta X_i^2) = 0 \\ S'(\theta) &= -2 \sum_{i=1}^5 X_i Y_i + 2\theta \sum_{i=1}^5 X_i^2. \end{aligned}$$

A derivada segunda de  $S$  é dada por:

$$S''(\theta) = 2 \sum_{i=1}^5 X_i^2 > 0$$

Igualando a derivada primeira a zero temos:

$$\sum_{i=1}^5 X_i Y_i - \theta \sum_{i=1}^5 X_i^2 = 0$$

Assim

$$\theta = \frac{\sum_{i=1}^5 X_i Y_i}{\sum_{i=1}^5 X_i^2},$$

que é ponto de mínimo relativo pois a derivada segunda é sempre positiva.

O estimador de mínimos quadrados de  $\theta$  é dado por:

$$\hat{\theta}_{MQ} = \frac{\sum_{i=1}^5 X_i Y_i}{\sum_{i=1}^5 X_i^2}.$$

Usando os dados acima encontramos  $\hat{\theta}_{MQ} = 2,94$ , que conduz a um valor mínimo para  $S(\theta)$  de  $0,94$ . Observe que esse valor é realmente menor do que o observado para  $\theta = 3$ , ou seja,  $1,06$ .

Como foi dito, não esperávamos uma relação perfeita entre as duas variáveis, já que o diâmetro da fibra não é o único responsável pela resistência; outros fatores não controlados afetam o resultado. Desse modo, duas amostras obtidas do mesmo diâmetro  $X$  não teriam obrigatoriamente que apresentar o mesmo resultado  $Y$ , mas valores em torno de um valor esperado  $\theta X$ . Em outras palavras, estamos supondo que, para um dado valor da variável explicativa  $X$ , os valores da variável resposta  $Y$  seguem uma distribuição de probabilidade  $f_Y(y)$ , centrada em  $\theta X$ .

Isso equivale a afirmar que, para cada  $X$ , o desvio

$$\epsilon = Y - \theta X$$

segue uma distribuição centrada no zero. Para melhor entendimento dessa proposição, veja o Capítulo 16. Podemos, então, escrever

$$E(Y|x) = \theta x, \text{ para todo valor } x.$$

É comum supor que  $\epsilon$  tem a mesma distribuição, para todo valor  $x$  da variável explicativa  $X$ . Desse modo, é comum escrever

$$Y = \theta x + \epsilon$$

, com  $\epsilon$  seguindo a distribuição  $f_\epsilon(\cdot)$ , com média zero. Como ilustração, poderíamos supor que

$$\epsilon \sim N(0, \sigma^2), \text{ para todo } x.$$

Quanto menor for a variância  $\sigma^2$ , melhor será a “previsão” de  $Y$  como função de  $x$ . Assim, parece razoável escolher  $\theta$  que torna mínima a soma dos quadrados dos erros: O modelo acima pode ser generalizado, de modo a envolver outras funções do parâmetro, resultando no modelo

$$Y = g(X; \theta) + \epsilon, \quad (11.27)$$

e devemos procurar o valor de  $\theta$  que minimize a função

$$S(\theta) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - g(X_i; \theta))^2, \quad (11.28)$$

para uma amostra  $(X_1, Y_1), \dots, (X_n, Y_n)$  das variáveis  $X$  e  $Y$ . A solução MQ é chamada de estimador de mínimos quadrados (EMQ) de  $\theta$ . Nos Capítulos 15 e 16, voltaremos a esse tópico e trataremos com mais detalhes os chamados modelos lineares.

Suponha que

$$Y_i | X_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \dots, n$$



com

$$\epsilon_i \sim N(0, \sigma^2), \quad i = 1, 2, \dots, n$$

Na prática usamos:

$$Y_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \dots, n.$$

Aplicando o operador esperança temos:

$$E(Y_i) = \theta X_i + E(\epsilon_i) = \theta X_i + 0 = \theta X_i.$$

Calculando a variância temos:

$$\text{Var}(Y_i) = \text{Var}(\theta X_i + \epsilon_i) = \text{Var}(\epsilon_i) = \sigma^2.$$

Considere o estimador de MQ de  $\theta$  dado por:

$$\hat{\theta}_{MQ} = \frac{\sum_{i=1}^n X_i Y_i}{\sum_{i=1}^n X_i^2} = \sum_{i=1}^n w_i Y_i,$$

com

$$w_i = \frac{X_i}{\sum_{i=1}^n X_i^2}.$$

Inicialmente mostre que:

$$\sum_{i=1}^n w_i X_i = 1.$$

Prova

Temos que :

$$\begin{aligned} \sum_{i=1}^n w_i X_i &= \sum_{i=1}^n \frac{X_i}{\sum_{i=1}^n X_i^2} \times X_i. \\ \sum_{i=1}^n w_i X_i &= \frac{1}{\sum_{i=1}^n X_i^2} \sum_{i=1}^n X_i^2 = 1. \end{aligned}$$

Agora mostre que  $\hat{\theta}_{MQ}$  é um estimador não viciado de  $\theta$ .

$$\begin{aligned} E(\hat{\theta}_{MQ}) &= E\left(\sum_{i=1}^n w_i Y_i\right), \\ E(\hat{\theta}_{MQ}) &= \sum_{i=1}^n E(w_i Y_i) = \sum_{i=1}^n w_i E(Y_i) \end{aligned}$$

$$E\left(\hat{\theta}_{MQ}\right) = \sum_{i=1}^n w_i \theta X_i = \theta \sum_{i=1}^n X_i w_i$$

$$E\left(\hat{\theta}_{MQ}\right) = \theta \times 1 = \theta.$$

Agora mostre que:

$$\sum_{i=1}^n w_i^2 = \frac{1}{\sum_{i=1}^n X_i^2}.$$

Prova:

Seja

$$A = \sum_{i=1}^n X_i^2$$

Assim

$$w_i = \frac{X_i}{A}, \quad w_i^2 = \frac{X_i^2}{A^2}$$

$$\sum_{i=1}^n w_i^2 = \sum_{i=1}^n \frac{X_i^2}{A^2} = \frac{1}{A^2} \sum_{i=1}^n X_i^2$$

$$\sum_{i=1}^n w_i^2 = \frac{1}{A^2} A = \frac{1}{A} = \frac{1}{\sum_{i=1}^n X_i^2}$$

Agora mostre que a variância do estimador de mínimos quadrados de  $\theta$  é dada por:

$$Var\left(\hat{\theta}_{MQ}\right) = \frac{\sigma^2}{\sum_{i=1}^n X_i^2}.$$

Prova:

$$Var\left(\hat{\theta}_{MQ}\right) = Var\left(\sum_{i=1}^n w_i Y_i\right) = \sum_{i=1}^n Var(w_i Y_i),$$

$$Var\left(\hat{\theta}_{MQ}\right) = \sum_{i=1}^n w_i^2 V(Y_i) = \sum_{i=1}^n w_i^2 \sigma^2,$$

$$Var\left(\hat{\theta}_{MQ}\right) = \sigma^2 \sum_{i=1}^n w_i^2 = \frac{\sigma^2}{\sum_{i=1}^n X_i^2}.$$

Qual a distribuição Amostral do estimador de mínimos quadrados  $V = \hat{\theta}_{MQ}$ ?

**Prova:** Sabemos que

$$Y_i \sim N(\theta X_i, \sigma^2)$$

e sua função geradora de momentos é dada por:

$$M_{Y_i}(t) = \exp(\theta X_i t + \frac{1}{2} \sigma^2 t^2)$$

A função de momentos de  $V$  é dada por:

$$M_V(t) = E(e^{tV}) = E\left(e^{t \sum_{i=1}^n w_i Y_i}\right)$$

$$M_V(t) = E\left(e^{\sum_{i=1}^n w_i t Y_i}\right)$$

$$M_V(t) = \prod_{i=1}^n E(e^{w_i t Y_i}),$$

$$M_V(t) = \prod_{i=1}^n M_{Y_i}(w_i t)$$

$$M_V(t) = \prod_{i=1}^n \exp(\theta X_i w_i t + \frac{1}{2} \sigma^2 w_i^2 t^2)$$

$$M_V(t) = \exp\left(\theta t \sum_{i=1}^n X_i w_i + \frac{1}{2} \sigma^2 \sum_{i=1}^n w_i^2 t^2\right)$$

$$M_V(t) = \exp\left(\theta t \times 1 + \frac{1}{2} \times \sigma^2 \times \frac{1}{\sum_{i=1}^n X_i^2}\right)$$

$$M_V(t) = \exp\left(\theta t + \frac{1}{2} \times \frac{\sigma^2}{\sum_{i=1}^n X_i^2} t^2\right)$$

**Assim**

$$V = \hat{\theta}_{MQ} \sim N \left( \theta, \frac{\sigma^2}{\sum_{i=1}^n X_i^2} \right)$$

### Problemas

6. Estamos estudando o modelo  $y_t = \mu + \epsilon_t$ , para o qual uma amostra de cinco elementos produziu os seguintes valores para  $y_t$  : 3, 5, 6, 8, 16.

(a) Calcule os valores de

$$S(\mu) = \sum_t (y_t - \mu)^2$$

para  $\mu = 6, 7, 8, 9, 10$ , e faça o gráfico de  $S(\mu)$  em relação a  $\mu$ . Qual o valor de  $\mu$  que parece tornar mínimo  $S(\mu)$ ?

(b) Derivando  $S(\mu)$  em relação a  $\mu$ , e igualando o resultado a zero, você encontrará o EMQ de  $\mu$ . Usando os dados acima, encontre a estimativa para  $\mu$  e compare com o resultado do item anterior.

7. Os dados abaixo referem-se ao índice de inflação ( $y_t$ ) de 1967 a 1979.

Ano(t)	1967	1969	1971	1973	1975	1977	1979
Inflação( $y_t$ )	128	192	277	373	613	1236	2639

(a) Faça o gráfico de  $y_t$  contra  $t$ .

(b) Considere ajustar o modelo

$$y_t = \alpha + \beta t + \epsilon_t$$

aos dados. Encontre as estimativas de mínimos quadrados de  $\alpha$  e  $\beta$ .

(c) Qual seria a inflação em 1981?

(d) Você teria alguma restrição em adotar o modelo linear nesse caso?

8. No Problema 7, determinamos os estimadores de mínimos quadrados para o modelo

$$y_t = f(t) + \epsilon_t$$

, no qual

$$f(t) = \alpha + \beta t$$

Suponha agora que

$$f(t) = \alpha + \beta x_t, \quad t = 1, 2, \dots, n,$$

ou seja, temos  $n$  valores fixos  $x_1, x_2, \dots, x_n$  uma variável fixa (não aleatória)  $x$ . Obtenha os EMQ de  $\alpha$  e  $\beta$  para esse modelo.

9. Aplique os resultados do Problema 8 para os dados a seguir:

t	1	2	3	4	5	6	7	8	9	10
$x_t$	1,5	1,8	1,6	2,5	4,0	3,8	4,5	5,1	6,5	6,0
$y_t$	66,8	67,0	66,9	67,6	68,9	68,7	69,3	69,8	71,0	70,6

## 11.5 Estimadores de Máxima Verossimilhança

O Novo Dicionário Aurélio da Língua Portuguesa (2ª edição, 1986) define verossímil (ou verossimilhante) aquilo que é semelhante à verdade, provável, e verossimilhança (ou verossimilidade, ou ainda verossimilitude), à qualidade ou caráter de verossímil. O que seria uma amostra verossímil? Seria uma amostra que fornecesse a melhor informação possível sobre um parâmetro de interesse da população, desconhecido, e que desejamos estimar.

O princípio da verossimilhança afirma que devemos escolher aquele valor do parâmetro desconhecido que maximiza a probabilidade de obter a amostra particular observada, ou seja, o valor que torna aquela amostra a “mais provável”. O uso desse princípio conduz a um método de estimação pelo qual se obtêm os chamados estimadores de máxima verossimilhança que, em geral, têm propriedades muito boas. Esse princípio foi enunciado por Fisher pela primeira vez em 1912 e, em 1922, deu-lhe forma mais completa, introduzindo a expressão “likelihood” (verossimilhança). Veja Fisher (1935) para mais detalhes.

Vamos começar com um exemplo.

**Exemplo 11.10** Suponha que temos  $n$  provas de Bernoulli com  $P(\text{sucesso}) = p$ ,  $0 < p < 1$  e  $X$  = número de sucessos. Devemos tomar como estimador aquele valor de  $p$  que torna a amostra observada a mais provável de ocorrer.

Suponha, por exemplo, que  $n = 3$  e obtemos dois sucessos e um fracasso. A função de verossimilhança é

$$L(p) = P(2 \text{ sucessos e } 1 \text{ fracasso}) = p^2(1 - p).$$

Maximizando essa função em relação a  $p$ , obtemos

$$L'(p) = 2p(1 - p) - p^2 = 2p - 3p^2.$$

A derivada segunda de  $L(p)$  é dada por:

$$L''(p) = 2 - 6p.$$

Igualando a derivada primeira a zero temos:

$$L'(p) = p(2 - 3p) = 0,$$

do que seguem  $p = 0$  ou  $p = \frac{2}{3}$ .

Note que

$$L(0) = 0 \quad e \quad L\left(\frac{2}{3}\right) = \frac{4}{9} \times \frac{1}{3} = \frac{4}{27}.$$

É fácil ver que o ponto máximo é  $\frac{2}{3}$ ,  
pois

$$L''\left(\frac{2}{3}\right) = 2 - 6 \times \frac{2}{3} = 2 - 4 = -2 < 0.$$

que é a estimativa de máxima verossimilhança (EMV) de  $p$ .

. De modo geral, o EMV do parâmetro  $p$  de uma distribuição binomial é parâmetro  $p$  de uma distribuição binomial é

$$\hat{p} = \frac{X}{n} \quad (11.29)$$

que é o estimador usado anteriormente no Exemplo 11.1.

Para chegar a (11.29), observe que a função de verossimilhança nesse caso é

$$L(p) = p^x(1 - p)^{n-x},$$

que é a probabilidade de se obter  $x$  sucessos e  $n - x$  fracassos.

O máximo dessa função ocorre no mesmo ponto

$$l(p) = \log(L(p)),$$

em  $\log(a)$  é o logaritmo natural ou neperiano de  $a$ .

Assim,

$$l(p) = \log(p^x(1 - p)^{n-x}) = \log(p^x) + \log((1 - p)^{n-x}),$$

$$l(p) = x \log(p) + (n - x) \log(1 - p)$$

Derivando temos:

$$l'(p) = \frac{x}{p} - \frac{n - x}{1 - p}$$

e igualando a zero

$$\frac{x}{p} - \frac{n-x}{1-p} = 0$$

$$\frac{x}{p} = \frac{n-x}{1-p}$$

que pode ser posta na forma:

$$\frac{p}{1-p} = \frac{x}{n-x}$$

Aplicando propriedades de proporção temos:

$$\frac{p}{p+1-p} = \frac{x}{x+n-x},$$

Assim

$$p = \frac{x}{n}.$$

O estimador de MV de  $p$  é dado por:  
obtemos

$$\hat{p}_{MV} = \frac{X}{n}.$$

Na realidade o livro passa por cima de vários detalhes que serão agora feitos:

A derivada segunda de  $L(p)$  é dada por

$$l''(p) = -\frac{x}{p^2} - \frac{n-x}{(1-p)^2}$$

Note que

$$n\hat{p} = x \quad e \quad n-x = n-n\hat{p} = n(1-\hat{p}).$$

$$l''(\hat{p}) = -\frac{x}{\hat{p}^2} - \frac{n-x}{(1-\hat{p})^2}$$

$$l''(\hat{p}) = -\frac{n\hat{p}}{\hat{p}^2} - \frac{n(1-\hat{p})}{(1-\hat{p})^2}$$

$$l''(\hat{p}) = -n \left[ \frac{1}{\hat{p}} + \frac{1}{1-\hat{p}} \right]$$

$$l''(\hat{p}) = -\frac{n}{\hat{p}(1-\hat{p})} < 0,$$

para  $0 < \hat{p} < 1$ . A condição do máximo está satisfeita.

Note para  $x = 0$  temos

$$L(p) = (1-p)^n$$

que é uma função sempre decrescente em  $p$ . O máximo ocorre em  $p = 0 = \frac{0}{n}$ .

E para  $x = n$  temos

$$L(p) = p^n$$

que é uma função sempre crescente em  $p$ . O máximo ocorre em  $p = 1 = \frac{n}{n}$ .

Falta mais um lembrete. Para acharmos o máximo procuramos os pontos em que:

$$L'(p) = 0.$$

No caso em que

$$l(p) = \log(L(p)).$$

$$l'(p) = \frac{L'(p)}{L(p)} = 0,$$

portanto  $l'(p) = 0$  quando  $L'(p) = 0$ .

Na realidade este estimador obtido é da Bernoulli de parâmetro  $p$ . Veja:

$$f(x, p) = p^x (1 - p)^{1-x} I_A(x), A = \{0, 1\}.$$

Seja  $(x_1, x_2, \dots, x_n)$  uma amostra aleatória de  $X$ . A função de verossimilhança de  $P$  é dada por:

$$L(p) = \prod_{i=1}^n f(x_i, p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}$$

$$L(p) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$

Fazendo

$$s = \sum_{i=1}^n x_i$$

temos

$$l(p) = p^s (1 - p)^{n-s},$$

que é a verossimilhança anterior.

Vamos continuar no livro:

O procedimento, pois, é obter a função de verossimilhança, que depende dos parâmetros desconhecidos e dos valores amostrais, e depois maximizar essa função ou o logaritmo dela, o que pode ser mais conveniente em determinadas situações.

Chamando de

$$L(\theta; X_1, \dots, X_n)$$

a função de verossimilhança,



### O logaritmo da função de verossimilhança

$$l(\theta; X_1, \dots, X_n) = \log(L(\theta; X_1, \dots, X_n)).$$

No caso de variáveis contínuas, a função de verossimilhança é definida da seguinte maneira. Suponha que a v.a.  $X$  tenha densidade  $f(x; \theta)$ , onde destacamos a dependência do parâmetro  $\theta$  desconhecido. Retiramos uma amostra de  $X$ , de tamanho  $n$ ,  $(X_1, \dots, X_n)$ , e sejam  $(x_1, \dots, x_n)$  os valores efetivamente observados.

#### Definição.

A função de verossimilhança é definida por

$$L(\theta; x_1, \dots, x_n) = f(x_1; \theta) \dots f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) \quad (11.30)$$

que deve ser encarada como uma função de  $\theta$ . O estimador de máxima verossimilhança de  $\theta$  é o valor  $\theta_{MV}$  que maximiza  $L(\theta; x_1, \dots, x_n)$ .

Se indicarmos por  $\mathbf{x} = (x_1, \dots, x_n)^t$  o vetor contendo a amostra, é costume denotar a verossimilhança por  $L(\theta|\mathbf{x})$  e a log-verossimilhança por  $l(\theta|\mathbf{x})$ .

O parâmetro  $\theta$  pode ser um vetor,

como no caso de querermos estimar a média  $\mu$  e a variância  $\sigma^2$  de uma normal.

Nesse caso,

$$\theta = (\mu, \sigma^2)^t.$$

**Exemplo 11.11** Suponha que a v.a.  $X$  tenha distribuição exponencial, com parâmetro  $\alpha > 0$ , desconhecido, e queremos obter o EMV desse parâmetro. A densidade de  $X$  é dada por 7.26

$$f(x, \alpha) = \frac{1}{\alpha} e^{-\frac{x}{\alpha}} I_A(x), \quad a = (0, \infty)$$

Então, a verossimilhança é dada por

$$L(\alpha|\mathbf{x}) = \prod_{i=1}^n \frac{1}{\alpha} e^{-\frac{x_i}{\alpha}} = \frac{1}{\alpha^n} e^{-\frac{s}{\alpha}},$$

em que

$$s = \sum_{i=1}^n x_i.$$

e o logaritmo da função de verossimilhança fica

$$l(\alpha|\mathbf{x}) = -n \log(\alpha) - \frac{s}{\alpha}.$$

Derivando

$$l'(\alpha|\mathbf{x}) = -\frac{n}{\alpha} + \frac{s}{\alpha^2} = -n(\alpha)^{-1} + s(\alpha)^{-2}.$$

A derivada segunda é dada por:

$$l''(\alpha|\mathbf{x}) = n(\alpha)^{-2} - 2s(\alpha)^{-3}.$$

De  $l'(\alpha|\mathbf{x}) = 0$  temos:

$$-\frac{n}{\alpha} + \frac{s}{\alpha^2} = 0$$

$$-n\alpha + s = 0$$

$$\alpha = \frac{s}{n}.$$

Note que:

$$l''\left(\frac{s}{n}\right) = n\left(\frac{s}{n}\right)^{-2} - 2s\left(\frac{s}{n}\right)^{-3} = n\frac{n^2}{s^2} - 2s\frac{n^3}{s^3}.$$

$$l''\left(\frac{s}{n}\right) = \frac{n^3}{s^2} - 2\frac{n^3}{s^2} = -\frac{n^3}{s^2} < 0.$$

O EMV de  $\alpha$  é

$$\hat{\alpha}_{MV} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X} \quad (11.31).$$

que nada mais é do que a média amostral. Lembremos que na distribuição exponencial  $E(X) = \alpha$ , e portanto o estimador obtido é o esperado pelo senso comum.

Na nossa disciplina usamos a seguinte parametrização da distribuição exponencial:

$$f(x, \theta) = \theta e^{-\theta x} I_A(x), \quad A = (0, \infty).$$

Vamos achar o EMV de  $\theta$ :

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum_{i=1}^n x_i} = \theta^n e^{-\theta s}$$

$$l(\theta) = n \log(\theta) - \theta s$$

A derivada primeira é dada por:

$$l'(\theta) = \frac{n}{\theta} - s.$$

A derivada segunda é dada por:

$$l''(\theta) = -\frac{n}{\theta^2} < 0.$$

Fazendo  $l'(\theta) = 0$  temos:

$$\frac{n}{\theta} = s.$$

$$\theta = \frac{s}{n}.$$

O estimador de MV de  $\theta$  é dado por:

$$\hat{\theta}_{MV} = \frac{n}{\sum_{i=1}^n X_i} = \frac{n}{n \bar{X}} = \frac{1}{\bar{X}}.$$

Note uma coisa interessante o valor esperado de  $X$  vale

$$E(X) = g(\theta) = \frac{1}{\theta} = \alpha.$$

O estimador de máxima verossimilhança de  $E(X)$  é dado por:

$$\hat{E}(X) = \hat{\alpha}_{MV} = \bar{X}.$$

Que também pode ser obtido através da propriedade da Invariância dos estimadores de Máxima Verossimilhança que diz:

$$g(\hat{\theta}) = g(\hat{\theta}).$$

Para

$$\mu = E(X) = g(\theta) = \frac{1}{\theta}.$$

$$\hat{\mu} = g\left(\frac{1}{\bar{X}}\right) = \bar{X}.$$

$$E(X) = g(\theta) = \frac{1}{\theta} = \alpha.$$

O estimador de máxima verossimilhança de  $\sigma^2 = V(X) = \frac{1}{\theta^2}$  é dado por:

Para

$$\sigma^2 = V(X) = g(\theta) = \frac{1}{\theta^2}.$$

$$\hat{\sigma}^2 = g\left(\frac{1}{\bar{X}}\right) = \bar{X}^2.$$

A única condição exigida sobre  $g(\theta)$  é que ela seja uma função mensurável. No caso discreto, a função de verossimilhança pode ser escrita na forma

$$L(\theta; x_1, \dots, x_n) = P(X_1 = x_1 | \theta) \dots P(X_n = x_n | \theta) = f(x_1 | \theta) \dots f(x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$$

Na realidade não tem diferença usamos a função densidade de probabilidade no caso contínuo ou a função de probabilidade no caso discreto.

Veja o Problema 37 para o caso de termos mais de um parâmetro.

**Exemplo** Seja  $X \sim \text{Bin}(5, \theta)$ . Qual o estimador de MV para  $\theta$  baseado em uma amostra aleatória  $X_1, X_2, \dots, X_n$  ?

**Solução:** A f.p. de  $X$  é dada por:

$$f(x|\theta) = \binom{5}{x} \theta^x (1-\theta)^{5-x} I_A(x), \quad A = \{0, 1, 2, 3, 4, 5\},$$

com

$$\mu = E(X) = 5\theta \quad \mathbb{E} \quad V(X) = 5\theta(1-\theta).$$

A função de verossimilhança é dada por:

$$L(\theta) = \prod_{i=1}^n \binom{5}{x_i} \theta^{x_i} (1-\theta)^{5-x_i}.$$

$$L(\theta) = \prod_{i=1}^n \binom{5}{x_i} \times \theta^s \times (1-\theta)^{5n-s},$$

$$s = \sum_{i=1}^n x_i.$$

O logaritmo da função de verossimilhança é dado por:

$$l((\theta)) = \sum_{i=1}^n \log\left(\binom{5}{x_i}\right) + s \log(\theta) + (5n-s) \log(1-\theta)$$

A derivada primeira é dada por:

$$l'(\theta) = \frac{s}{\theta} - \frac{5n-s}{1-\theta}.$$

Fazendo  $l'(\theta) = 0$  temos:

$$\frac{s}{\theta} = \frac{5n-s}{1-\theta}.$$

$$\frac{\theta}{1-\theta} = \frac{s}{5n-s}.$$

$$\frac{\theta}{\theta+1-\theta} = \frac{s}{s+5n-s}.$$

$$\theta = \frac{s}{5n} = \frac{n \bar{x}}{5n} = \frac{\bar{x}}{5}.$$

A derivada segunda é dada por:

$$l''(\theta) = -\frac{s}{\theta^2} - \frac{5n-s}{(1-\theta)^2}.$$

Assim,

$$l''\left(\frac{s}{5n}\right) = -\frac{s}{\frac{s^2}{25n^2}} - \frac{5n-s}{\left(1-\frac{s}{5n}\right)^2}.$$

$$l''\left(\frac{s}{5n}\right) = -\frac{25n^2}{s} - \frac{25n^2}{5n-s}$$

$$l''\left(\frac{s}{5n}\right) = -25n^2 \left[ \frac{1}{s} + \frac{1}{5n-s} \right] = -\frac{125n^3}{s(5n-s)} < 0, \quad s \neq 0, 5n.$$

O estimador de MV  $T$  de  $\theta$  é dado por:

$$T = \frac{\bar{X}}{5}.$$

Note que:

$$E(T) = \frac{E(\bar{X})}{5} = \frac{\mu}{5} = \frac{5\theta}{5} = \theta$$

assim  $T$  é não viciado para  $\theta$ .

$$V(T) = \frac{V(\bar{X})}{25} = \frac{\frac{\sigma^2}{n}}{25} = \frac{\sigma^2}{25n} = \frac{5\theta(1-\theta)}{25n} = \frac{\theta(1-\theta)}{5n}.$$

$$\lim_{n \rightarrow \infty} V(T) = \frac{\theta(1-\theta)}{5} \lim_{n \rightarrow \infty} \frac{1}{n} = 0.$$

$T$  é um estimador consistente de  $\theta$ .

Em algumas situações práticas função de verossimilhança é uma função crescente ou decrescente do parâmetro  $\theta$ . Assim não podemos derivá-la para obter o estimador de MV.

**Exemplo** Seja  $X$  uma variável aleatória contínua com f.d.p. dada por:

$$f(x; \theta) = e^{-(x-\theta)} I_A(x), \quad A = [\theta, \infty), \theta > 0.$$

Note que o suporte depende de  $\theta$ .

Assim na verossimilhança não podemos descartar o suporte.

Logo

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n e^{-(x_i-\theta)} I_A(x_i)$$

$$L(\theta) = e^{-\sum_{i=1}^n x_i} e^{n\theta} \prod_{i=1}^n I_A(x_i)$$

$$L(\theta) = e^{-s} e^{n\theta} \prod_{i=1}^n I_A(x_i)$$

Mas

$$\prod_{i=1}^n I_A(x_i) = 1.$$

Quando

$$I_A(x_1) = 1, I_A(x_2) = 1, \dots, I_A(x_n) = 1.$$

Ou

$$x_1 \geq \theta, x_2 \geq \theta, \dots, x_n \geq \theta.$$

Ou

$$y_1 = \min(x_1, x_2, \dots, x_n) \geq \theta.$$

Ou

$$0 < \theta \leq y_1$$

ou

$$I_{(0, y_1]}(\theta) = 1.$$

Logo a verossimilhança fica:

$$L(\theta) = e^{-s} e^{n\theta} I_{([0, y_1])}(\theta).$$

Maximizar  $L(\theta)$  é maximizar  $g(\theta) = e^{n\theta}$ .

Mas

$$g'(\theta) = n e^{n\theta} > 0.$$

Logo  $g(\theta)$  é uma função sempre crescente . Seu máximo ocorre no limite superior do seu domínio.

Assim

$$\hat{\theta} = y_1 = \min(x_1, x_2, \dots, x_n).$$

Assim o EMV de  $\theta$  é:

$$Y_1 = \min(X_1, X_2, \dots, X_n).$$

A f.d.p. de  $Y_1$  é dada por:

$$g_{Y_1}(y) = n [1 - F_X(y)]^{n-1} f(y) = n[S(y)]^{n-1} f(y).$$

Mas para  $y > \theta$

$$S(y) = \int_y^\infty e^{-(t-\theta)} dt = e^{-(y-\theta)}.$$

$$g_{Y_1}(y) = n [1 - F_X(y)]^{n-1} f(y) = n[e^{-(y-\theta)}]^{n-1} e^{-(y-\theta)} I_{[\theta, \infty]}(y).$$

$$g_{Y_1}(y) = n e^{-n(y-\theta)} I_{[\theta, \infty]}(y).$$

O valor esperado de  $Y_1$  é dado por:

$$E(Y_1) = \int_{\theta}^{\infty} ny e^{-n(y-\theta)} dy = \int_{\theta}^{\infty} y e^{-n(y-\theta)} n dy$$

Fazendo a mudança de variável:

$$u = n(y - \theta) \quad , \quad du = n dy.$$

logo

$$y = \frac{u}{n} + \theta.$$

Assim

$$E(Y_1) = \int_0^{\infty} \left( \frac{u}{n} + \theta \right) e^{-u} du$$

temos

$$E(Y_1) = \frac{1}{n} \int_0^{\infty} u e^{-u} du + \theta \int_0^{\infty} e^{-u} du$$

$$E(Y_1) = \frac{1}{n} \Gamma(2) + \theta \Gamma(1) = \frac{1}{n} + \theta,$$

pois  $\Gamma(2) = 1! = 1$  e  $\Gamma(1) = 0! = 1$ .

Logo

$$T = Y_1 - \frac{1}{n}$$

é um estimador não viciado de  $\theta$ .

Note que

$$Var(T) = Var\left(Y_1 - \frac{1}{n}\right) = Var(Y_1).$$

O valor esperado de  $Y_1^2$  é dado por:

$$E(Y_1^2) = \int_{\theta}^{\infty} ny^2 e^{-n(y-\theta)} dy = \int_{\theta}^{\infty} y^2 e^{-n(y-\theta)} n dy$$

Fazendo a mesma mudança de variável temos:

$$E(Y_1^2) = \int_0^{\infty} \left( \frac{u}{n} + \theta \right)^2 e^{-u} du$$

temos

$$E(Y_1^2) = \frac{1}{n^2} \int_0^{\infty} u^2 e^{-u} du + \frac{2\theta}{n} \int_0^{\infty} u e^{-u} du + \theta^2 \int_0^{\infty} e^{-u} du$$

$$E(Y_1^2) = \frac{1}{n^2} \Gamma(3) + \frac{2\theta}{n} \Gamma(2) + \theta^2 \Gamma(1).$$

$$E(Y_1^2) = \frac{2}{n^2} + \frac{2\theta}{n} + \theta^2,$$

pois  $\gamma(3) = 2! = 2$ .

$$E(Y_1^2) = \theta^2 + \frac{2\theta}{n} + \frac{1}{n^2} + \frac{1}{n^2},$$

$$E(Y_1^2) = \left[ \theta + \frac{1}{n} \right]^2 + \frac{1}{n^2}.$$

Finalmente temos:

$$V(Y_1) = E(Y_1^2) - E^2(Y_1) = \left[ \theta + \frac{1}{n} \right]^2 + \frac{1}{n^2} - \left[ \theta + \frac{1}{n} \right]^2 = \frac{1}{n^2}$$

Note que  $Y_1$  não é um estimador não viciado de  $\theta$  mas assintoticamente ele é:

$$\lim_{n \rightarrow \infty} E(Y_1) = \lim_{n \rightarrow \infty} \left( \theta + \frac{1}{n} \right) = \theta + 0 = \theta.$$

Além disso

$$\lim_{n \rightarrow \infty} V(Y_1) = \lim_{n \rightarrow \infty} \frac{1}{n^2} = 0,$$

Assim  $Y_1$  é um estimador consistente de  $\theta$ .

## Problemas

10. Na função de verossimilhança  $L(p)$  da binomial, suponha que  $n = 5$  e  $x = 3$ . Construa o gráfico da função para os possíveis valores de

$$p = \frac{1}{5}, \frac{2}{5}, \frac{3}{5}, \frac{4}{5},$$

e verifique que o máximo ocorre realmente para  $p = \frac{3}{5}$ .

11. Observa-se uma sequência de ensaios de Bernoulli, independentes, com parâmetro  $p$ , até a ocorrência do primeiro sucesso. Se  $X$  indicar o número de ensaios necessários:

(a) Mostre que

$$P(X = x) = p(1-p)^{x-1}I_A(x), \quad a = \{1, 2, \dots\},$$

(distribuição geométrica).

(b) Repetiu-se esse experimento  $n$  vezes e, em cada um deles, o número de ensaios necessários foram  $x_1, x_2, \dots, x_n$ . Encontre o EMV para  $p$ .

(c) Usando uma moeda, repetiu-se esse experimento 5 vezes, e o número de ensaios necessários até a ocorrência da primeira coroa foi 2, 3, 1, 4, 1, respectivamente. Qual a estimativa de MV para  $p$  = probabilidade de ocorrência de coroa nessa moeda?



Existiria outra maneira de estimar  $p$ ?

12. Suponha que  $X$  seja uma v.a. com distribuição normal, com média  $\mu$  e variância 1. Obtenha o EMV de  $\mu$ , para uma amostra de tamanho  $n$ ,  $x_1, \dots, x_n$ .

13. Considere  $Y$  uma v.a. com distribuição de Poisson, com parâmetro  $\lambda > 0$ . Obtenha a EMV de  $\lambda$ , baseado numa amostra de tamanho  $n$ .

## 11.6 Intervalos de Confiança

Até agora, todos os estimadores apresentados foram pontuais, isto é, especificam um único valor para o estimador. Esse procedimento não permite julgar qual a possível magnitude do erro que estamos cometendo. Daí, surge a ideia de construir os intervalos de confiança, que são baseados na distribuição amostral do estimador pontual.

**Exemplo 11.12** Suponha que queiramos estimar a média  $\mu$  de uma população qualquer, e para tanto usamos a média  $\bar{X}$  de uma amostra de tamanho  $n$ . Do TLC,

$$E = \bar{X} - \mu \sim N(0, \sigma_{\bar{X}}^2), \quad (11.32)$$

com

$$Var(\bar{X}) = \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}.$$

Daqui podemos determinar qual a probabilidade de cometermos erros de determinadas magnitudes. Por exemplo,

$$P(|E| < 1,96 \sigma_{\bar{X}}) = 0,95$$

ou

$$P(|\bar{X} - \mu| < 1,96 \sigma_{\bar{X}}) = 0,95$$

que é equivalente a

$$P(-1,96 \sigma_{\bar{X}} < \bar{X} - \mu < 1,96 \sigma_{\bar{X}}) = 0,95$$

e, finalmente,

$$P(\bar{X} - 1,96 \sigma_{\bar{X}} < \mu < \bar{X} + 1,96 \sigma_{\bar{X}}) = 0,95 \quad (11.33)$$

Convém lembrar que  $\mu$  não é uma variável aleatória e sim, um parâmetro, e a Fórmula (11.33) deve ser interpretada da seguinte maneira: se pudéssemos construir uma quantidade grande de intervalos (aleatórios!) da forma

$$]\bar{X} - 1,96 \sigma_{\bar{X}}, \bar{X} + 1,96 \sigma_{\bar{X}}[$$

, todos baseados em amostras de tamanho  $n$ , 95% deles conteriam o parâmetro  $\mu$ . Veja a Figura 11.3.

Dizemos que  $\gamma = 0,95$  é o coeficiente de confiança. Nessa figura, estão esquematizados o funcionamento e o significado de um intervalo de confiança (IC) para  $\mu$ , com  $\gamma = 0,95$  e  $\sigma^2$  conhecido.

Figura 11.3 Significado de um IC para  $\mu$ , com  $\gamma = 0,95$  e  $\sigma^2$  conhecido.

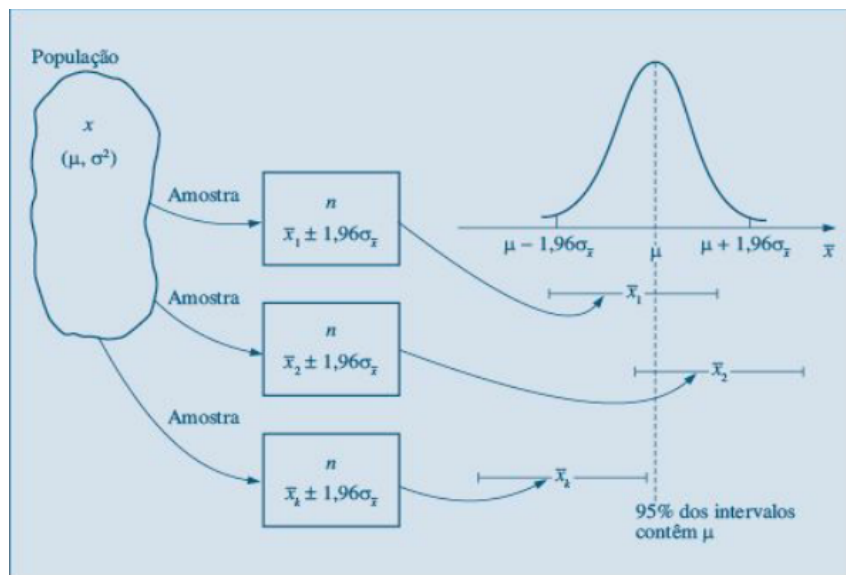


Figura 3:

Escolhida uma amostra e encontrada sua média  $\bar{x}_0$ , e admitindo-se  $\sigma$  conhecido, podemos construir o intervalo

$$]\bar{x}_0 - 1,96 \sigma_{\bar{X}}; \bar{x}_0 + 1,96 \sigma_{\bar{X}}[ \quad ](11.34)$$

Esse intervalo pode ou não conter o parâmetro  $\mu$ , mas pelo exposto acima temos 95% de confiança de que contenha.

Para ilustrar o que foi dito acima, consideremos o seguinte experimento de simulação. Geramos 20 amostras de tamanho  $n = 25$  de uma distribuição normal de média  $\mu = 5$  e desvio padrão  $\sigma = 3$ . Para cada amostra construímos o intervalo de confiança para  $\mu$ , com coeficiente de confiança  $\gamma = 0,95$ , que é da forma

$$\bar{X} \pm 1,176$$

, usando (11.34).

Na Figura 11.4, temos esses intervalos representados e notamos que três deles (amostras de números 5, 14 e 15) não contêm a média  $\mu = 5$ .

Figura 11.4 Intervalos de confiança para a média de uma  $N(5, 9)$ , para 20 amostras de tamanho  $n = 25$ .




Figura 4:

**Exemplo 11.13**

Uma máquina enche pacotes de café com uma variância igual a  $100 \text{ g}^2$ . Ela estava regulada para encher os pacotes com 500 g, em média. Agora, ela se desregulou, e queremos saber qual a nova média  $\mu$ . Uma amostra de 25 pacotes apresentou uma média igual a 485 g. Vamos construir um intervalo de confiança com 95% de confiança para  $\mu$ . De (11.34), teremos

$$IC(\mu, ; 0, 95) = 485 \pm 1,96 \times 2,$$

ou seja

$$IC(\mu, ; 0, 95) = ]480,8, 489,2,$$

pois

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{10}{5} = 2 \text{ g}.$$

Se  $T$  for um estimador do parâmetro  $\theta$ , e conhecida a distribuição amostral de  $T$ , sempre será possível achar dois valores  $t_1$  e  $t_2$ , tais que

$$P(t_1 < \theta < t_2) \gamma \quad (11.35).$$

a probabilidade interpretada como em (11.33), e  $\gamma$  um valor fixo,  $0 < \gamma < 1$ . Para uma dada amostra, teremos dois valores fixos para  $t_1$  e  $t_2$ , e o intervalo de confiança para  $\theta$ , com coeficiente de confiança  $\gamma$ , será indicado do seguinte modo:

$$IC(\theta; \gamma) = ]t_1, t_2[ \quad ; \quad (11.36)$$

Se a variância populacional  $\sigma^2$  não for conhecida, podemos substituir em (11.34),

$$\sigma_{\bar{X}}$$

por

$$\frac{S}{\sqrt{n}},$$

em que  $S^2$  é a variância amostral dada em (11.9).

Para  $n$  grande, da ordem de 100, o intervalo (11.34), com essa modificação, pode ainda ser usado.

Para  $n$  não muito grande, a distribuição normal não pode mais ser usada e terá de ser substituída pela distribuição  $t$  de Student, que estudamos no Capítulo 7. Esse assunto voltará a ser abordado no Capítulo 12.

Para um coeficiente de confiança qualquer  $\gamma$ , teremos de usar o valor  $z(\gamma)$  tal que

$$P(-z(\gamma) < Z < z(\gamma)) = \gamma$$

, com  $Z \sim N(0, 1)$ .

O intervalo fica

$$IC(\mu; \gamma) = ]\bar{X} - z(\gamma) \sigma_{\bar{X}} ; \bar{X} + z(\gamma) \sigma_{\bar{X}}[ \quad (11.37)$$

Observe, também, que a amplitude do intervalo (11.37) é

$$L = \bar{X} + z(\gamma) \sigma_{\bar{X}} - (\bar{X} - z(\gamma) \sigma_{\bar{X}}) = \frac{2 z(\gamma)}{\sqrt{n}},$$

que é uma constante, independente de  $\bar{X}$ .

Se construirmos vários intervalos de confiança para o mesmo valor de  $n$ ,  $\sigma$  e  $\gamma$ , estes terão extremos aleatórios, mas todos terão a mesma amplitude  $L$ .

**Exemplo 11.14**

Vamos obter um intervalo de confiança para o parâmetro  $p$  de uma distribuição  $b(n, p)$ . Sabemos que se  $X =$  número de sucessos nas  $n$  provas, então  $X$  tem distribuição aproximadamente normal, com

$$E(X) = \mu = np \text{ e } V(X) = \sigma^2 = npq, \text{ com } q = 1 - p.$$

Logo,

$$Z = \frac{X - np}{\sqrt{npq}} \sim N(0, 1).$$

ou ainda,

$$Z = \frac{\frac{X}{n} - p}{\sqrt{\frac{pq}{n}}} = \frac{\sqrt{n}(\hat{p} - p)}{\sqrt{pq}} \sim N(0, 1) \quad (11.38)$$

Assim, se  $\gamma = 0,95$ , temos, consultando a Tabela III, que

$$P(-1,96 \leq Z \leq 1,96) = 0,95.$$

ou seja,

$$P\left(-1,96 \leq \frac{\sqrt{n}(\hat{p} - p)}{\sqrt{pq}} \leq 1,96\right) = 0,95.$$

Portanto, com probabilidade 0,95, temos que

$$-1,96 \times \frac{pq}{n} \leq \hat{p} - p \leq 1,96 \times \frac{pq}{n},$$

do que segue

$$\hat{p} - 1,96 \times \frac{pq}{n} \leq p \leq \hat{p} + 1,96 \times \frac{pq}{n},$$

Como não conhecemos  $p$ , podemos proceder de duas maneiras. Uma é usar o fato que

$$pq = p(1 - p) \leq \frac{1}{4}.$$

Isto é fácil de ver lembrando que a média geométrica é sempre menor que a média aritmética.

Seja  $p$  e  $q$  números não negativos tais que  $p + q = 1$ . Assim

$$MG = \sqrt{pq} \text{ ; } MA = \frac{p + q}{2} = \frac{1}{2}.$$

Como

$$MG \leq MA$$

temos:

$$\sqrt{pq} \leq \frac{1}{2}.$$

Elevando ao quadrado temos o resultado:

$$pq = p(1 - p) \leq \frac{1}{4}.$$

Assim,

$$\frac{pq}{n} \leq \frac{1}{4n}.$$

E o nosso intervalo fica:

$$\hat{p} - 1,96 \times \frac{1}{\sqrt{4n}} \leq p \leq \hat{p} + 1,96 \times \frac{1}{\sqrt{4n}},$$

Temos, então, que

$$\left] \hat{p} - 1,96 \times \frac{1}{\sqrt{4n}}, \hat{p} + 1,96 \times \frac{1}{\sqrt{4n}} \right[$$

é um intervalo de confiança para  $p$  com coeficiente de confiança de 95%.

Para um  $\gamma$  qualquer,  $0 < \gamma < 1$ , (11.39) fica

$$\left] \hat{p} - 1,96 \times \frac{z(\gamma)}{\sqrt{4n}}, \hat{p} + 1,96 \times \frac{z(\gamma)}{\sqrt{4n}} \right[ \quad (11.40)$$

em que  $z(\gamma)$  é definido como em (11.37).

**Exemplo 11.15** Numa pesquisa de mercado,  $n = 400$  pessoas foram entrevistadas sobre determinado produto, e 60% delas preferiram a marca A. Aqui,  $\hat{p} = 0,6$  e um intervalo de confiança para  $p$  com coeficiente de confiança  $\gamma = 0,95$  será

$$0,6 \pm 1,96 \frac{1}{\sqrt{1600}} = 0,6 \pm 0,049,$$

ou seja

$$C(p \ 0,95) = ]0,551 ; 0,649[.$$

O intervalo (11.40) é chamado conservador, pois se  $p$  não for igual a  $\frac{1}{2}$  e estiver próximo de zero ou de um, então ele fornece um intervalo desnecessariamente maior, porque substituímos  $pq$  pelo seu valor máximo,  $\frac{1}{4}$ .

Uma outra maneira de proceder é substituir  $pq$

por

$$\hat{p} \times \hat{q}, \text{ com } \hat{q} = 1 - \hat{p},$$

sendo  $\hat{p}$ , sendo o estimador de máxima verossimilhança de  $p$ , por exemplo.  
O intervalo obtido fica

$$(11.41)$$

com  $z(\gamma)$  definido como em (11.40).

Na realidade, pode-se demonstrar que

$$Z = \frac{(\hat{p} - p)}{\sqrt{\frac{\hat{p}\hat{q}}{n}}} \sim N(0, 1)$$

do que resulta a Fórmula (11.41).

**Exemplo 11.16** Suponha que em  $n = 400$  provas obtemos  $k = 80$  sucessos.

Vamos obter um intervalo de confiança para  $p$  com  $\gamma = 0,90$ . Como

$$\hat{p} = \frac{80}{400} = 0,2 \quad \text{e} \quad \hat{q} = 1 - \hat{p} = 0,8,$$

então (11.41) fica

$$0,2 \pm 1,645 \times \sqrt{\frac{0,2 \times 0,8}{400}} = 0,2 \pm 0,033$$

ou seja,

$$IC(p; 0,90) = ]0,167; 0,233[.$$

Usando (11.40) o intervalo conservador é

$$IC(p; 0,90) = ]0,167; 0,233[.$$

Observe que o primeiro intervalo tem amplitude menor que o segundo. Outra observação importante é que por (11.40) e um  $\gamma$  fixo, os intervalos que podemos obter para amostras diferentes (mas de mesmo tamanho  $n$ ) terão a mesma amplitude, dada por

$$L_1 = \frac{2z(\gamma)}{\sqrt{4n}} = \frac{z(\gamma)}{\sqrt{n}}.$$

Por outro lado, usando (11.41), a amplitude do intervalo será

$$L_2 = \frac{2z(\gamma) \sqrt{\hat{p}\hat{q}}}{\sqrt{n}}.$$

que é variável de amostra para amostra, pois  $\hat{p}$  (e, consequentemente,  $\hat{q}$ ) variará de amostra para amostra.

## Problemas

14. Calcule o intervalo de confiança para a média de uma  $N(\mu, \sigma^2)$  em cada um dos casos abaixo.

Média Amostral	Tamanho da Amostra	Desvio Padrão da População	Coefficiente d
170 cm	100	15 cm	95%
165 cm	184	30 cm	85%
180 cm	225	30	70%

15. De 50.000 válvulas fabricadas por uma companhia retira-se uma amostra de 400 válvulas, e obtém-se a vida média de 800 horas e o desvio padrão de 100 horas.

- (a) Qual o intervalo de confiança de 99% para a vida média da população?
- (b) Com que confiança é possível afirmar que a vida média é  $800 \pm 0,98$ ?
- (c) Que tamanho deve ter a amostra para que seja de 95% a confiança na estimativa  $800 \pm 7,84$  ?

(Que suposições você fez para responder às questões acima?)

16. Qual deve ser o tamanho de uma amostra cujo desvio padrão é 10 para que a diferença da média amostral para a média da população, em valor absoluto, seja menor que 1, com coeficiente de confiança igual a:

- (a) 95%      (b) 99%

17. Uma população tem desvio padrão igual a 10.

(a) Que tamanho deve ter uma amostra para que, com probabilidade 8%, o erro em estimar a média seja superior a uma unidade?

(b) Supondo-se colhida a amostra no caso anterior, qual o intervalo de confiança, se  $\bar{x} = 50$ ?

18. Uma amostra aleatória de 625 donas de casa revela que 70% delas preferem a marca A de detergente. Construir um intervalo de confiança para a  $p$  = proporção das donas de casa que preferem A com c.c.  $\gamma = 90\%$  .

19. Encontre os intervalos de confiança para  $p$  se  $\frac{k}{n} = 0,3$ , com c.c.  $\gamma = 0,95$ . Utilize os dois enfoques apontados na Seção 11.6, com  $n = 400$ .

20. Antes de uma eleição, um determinado partido está interessado em estimar a proporção  $p$  de eleitores favoráveis ao seu candidato. Uma amos-



tra piloto de tamanho 100 revelou que 60% dos eleitores eram favoráveis ao candidato em questão.

(a) Determine o tamanho da amostra necessário para que o erro cometido na estimação seja de, no máximo, 0,01 com probabilidade de 80%.

(b) Se na amostra final, com tamanho igual ao obtido em (a), observou-se que 55% dos eleitores eram favoráveis ao candidato em questão, construa um intervalo de confiança para a proporção  $p$ . Utilize  $\gamma = 0,95$ .

21. Suponha que estejamos interessados em estimar a proporção de consumidores de um certo produto. Se a amostra de tamanho 300 forneceu 100 indivíduos que consomem o dado produto, determine:

(a) o intervalo de confiança para  $p$ , com coeficiente de confiança de 95% (interprete o resultado);

(b) o tamanho da amostra para que o erro da estimativa não exceda a 0,02 unidades com probabilidade de 95% (interprete o resultado).

## 11.7 Erro Padrão de um Estimador

Vimos que, obtida a distribuição amostral de um estimador, podíamos calcular a sua variância. Se não pudermos obter a distribuição exata, usamos uma aproximação, se essa estiver disponível, como no caso de  $\bar{X}$ , e a variância do estimador será a variância dessa aproximação. Por exemplo, para a média amostral  $\bar{X}$ , obtida de uma amostra de tamanho  $n$ , temos que na qual  $\sigma^2$  é a variância da v.a.  $X$  definida sobre a população.

$$V(\bar{X}) = \frac{\sigma^2}{n},$$

À raiz quadrada dessa variância chamaremos de erro padrão de  $\bar{X}$  e o denotaremos por

$$EP(\bar{X}) = \frac{\sigma}{\sqrt{n}},$$

**Definição.** Se  $T$  for um estimador do parâmetro  $\theta$  chamaremos de erro padrão de  $T$  a quantidade

$$EP(T) = \sqrt{V(T)} \quad (11.43).$$

A variância de  $T$  dependerá dos parâmetros da distribuição de  $X$ , o mesmo acontecendo com o erro padrão. Por exemplo, em (11.42),  $EP(\bar{X})$  depende de  $\sigma$ , que em geral é desconhecida. Podemos, então, obter o erro padrão estimado de  $\bar{X}$ , dado por

$$ep(\bar{X}) = \frac{S}{\sqrt{n}}, \quad (11.44)$$

na qual  $S^2$  é a variância amostral. Genericamente, o erro padrão estimado de  $T$  é dado por

$$\widehat{EP}(T) = \sqrt{\widehat{Var}(T)}. \quad (11.45)$$

Muitas vezes, a quantidade (11.45) é chamada de erro amostral. Mas preferimos chamar de erro amostral à diferença

$$E = T - \theta.$$

**Exemplo 11.17** Para o Exemplo 11.15,  $\hat{p} = 0,6$ , e o erro padrão de será dado por

$$EP(\hat{p}) = \sqrt{\frac{p(1-p)}{n}} \quad (11.46).$$

Como não conhecemos  $p$  usamos no seu lugar o estimador  $\hat{p}$ , obtendo-se

$$\widehat{EP}(\hat{p}) = \sqrt{\frac{0,6 \times 0,4}{400}} = 0,025.$$

Observe que o intervalo de confiança (11.41) pode ser escrito

$$\hat{p} \pm z(\gamma) \times \left( \widehat{EP}(\hat{p}) \right),$$

ao passo que o intervalo para  $\mu$  dado por (11.37) pode ser escrito

$$\hat{X} \pm z(\gamma) \times \left( \widehat{EP}(\hat{X}) \right).$$

## 11.8 Inferência Bayesiana

O estabelecimento de uma ponte entre os valores observados na amostra e os modelos postulados para a população, objeto da inferência estatística, exige a adoção de princípios teóricos muito bem especificados. Neste livro, usaremos a chamada teoria frequentista (às vezes, também chamada de clássica). Seus fundamentos encontram-se em trabalhos de J. Neyman, E. Pearson, R. Fisher e outros.

Consideremos um exemplo para ilustrar esse enfoque. Suponha que tenhamos uma amostra observada  $(x_1, x_2, \dots, x_n)$  de uma população normal,  $N(\mu, \sigma^2)$ , e queremos fazer inferências sobre os valores de  $\mu$  e  $\sigma^2$ , baseados nas  $n$  observações.

Por meio de algum procedimento estudado neste capítulo, selecionamos estimadores  $\hat{\mu}(x)$  e  $\hat{\sigma}^2(x)$  que sejam funções do vetor de observações

$$\mathbf{x} = (x_1, x_2, \dots, x_n).$$

Considere dados hipotéticos  $x_1, x_2, \dots$  todas amostras de tamanho  $n$ , que poderiam ter sido gerados da população em questão. Obtemos, então, as distribuições amostrais de  $\mu(\mathbf{x})$  e  $\hat{\sigma}^2(\mathbf{x})$ , como na Seção 10.7. Podemos também obter intervalos de confiança para os parâmetros desconhecidos  $\mu$  e  $\sigma^2$ , bem como testar hipóteses sobre esses parâmetros, assunto a ser discutido no Capítulo 12.

Para construir intervalos de confiança e testar hipóteses será necessário conhecer a distribuição amostral dos estimadores. Como só temos um conjunto de dados e não dados hipotéticos, essas distribuições amostrais terão de ser obtidas de outra maneira, e não como no Exemplo 10.7. Usualmente isso é feito usando teoremas como o Teorema Limite Central, discutido na Seção 10.8, obtendo-se uma distribuição aproximada para os estimadores, que vale para tamanhos de amostras grandes.

A crítica que se faz à teoria frequentista é a possibilidade de “replicar dados”, bem como o recurso à teoria assintótica. Uma teoria que não faz uso de tais argumentos é a inferência bayesiana, cujos fundamentos foram estabelecidos por T. Bayes em 1763. Outros expoentes dessa corrente foram Bernoulli (1713), Laplace (1812) e Jeffreys (1939). Aqui, o Teorema de Bayes, estudado no Capítulo 5, tem papel fundamental. A noção de probabilidade prevalente aqui é a subjetiva, discutida brevemente no mesmo capítulo.

Com relação ao nosso exemplo, a Inferência Bayesiana admite que os parâmetros

$\mu$  e  $\sigma^2$ , que são quantidades desconhecidas da distribuição de  $X$ , podem ser descritos por uma distribuição de probabilidades,  $p(\mu, \sigma^2)$ , chamada a distribuição a priori desses parâmetros. Nessa distribuição, são incorporadas todas as informações que temos sobre  $\theta = (\mu, \sigma^2)$ , inclusive de natureza subjetiva. Essa distribuição é hipotetizada antes de se colherem os dados.

O que é importante observar é que, tanto na teoria frequentista como na bayesiana, um parâmetro qualquer, como  $\mu$ , no exemplo acima, é considerado fixo. O que se faz no enfoque bayesiano é caracterizar a incerteza sobre esse parâmetro por meio de uma distribuição de probabilidades.

Após obtidos os dados, obtemos a função de verossimilhança, que incorpora a informação sobre  $\theta$  fornecida pelos dados. Finalmente, obtemos a distribuição a posteriori de  $\theta$ , dada a amostra observada. Um estimador de  $\theta$  pode ser tomado, por exemplo, como a média ou a moda dessa distribuição a posteriori.

Vimos no Capítulo 5 que o teorema de Bayes pode ser usado para atualizar probabilidades de um evento. Mas o teorema também pode ser utilizado para obter informação sobre um parâmetro desconhecido de um modelo probabilístico, como o binomial ou normal, por exemplo. Chamemos de  $\theta$  um tal parâmetro, suposto desconhecido, e para o qual tenhamos alguma informação anterior, consubstanciada numa distribuição de probabilidades  $p(\theta)$ , chamada distribuição a priori de  $\theta$ . Vamos supor, por ser mais simples, que  $\theta$  tenha os valores  $\theta_1, \theta_2, \dots, \theta_r$ , com probabilidades a priori

$$P(\Theta = \theta_i) = p(\theta_i), \quad i = 1, 2, \dots, r.$$

Chamemos de  $y$  a nova informação sobre  $\theta$ , que também é obtida de um modelo discreto. Então o Teorema de Bayes pode ser escrito

$$P(\theta_i|y) = \frac{p(\theta_i) \times P(y|\theta_i)}{\sum_{j=1}^r p(\theta_j) \times P(y|\theta_j)}, \quad i = 1, 2, \dots, r \quad (11.47)$$

Aqui, as verossimilhanças são  $P(y|\theta_1), \dots, P(y|\theta_r)$ , e as probabilidades a posteriori determinadas pelo teorema de Bayes são

$$P(\theta_1|y), \dots, P(\theta_r|y).$$

Obtida essa distribuição a posteriori de  $\theta$ , dada a nova informação  $y$ , podemos por exemplo estimar  $\theta$  como a média dessa distribuição ou a moda (o valor que maximiza  $P(\theta|y)$ ).

**Exemplo 11.18**

Vamos considerar uma aplicação do Teorema de Bayes a um exemplo simples de mercado de ações. Chamemos de  $y$  o rendimento do IBOVESPA (Índice da Bolsa de Valores de São Paulo), em porcentagem, por período (mês, por exemplo). Suponha que estejamos interessados somente se o rendimento for positivo ( $y > 0$ ) ou negativo ( $y < 0$ ). Designando por  $\theta$  o “estado do mercado”, vamos considerar apenas dois estados, mercado em alta ( $\theta_1$ ) ou mercado em baixa ( $\theta_2$ ). Suponha que se tenha a seguinte informação prévia (ou a priori) sobre as probabilidades de  $\theta_1$  e  $\theta_2$ :

priori	$\theta_1$	$\theta_2$
$p(\theta)$	$\frac{3}{5}$	$\frac{2}{5}$

Então, as probabilidades a priori dos estados são

$$p(\theta_1) = P(\Theta = \theta_1) = \frac{3}{5} \quad e \quad p(\theta_2) = P(\Theta = \theta_2) = \frac{2}{5}.$$

As verossimilhanças são dadas aqui por

$$P(y > 0 | \theta) \quad e \quad P(y < 0 | \theta),$$

para  $\theta = \theta_1, \theta_2$ , que denotaremos genericamente por  $p(y|\theta)$ . Essas verossimilhanças são supostas conhecidas no Teorema de Bayes e vamos supor que em nosso caso são dadas na tabela abaixo.

$y \backslash \Theta$	$\theta_1$	$\theta_2$
$y > 0$	$2/3$	$1/3$
$y < 0$	$1/3$	$2/3$

Ou seja, temos que

$$P(y < 0 | \theta_1) = \frac{1}{3}, \quad e \quad P(y > 0 | \theta_2) = \frac{2}{3}.$$

Assim cada coluna é uma distribuição de probabilidade.

Podemos calcular as probabilidades conjuntas  $p(y, \theta)$ , ou seja,

$$p(y, \theta) = p(\theta)p(y|\theta),$$

obtendo-se a tabela abaixo.

$y \backslash \Theta$	$\theta_1$	$\theta_2$	$p(y)$
$y > 0$	$6/15$	$2/15$	$8/15$
$y < 0$	$3/15$	$4/15$	$7/15$
$p(\theta)$	<b><math>9/15</math></b>	<b><math>6/15</math></b>	<b>1</b>

Por exemplo,

$$P(y > 0, \Theta = \theta_1) = P(\Theta = \theta_1) \times P(y > 0 | \Theta = \theta_1) = \frac{3}{5} \times \frac{2}{3} = \frac{6}{15}.$$

O Teorema de Bayes, dado pela Fórmula (11.47), fornece as probabilidades a posteriori de  $\theta_1$  e  $\theta_2$ , dado o valor observado de  $y$ :

$$p(\theta | y) = \frac{p(\theta) \times p(y | \theta)}{p(y)}. \quad (11.48)$$

Para calcular (11.48) precisamos calcular  $p(y)$ , que são chamadas probabilidades marginais preditoras ou simplesmente previsões. Usando o mesmo argumento que deu origem a (5.14), podemos escrever

$$p(y) = \sum_{\theta} p(y, \theta) = \sum_{\theta} p(\theta) \times p(y | \theta).$$

Em nosso caso,

$$P(y > 0) = P(\theta_1) \times P(y > 0 | \theta_1) + P(\theta_2) \times P(y > 0 | \theta_2),$$

$$P(y > 0) = \frac{3}{5} \times \frac{2}{3} + \frac{2}{5} \times \frac{1}{3} = \frac{8}{15}.$$

Do mesmo modo,

$$P(y < 0) = P(\theta_1) \times P(y < 0 | \theta_1) + P(\theta_2) \times P(y < 0 | \theta_2),$$

$$P(y < 0) = \frac{3}{5} \times \frac{1}{3} + \frac{2}{5} \times \frac{2}{3} = \frac{7}{15}.$$

e teremos a tabela a seguir:

$y$	$p(y)$
$y > 0$	$\frac{8}{15}$
$y < 0$	$\frac{7}{15}$

Vemos que essa é a mesma distribuição marginal de  $y$ , dada na tabela que mostra a distribuição conjunta de  $y$  e  $\theta$ .

Então, por (11.48),

$$P(\Theta = \theta_1 | y > 0) = \frac{P(\theta_1) \times p(y > 0 | \theta_1)}{P(y > 0)} = \frac{\frac{3}{5} \times \frac{2}{3}}{\frac{8}{15}} = \frac{3}{4}.$$

$$P(\Theta = \theta_2 | y > 0) = \frac{P(\theta_2) \times p(y > 0 | \theta_2)}{P(y > 0)} = \frac{\frac{2}{5} \times \frac{1}{3}}{\frac{8}{15}} = \frac{1}{4}.$$

De modo análogo, obtemos

$$P(\Theta = \theta_1 | y < 0) = \frac{3}{7}, \quad P(\Theta = \theta_2 | y < 0) = \frac{4}{7}.$$

Temos, então, as probabilidades condicionais de alta e baixa, dada a informação de que o retorno é positivo ou negativo:

y \ Θ	$\theta_1$	$\theta_2$
	$\theta_1$	$\theta_2$
$y > 0$	3/4	1/4
$y < 0$	3/7	4/7

Cada linha é uma distribuição de probabilidade.

Podemos, por exemplo, “estimar”  $\theta$  (alta ou baixa) por  $\theta_1$  (mercado em alta) se  $y > 0$ , já que

$$P(\Theta = \theta_1 | y > 0) = \frac{3}{4},$$

e “estimar”  $\theta$  por  $\theta_2$  (mercado em baixa) se  $y < 0$ , pois

$$P(\Theta = \theta_2 | y < 0) = \frac{4}{7}.$$

Ou seja, tomamos o valor máximo da probabilidade a posteriori, dada a informação sobre o rendimento. Esse é um exemplo do que se chama de modelo estático. Poderíamos considerar um modelo dinâmico, supondo-se que esse muda de período para período (de dia para dia ou de mês para mês etc.).

## 11.9 Exemplos Computacionais-11.9.1 Simulando Erros Padrões

Na Seção 11.7, definimos o que seja o erro padrão de um estimador  $T$  de um parâmetro  $\theta$ , baseado numa AAS de uma população rotulada pela v.a.  $X$ . Vimos, em particular, que o erro padrão da média amostral  $\bar{X}$  é dado por (11.42) e esse pode ser estimado por (11.44)

ou seja,

$$\widehat{EP} = \frac{S}{\sqrt{n}}.$$

O erro padrão de um estimador é fundamental para avaliarmos quão bom ele é. Simplesmente calcular  $T$ , ou saber que ele é não viesado, não é suficiente: é necessário calcular sua variabilidade.

Mas, na maioria das situações, não podemos obter uma estimativa do erro padrão de um estimador. Considere, por exemplo, a mediana de uma amostra,

$$md = med(X_1, \dots, X_n). \quad (11.49)$$

Pode não ser fácil calcular a  $Var(md)$ , e, conseqüentemente, o erro padrão de  $md$ . Se admitirmos que a aproximação (11.18) é razoável, então teremos

$$EP(md) = \sigma \sqrt{\frac{\pi}{2n}}.$$

e poderemos, novamente, estimar  $\sigma$  por  $S$  e obter

$$\widehat{EP}(md) = S \sqrt{\frac{\pi}{2n}}.$$

Mas, se tivermos amostras não muito grandes, a aproximação pode não ser adequada.

Felizmente, com o progresso de métodos computacionais usando intensivamente computadores cada vez mais rápidos e com capacidade cada vez maior



de lidar com conjuntos grandes de dados, o cálculo de erros padrões, vieses etc., pode ser feito sem recorrer a uma teoria, que muitas vezes pode ser muito complicada ou simplesmente não existir. Um desses métodos é chamado bootstrap, introduzido por B. Efrom, em 1979. Os livros de Efrom e Tibshirani (1993) e Davison e Hinkley (1997) são referências importantes para aqueles que quiserem se aprofundar no assunto.

A ideia básica do método bootstrap é reamostrar o conjunto disponível de dados para estimar o parâmetro  $\theta$ , com o fim de criar dados replicados. A partir dessas replicações, podemos avaliar a variabilidade de um estimador proposto para  $\theta$ , sem recorrer a cálculos analíticos.

Vamos ilustrar o método com um exemplo.

**Exemplo 11.19** Suponha que temos os dados amostrais  $x = (x_1, x_2, \dots, x_n)$  e queremos estimar a mediana populacional,  $Md$ , por meio da mediana amostral  $md(x) = (x_1, x_2, \dots, x_n)$ .

Vamos escolher uma AAS (portanto, com reposição) de tamanho  $n$  dos dados. Tal amostra é chamada uma amostra bootstrap e denotada por  $x^* = (x^*_1, \dots, x^*_n)$ .

Por exemplo, suponha que  $x = (x_1, x_2, x_3, x_4, x_5)$ . Poderemos obter, por exemplo,  $x^* = (x_4, x_3, x_3, x_1, x_2)$ .

Suponha, agora, que geremos  $B$  tais amostras independentes, denotadas  $x_1, \dots, x^*_B$ .

Para cada amostra bootstrap, geramos uma réplica bootstrap do estimador proposto, ou seja, de  $md(x)$ , obtendo-se

$$md(x^*_1), md(x^*_2), \dots, md(x^*_B). \quad (11.50)$$

Definimos o estimador bootstrap do erro padrão de  $md(x)$  como

$$\widehat{EP}_B(md) = \left[ \frac{\sum_{b=1}^B (md(x^*_b) - \bar{md})^2}{B-1} \right]^{1/2}. \quad (11.51)$$

com

$$\bar{md} = \frac{\sum_{b=1}^B md(x^*_b)}{B}. \quad (11.52)$$

Ou seja, o estimador bootstrap do erro padrão da mediana amostral é o desvio padrão amostral do conjunto (11.50).

Figura 11.5 Procedimento bootstrap para calcular o erro padrão da mediana amostral.




Figura 5:

Na Figura 11.5, temos representado o esquema do método. Vamos ilustrar o método com um exemplo numérico simples. Suponha que  $n = 5$  e a amostra é  $x = (2, 5, 3, 4, 6)$ .

Vamos considerar  $B = 5$  amostras bootstrap de  $x$ . Como gerar tais amostras?

Primeiramente, geramos cinco números aleatórios  $i_1, i_2, i_3, i_4, i_5$  dentre os cinco números inteiros

$$1, 2, 3, 4, 5$$

e consideramos a amostra bootstrap

$$x^* = (x_{i_1}, x_{i_2}, x_{i_3}, x_{i_4}, x_{i_5}).$$

Repetimos esse procedimento cinco vezes.

Podemos usar a Tabela VII para gerar esses NA, como já aprendemos. Considere, por exemplo, as cinco primeiras linhas e, começando do canto esquerdo, prossiga em cada linha até obter cinco dígitos entre 1 e 5, inclusive; note que pode haver repetições! Obtemos a Tabela 11.2.

Tabela 11.2 Procedimento bootstrap.

NA	Amostra bootstrap	$md(x^*)$	$bar(x)(x^*)$
1,2,2,5,1	(2,5,5,6,2)	5,0	4,0
4,4,4,3,2	(4,4,4,3,5)	4,0	4,0
5,4,5,5,5	(6,4,6,6,6)	6,0	5,6
5,1,1,5,5	(6,2,2,6,6)	6,0	4,4
2,5,4,5,3	(5,6,4,6,3)	5,0	4,8

Por exemplo, obtidos os NA 1, 2, 2, 5, 1, teremos a amostra bootstrap

$$(x_1, x_2, x_3, x_4, x_5) = (2, 5, 5, 6, 2),$$

Ordenando amostra bootstrap

$$(2, 2, 5, 5, 6)$$

para a qual a mediana amostral é 5.

A soma das 5 medianas obtidas foi 26. A mediana média vale:

$$\bar{md} = \frac{26}{5} = 5,2.$$

$$\widehat{EP}_B(md) = \left[ \frac{\sum_{b=1}^5 (md(x^*_b) - 5,2)^2}{4} \right]^{1/2} = 0,837.$$

Se usarmos a aproximação (11.18), calculamos a variância da amostra original, obtendo-se  $s^2 = 2,5$ , donde Levando-se em conta o tamanho da amostra, a discrepância entre os dois valores não é grande.

Veja a página do livro para aprender como usar o R para obter amostra bootstrap e calcular o erro padrão correspondente.

**Exemplo 11.20** Na Tabela 11.2, calculamos, também, para cada amostra bootstrap, a média amostral,  $\bar{x}$ . Obtemos, usando (11.51),

$$\widehat{EP}_B(\bar{x}) = 0,669,$$

e usando a fórmula (11.44),

$$\widehat{EP}(\bar{x}) = 0,707,$$

logo o valor obtido pelo método bootstrap está bastante próximo do valor calculado pela fórmula obtida de maneira analítica. Obviamente, em situações nas quais há uma fórmula disponível, não há necessidade de se usar bootstrap.

A questão que se apresenta é: qual deve ser o valor de  $B$ , ou seja, quantas amostras bootstrap devemos gerar para estimar erros padrões de estimadores? A experiência indica que um valor razoável é  $B = 200$ .

No caso geral de um estimador  $\hat{\theta} = T(x)$ , o algoritmo bootstrap para estimar o erro padrão de  $\hat{\theta}$  é o seguinte:

[1] Selecione  $B$  amostras bootstrap independentes  $x_1, \dots, x_B^*$ , cada uma consistindo de  $n$  valores selecionados com reposição de  $x$ . Tome  $B \geq 200$ .

[2] Para cada amostra bootstrap  $x_B^*$  calcule a réplica bootstrap

$$\hat{\theta}^*(b) = T(x_b^*), \quad b = 1, 2, \dots, B.$$

[3] O erro padrão de  $\hat{\theta}$  é estimado pelo desvio padrão das  $B$  réplicas:

$$\widehat{EP}_B = \left[ \frac{1}{B-1} \sum_{b=1}^B \left( \hat{\theta}^*(b) - \bar{\theta}^* \right)^2 \right]^{1/2}, \quad (11.53)$$

com

$$\bar{\theta}^* = \frac{\sum_{b=1}^B \hat{\theta}^*(b)}{B} \quad (11.54).$$

No exemplo acima, notamos que um intervalo de confiança aproximado para a mediana populacional  $Md$ , com coeficiente de confiança 95%, seria

$$5,2 \pm (1,95)(0,837) = ]3,56 ; 6,84[.$$

No exemplo dado, para efeito de ilustração do método bootstrap, tomamos uma amostra pequena ( $n = 5$ ) e poucas amostras bootstrap ( $B = 5$ ). Para amostras maiores e  $B$  na ordem de 200 deveremos fazer um pequeno programa, em alguma linguagem (como o Visual Basic, S, Fortran, C etc.), que gere as amostras bootstrap, e calcular o estimador dado por (11.53). Isso implica, em particular, gerar, para cada amostra bootstrap,  $n$  números aleatórios. Como já vimos, não é prático usar uma tabela de NA nessa situação; devemos usar alguma rotina de computador.

## 11.10 Problemas Suplementares

22. Um pesquisador está em dúvida sobre duas possíveis estatísticas,  $t$  e  $t'$ , para serem usadas como estimadores de um parâmetro  $\theta$ . Assim, ele decidiu usar simulação para uma situação hipotética, procurando encontrar pistas que o ajudassem a decidir qual o melhor estimador. Partindo de uma população fictícia, onde  $\theta = 10$ , ele retirou 1.000 amostras de 20 elementos, e para cada amostra calculou o valor das estatísticas  $t$  e  $t'$ . Em seguida, construiu a distribuição de frequências, segundo o quadro abaixo.

Classess	% de $t$	% de $t'$
5 $\vdash$ 7	10	5
7 $\vdash$ 9	20	30
9 $\vdash$ 11	40	35
11 $\vdash$ 13	20	25
13 $\vdash$ 15	10	5

(a) Verifique as propriedades de  $t$  e  $t'$  como estimadores de  $\theta$ .

(b) Qual dos dois você adotaria? Por quê?

23. De experiências passadas, sabe-se que o desvio padrão da altura de crianças de quinta série do primeiro grau é 5 cm.

(a) Colhendo uma amostra de 36 dessas crianças, observou-se a média de 150 cm. Qual o intervalo de confiança de 95% para a média populacional?

(b) Que tamanho deve ter uma amostra para que o intervalo  $150 \pm 0,98$  tenha 95% de confiança?

24. Um pesquisador está estudando a resistência de um determinado material sob determinadas condições. Ele sabe que essa variável é normalmente distribuída com desvio padrão de duas unidades.

(a) Utilizando os valores 4,9; 7,0; 8,1; 4,5; 5,6; 6,8; 7,2; 5,7; 6,2 unidades, obtidos de uma amostra de tamanho 9, determine o intervalo de confiança para a resistência média com um coeficiente de confiança  $\gamma = 0,90$ .

(b) Qual o tamanho da amostra necessário para que o erro cometido, ao estimarmos a resistência média, não seja superior a 0,01 unidade com probabilidade 0,90?

(c) Suponha que no item (a) não fosse conhecido o desvio padrão. Como

você procederia para determinar o intervalo de confiança, e que suposições você faria para isso? Veja também o Problema 44.

25. Estime o salário médio dos empregados de uma indústria têxtil, sabendo-se que uma amostra de 100 indivíduos apresentou os seguintes resultados:

Salário	Frequência
150,00– 250,00	8
250,00– 350,00	22
350,00 – 450,00	38
450,00– 550,00	28
550,00 – 650,00	2
650,00 – 750,00	2

Use  $\gamma = 0,95$ .

26. Suponha que as vendas de um produto satisfaçam ao modelo

$$V_t = \alpha + \beta t + a_t,$$

em que  $a_t$  é a variável aleatória satisfazendo as suposições da Seção 11.4, e o tempo é dado em meses. Suponha que os valores das vendas nos 10 primeiros meses do ano 1 sejam dados pelos valores da tabela abaixo. Obtenha as previsões para os meses de novembro e dezembro do ano 1 e para julho e agosto do ano 2.

$t$	1	2	3	4	5	6	7	8	9	10
$y_t$	5,0	6,7	6,0	8,7	6,2	8,6	11,0	11,9	10,6	10,8

27. Numa pesquisa de mercado para estudar a preferência da população de uma cidade em relação a um determinado produto, colheu-se uma amostra aleatória de 300 indivíduos, dos quais 180 preferiam esse produto.

(a) Determine um intervalo de confiança para a proporção da população que prefere o produto em estudo; tome  $\gamma = 0,90$ .

(b) Determine a probabilidade de que a estimativa pontual dessa proporção não difira do verdadeiro valor em mais de 0,001.

(c) É possível obter uma estimativa pontual dessa proporção que não difira do valor verdadeiro em mais de 0,0005 com probabilidade 0,95? Caso contrário, determine o que deve ser feito.

28. Uma amostra de 10.000 itens de um lote de produção foi inspecionada, e o número de defeitos por item foi registrado na tabela abaixo.

Número de defeitos	0	1	2	3	4
Quantidade de peças	6.000	3.200	600	150	50

(a) Determine os limites de confiança para a proporção de itens defeituosos na população, com coeficiente de confiança de 98%. Use (11.40).

(b) Mesmo problema, usando (11.41).

29. Antes de uma eleição em que existiam dois candidatos, A e B, foi feita uma pesquisa com 400 eleitores escolhidos ao acaso, e verificou-se que 208 deles pretendiam votar no candidato A. Construa um intervalo de confiança, com  $c.c.\gamma = 0,95$ , para a porcentagem de eleitores favoráveis ao candidato A na época das eleições.

30. Encontre o  $c.c.$  de um intervalo de confiança para  $p$ , se  $n = 100$ ,  $\hat{p} = 0,6$  e a amplitude do intervalo deve ser igual a 0,090.

31. Usando os resultados do Problema 32 do Capítulo 10, mostre que o intervalo de confiança para a diferença das médias populacionais, com variâncias conhecidas, é dado por

$$IC(\mu_1 - \mu_2 : \gamma) = (\bar{X} - \bar{Y}) \pm z(\gamma) \times \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}.$$

32. Estão sendo estudados dois processos para conservar alimentos, cuja principal variável de interesse é o tempo de duração destes. No processo A, o tempo  $X$  de duração segue a distribuição  $N(\mu_A, 100)$ , e no processo B o tempo  $Y$  obedece à distribuição  $N(\mu_B, 100)$ . Sorteiam-se duas amostras independentes: a de A, com 16 latas, apresentou tempo médio de duração igual a 50, e a de B, com 25 latas, duração média igual a 60.

(a) Construa um IC para  $\mu_A$  e  $\mu_B$ , separadamente.

(b) Para verificar se os dois processos podem ter o mesmo desempenho, decidiu-se construir um IC para a diferença  $\mu_A - \mu_B$ . Caso o zero pertença ao intervalo, pode-se concluir que existe evidência de igualdade dos processos. Qual seria sua resposta?

33. Usando (11.55), prove que  $\bar{X}$  é um estimador consistente para a média  $\mu$  de uma população com variância  $\sigma^2$ .

34. Prove (11.56), usando (11.55).

35. Usando (11.57), resolva este problema: suponha que a proporção de fumantes de uma população é  $p$ , desconhecida. Queremos determinar  $p$  com um erro de, no máximo, 0,05. Qual deve ser o tamanho da amostra  $n$ , a ser escolhida com reposição, se  $\gamma = 0,95$  ?

36. Se a distribuição de  $X$  depende de mais de um parâmetro, digamos  $\theta_1$  e  $\theta_2$ , então

$$L(\theta_1, \theta_2; X_1, \dots, X_n),$$

, para maximizar  $L$  basta derivar  $L$  em relação a  $\theta_1$  e  $\theta_2$  (em algumas situações, derivar  $L$  não conduz ao EMV; veja o Problema 43). Considere, então,

$$X \sim N(\mu, \sigma^2).$$

Determine os EMV de  $\theta_1 = \mu$  e  $\theta_2 = \sigma^2$ , considerando

$$\frac{\partial l}{\partial \mu} = 0 \text{ e } \frac{\partial l}{\partial \sigma^2} = 0, \text{ em que } l = \log L.$$

37. Suponha que  $X \sim N(\mu, \sigma^2)$ ,  $\mu$  e  $\sigma^2$  desconhecidos. Uma amostra de tamanho  $n = 600$  forneceu  $\bar{X} = 10,3$  e  $S^2 = 1,96$ . Supondo que a v.a. seja aproximadamente normal, obtenha um IC para  $\mu$ , com c.c.  $\gamma = 0,95$  (se  $n$  for pequeno,  $Z$  não é aproximadamente normal; ver Capítulo 12).

38. Para estimar a média  $\mu$  desconhecida de uma população, foram propostos dois estimadores não viesados independentes,  $\hat{\mu}_1$  e  $\hat{\mu}_2$  de tal sorte que

$$\text{Var}(\hat{\mu}_1) = \frac{\text{Var}(\hat{\mu}_2)}{3}.$$

Considere os seguintes estimadores ponderados de  $\mu$ :

(a)  $T_1 = \frac{\hat{\mu}_1 + \hat{\mu}_2}{2};$

(b)  $T_2 = \frac{4\hat{\mu}_1 + \hat{\mu}_2}{5};$

(c)  $T_3 = \hat{\mu}_1.$

.

(i) Quais estimadores são não viesados?

(ii) Dispor esses estimadores em ordem crescente de eficiência.

39. Obtenha o estimador de  $\lambda$  na Poisson, pelo método dos momentos.

40. Considere o CD-Notas e retire uma amostra com reposição de tamanho  $n = 10$ . Determine o erro padrão estimado pelo método bootstrap das estatísticas (use  $B = 15$ , por exemplo):

(a) md = mediana da amostra; (b) dm = desvio médio da amostra;

(c) dam = desvio absoluto mediano.

41. Prove (11.15).



42. Calcule o EQM (erro quadrático médio), dado por (11.20), para os estimadores  $S^2$  e  $\hat{\sigma}^2$ , no caso de população normal.

Compare esses dois EQM. Qual estimador você escolheria, se o critério de escolha é ter o menor EQM?

43. Considere a v.a. discreta  $X$  com função de probabilidade dada por:

$$p(x; \theta) = P(X = x; \theta) = \frac{1}{\theta} I_A(x), \quad A = \{1, 2, \dots, \theta\},$$

em que  $\theta > 0$  é um número inteiro desconhecido.

Uma AAS  $X_1, X_2, \dots, X_n$  de tamanho  $n$  é selecionada e considera-se o seguinte estimador de  $\theta$ :

$$T = 2\bar{X} - 1, \quad \text{em que } \bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

(a) Mostre que  $T$  é um estimador não viesado de  $\theta$  e obtenha sua variância.  $T$  é um estimador consistente de  $\theta$ ? Por quê?

(b) Se  $n = 6$  e a amostra observada for  $x_1 = x_2 = x_3 = x_4 = x_5 = 1$  e  $x_6 = 2$ , qual é a estimativa de  $\theta$ ? Esta estimativa é um valor plausível para  $\theta$ ?

Sugira outro estimador para  $\theta$  que somente conduza a valores plausíveis de  $\theta$ .

Observação:

Para  $k$  inteiro positivo temos:

$$\sum_{i=1}^k i = \frac{k(k+1)}{2}, \quad \sum_{i=1}^k i^2 = \frac{k(k+1)(2k+1)}{6}.$$

## 11.11 Complementos Metodológicos

1. Desigualdade de Chebyshev. Seja  $X$  uma v.a. com  $E(X) = \mu$  e  $Var(X) = \sigma^2$ , finita. Então, para todo  $k > 0$ , a seguinte desigualdade é válida:

$$P\left(|X - \mu| \geq k\right) \leq \frac{Var(X)}{k^2} \quad (11.55)$$

Esta desigualdade é importante em muitas aplicações e, em particular, para provar o resultado (11.56) a seguir.

2. Lei dos Grandes Número. Consideremos  $n$  provas de Bernoulli com  $p = P$  (sucesso), e seja  $k$  o número de sucessos nas  $n$  provas. A Lei dos Grandes Números (LGN) afirma que, para  $n$  grande, a proporção de sucessos  $\frac{k}{n}$  estará próxima de  $p = P$  (sucesso). Formalmente, para todo  $\epsilon > 0$ ,

$$P\left(\left|\frac{k}{n} - p\right| \geq \epsilon\right) \leq \frac{p(1-p)}{n \epsilon^2}. \quad (11.56)$$

Prove (11.56), usando (11.55).

3. A LGN pode ser usada de maneira útil na seguinte situação. Suponha que queiramos saber quantas repetições de um experimento de Bernoulli devemos realizar a fim de que  $\frac{k}{n}$  difira de  $p$  de menos de  $\epsilon$  e, com probabilidade maior ou igual a  $\gamma$ . Ou seja, queremos determinar  $n$ , tal que

$$P\left(\left|\frac{k}{n} - p\right| \geq \epsilon\right) \geq \gamma.$$

De (11.56), temos

$$P\left(\left|\frac{k}{n} - p\right| < \epsilon\right) \geq 1 - \frac{p(1-p)}{n \epsilon^2}$$

logo, comparando, temos que  $n$  deve satisfazer

$$1 - \frac{p(1-p)}{n \epsilon^2} = \gamma,$$

do que segue

$$n = \frac{p(1-p)}{\delta \epsilon^2}, \text{ em que } \delta = 1 - \gamma.$$

Como não conhecemos  $p$ , usando o fato de  $p(1-p)p < 1/4$ ; logo basta tomar  $n$  tal que

$$n = \frac{1}{4 \delta \epsilon^2} \quad (11.57)$$

4. Estimação numa distribuição uniforme. Suponha que  $X$  tenha uma distribuição uniforme no intervalo  $(0, \theta)$ , onde  $\theta$  é desconhecido. Uma amostra de  $n$  observações  $X_1, \dots, X_n$  é escolhida. Sabemos que

$$E(X) = E(X_i) = \frac{\theta}{2}, \text{ e } Var(X) = Var(X_i) = \frac{\theta^2}{12}, \text{ para todo } i.$$

Logo, se calcularmos a média amostral  $\bar{X}$ , essa deve estar próxima de  $\frac{\theta}{2}$  e podemos estimar  $\theta$  por

$$T_1 = 2\bar{X},$$

que é o estimador pelo método dos momentos de  $\theta$ .

- (a) Calcule  $E(T_1)$ .
- (b) Calcule  $EQM(T_1) = E(T_1 - \theta)^2$ .
- (c)  $T_1$  é consistente? Por quê?

5. Continuação de 4. Outra maneira de estimar  $\theta$  na uniforme é a seguinte. Considere

$$M = \max(X_1, X_2, \dots, X_n) = Y_n$$

, ou seja, o maior valor da amostra.

Para qualquer valor de  $\theta$ ,  $M < \theta$  e  $M$  se aproxima de  $\theta$  quando  $n$  aumenta. Tome  $M$  como estimador de  $\theta$ , o que é bastante razoável. Na realidade, veremos, em 9, que

$$M = \hat{\theta}_{MV}.$$

Usando (10.10) a densidade de  $M$  é dada por

$$f_M(y) = \frac{ny^{n-1}}{\theta^n} I_A(y), \quad A = (0, \theta). \quad (11.58)$$

(a) Mostre que logo  $M$  é viesado. Calcule o viés  $V_M(\theta)$  de  $M$  e mostre que esse viés tende a zero, quando  $\rightarrow \infty$ ?

(b) Considere o estimador

$$T_2 = \frac{n+1}{n} M,$$

segue-se que é não viesado para  $\theta$ ?, ou seja,  $E(T_2) = \theta$ . Calcule o erro quadrático médio de  $T_2$ ,

$$EQM(T_2) = E(T_2 - \theta)^2$$

.

(c)  $T_2$  é consistente? Por quê?

6. Usando 4 e 5, mostre que

$$Var(T_2) = \frac{3}{n+2} Var(T_1).$$

Tome  $n = 1, 2, 10, 50, 100$  e verifique qual a relação entre as duas variâncias. Verifique que, para  $n$  grande,

$$T_2 = \frac{n+1}{n} M$$

é um estimador muito melhor do que  $T_1 = 2\bar{X}$ . Como

$$T_2 = (1 + \frac{1}{n})M,$$

vemos que, para  $n$  grande,  $T_2 \approx M$ . Portanto, para tamanhos de amostras grandes, o EMV é melhor do que  $2\bar{X}$  (EMM).

7. Suponha que  $n$  seja suficientemente grande para que o TLC se aplique e se possa aproximar a distribuição de  $\bar{X}$  e de  $M$  por uma distribuição normal.

(a) Mostre que a média e variância de  $T_1 = 2\bar{X}$ ,  $M$  e  $T_2$ .

$$E(T_1) = \theta \quad e \quad Var(T_1) = \frac{\theta^2}{3n}.$$

$$E(M) = \frac{n}{n+1} \theta \quad e \quad Var(M) = \frac{n \theta^2}{(n+2)(n+1)^2}.$$

$$E(T_2) = \theta \quad e \quad Var(T_2) = \frac{\theta^2}{n(n+2)}.$$

(b) Obtenha um I.C.  $(\theta; 0, 90)$  usando  $T_1$ .

(c) Idem usando  $M$ .

(d) Idem usando  $T_2$ .

[Sugestão: substitua na variância de cada estimador, obtida em (a), o parâmetro  $\theta$ , desconhecido, pelo seu estimador, para obter a respectiva variância estimada]

8. Foram gerados 1.000 valores de uma distribuição uniforme no intervalo  $(0, 5)$ , ou seja,  $\theta = 5$ .

As seguintes estatísticas foram obtidas:

$$x_{(1)} = y_1 = \min(x_1, x_2, \dots, x_{1000}) = 0,01132 \quad x_{(1000)} = y_{1000} = \max(x_1, x_2, \dots, x_{1000}) = 4,992$$

$$q_1 = 1,315, \quad q_2 = 2,572, \quad q_3 = 3,829, \quad \bar{x} = 2,547.$$

Calcule  $T_1$ ,  $T_2$  e aplique o resultado de 7 para obter um intervalo de confiança para  $\theta$ , com c.c. = 90%.

Vamos fazer no R:

```
>
> set.seed(32)
> AX=runif(1000,0,5)
> round(AX,3)
[1] 2.529 2.974 4.044 3.644 0.760 4.781 3.768 4.260 3.367 1.936 3.290 1.607
[13] 3.060 3.863 1.331 3.744 3.997 2.097 3.111 4.538 3.413 4.454 2.301 0.694
[25] 2.903 4.910 2.313 2.586 2.700 3.059 1.971 4.123 4.554 4.143 2.209 3.841
[37] 2.599 0.742 3.989 4.931 1.928 3.797 0.695 2.676 4.131 1.111 3.204 4.817
[49] 3.852 0.314 4.055 4.761 3.507 1.745 0.101 0.008 4.185 4.344 3.410 4.783
[61] 3.970 0.663 3.612 0.967 1.042 4.987 4.231 0.554 4.699 2.051 4.187 1.271
[73] 2.264 0.143 0.563 1.119 3.729 0.578 1.899 1.905 2.660 2.699 2.665 0.040
[85] 0.884 2.662 2.261 4.302 0.953 4.303 0.273 1.591 0.626 1.645 1.346 0.306
[97] 1.301 1.993 0.530 0.453 3.231 4.273 2.114 0.152 1.591 3.958 2.374 3.666
[109] 0.316 3.634 1.151 0.661 3.898 0.805 2.126 4.724 4.057 1.126 1.372 1.922
[121] 0.772 4.648 0.094 2.941 1.913 1.026 2.929 1.864 2.750 0.442 0.880 2.750
[133] 1.079 2.502 3.291 3.012 3.262 2.343 2.424 0.563 0.657 0.272 3.124 4.752
[145] 3.187 4.815 1.513 2.493 0.951 0.622 1.804 0.692 4.590 1.175 0.017 4.965
[157] 3.161 1.413 1.710 0.151 4.566 3.498 0.572 4.853 0.583 3.563 0.135 3.034
[169] 3.020 2.748 4.319 0.709 4.128 0.391 2.833 2.151 3.978 3.011 1.124 0.664
[181] 1.494 0.143 2.723 0.227 4.524 0.726 4.549 1.556 3.617 2.915 2.972 2.371
[193] 1.112 0.855 1.517 0.702 1.220 0.313 2.479 0.015 1.405 2.287 3.376 1.000
[205] 2.099 0.459 1.990 2.520 2.704 0.401 1.467 2.285 2.627 3.506 3.299 1.570
[217] 2.652 2.638 2.970 3.260 1.275 2.867 0.699 3.639 4.812 1.511 0.682 0.055
[229] 2.487 0.155 0.101 0.194 4.742 0.230 1.704 2.961 0.765 3.064 2.568 0.606
[241] 1.881 0.512 4.785 1.460 1.818 1.612 3.738 0.054 3.653 1.404 4.676 3.854
[253] 4.773 2.392 1.324 1.161 4.308 4.424 3.901 0.653 3.277 4.084 4.580 3.870
[265] 1.440 1.475 0.507 0.738 0.914 4.152 0.894 2.221 2.756 4.085 2.162 1.242
```

---

[277]	1.320	3.824	0.711	3.624	3.315	2.029	2.738	0.643	3.763	2.994	2.007	3.730
[289]	2.419	2.192	0.255	2.208	0.057	3.140	4.789	2.752	0.996	1.311	0.134	3.549
[301]	2.044	1.291	1.612	3.747	3.691	4.992	1.462	0.170	3.786	1.490	4.478	2.986
[313]	2.969	0.958	3.179	4.802	4.617	4.566	3.352	3.157	1.482	4.404	4.270	0.519
[325]	0.761	3.234	4.006	1.928	4.802	1.760	0.316	3.347	2.806	4.190	4.063	3.858
[337]	0.075	4.812	1.491	1.624	1.555	0.983	3.418	1.253	1.875	3.909	2.709	4.915
[349]	3.753	2.075	3.115	2.953	2.278	2.151	1.328	3.230	3.029	1.174	0.418	0.897
[361]	0.126	4.909	3.277	3.409	1.269	3.265	0.990	1.181	2.561	4.525	3.725	3.074
[373]	1.320	1.381	4.558	4.048	0.862	2.240	2.344	1.446	4.775	2.300	3.928	2.849
[385]	4.294	0.814	1.241	0.182	2.844	2.853	4.379	1.626	1.343	0.161	1.743	2.027
[397]	0.128	4.208	0.905	3.426	0.014	3.309	2.649	1.999	2.539	2.310	0.423	1.488
[409]	0.108	3.487	4.123	2.821	4.903	1.149	4.968	4.717	1.913	4.974	3.402	3.989
[421]	3.271	4.145	1.692	3.379	3.249	3.415	4.329	1.263	0.704	4.447	0.081	0.805
[433]	2.758	0.430	4.814	2.614	2.025	4.848	3.931	0.750	2.421	1.051	1.165	2.717
[445]	1.808	1.955	3.331	0.340	3.878	2.213	3.550	3.210	3.934	0.305	0.738	4.780
[457]	3.659	3.628	1.269	1.131	4.140	3.682	3.916	2.610	1.175	4.540	2.275	4.280
[469]	2.715	0.173	3.367	3.456	3.091	3.109	4.633	4.102	3.392	2.114	3.675	3.150
[481]	2.277	4.767	3.661	1.635	2.761	1.108	4.789	0.199	1.140	4.101	0.884	4.059
[493]	2.786	1.240	3.667	2.233	1.427	1.661	1.667	4.474	3.759	2.927	1.675	4.964
[505]	0.590	2.312	1.262	1.782	1.413	0.352	4.928	3.730	0.549	4.988	2.098	2.160
[517]	2.990	2.115	1.562	2.998	4.630	4.673	2.890	3.503	4.774	2.255	3.040	4.732
[529]	4.073	4.874	2.320	0.546	0.860	2.909	3.398	2.095	2.226	1.924	4.858	4.300
[541]	3.462	2.657	4.947	0.305	2.861	4.367	1.362	4.339	3.719	0.523	3.021	3.104
[553]	0.907	0.724	4.432	3.986	4.947	4.725	3.100	0.678	0.511	1.573	0.162	4.544
[565]	2.991	0.426	0.725	2.860	1.591	3.510	1.901	2.341	0.510	2.508	1.947	0.661
[577]	3.223	1.204	2.762	2.835	3.745	3.829	2.516	4.505	1.229	1.339	2.066	4.446
[589]	0.512	3.387	2.374	4.697	3.173	1.971	2.452	2.908	4.522	3.159	4.380	0.867
[601]	0.653	0.042	0.034	3.199	1.695	1.683	3.264	2.600	1.357	0.438	4.817	0.140
[613]	3.646	4.059	2.259	4.571	2.117	3.407	0.669	2.848	0.331	1.649	1.896	4.818
[625]	2.205	0.813	1.516	4.953	4.232	1.279	1.915	3.238	3.586	4.055	2.880	0.713
[637]	0.922	0.100	2.536	2.151	2.938	2.817	2.479	4.275	2.009	1.619	4.407	2.372
[649]	2.480	2.084	2.085	4.457	1.043	0.293	1.728	0.436	3.031	2.013	2.305	0.153
[661]	4.000	0.001	3.100	3.338	3.446	2.549	3.750	0.975	4.129	0.145	4.760	1.975
[673]	1.099	1.276	1.993	1.352	0.501	1.477	0.385	2.193	1.373	1.110	0.349	2.241
[685]	0.710	2.494	1.800	0.001	1.999	1.774	1.670	4.774	3.754	3.302	3.899	0.113
[697]	3.852	0.557	4.519	3.505	1.742	1.835	4.658	1.891	0.884	1.597	4.445	2.589
[709]	3.376	0.082	2.327	0.545	2.954	1.735	4.992	3.681	1.498	2.199	1.198	0.915
[721]	3.376	0.672	0.711	0.004	3.474	2.318	3.364	0.031	3.279	1.143	0.055	0.531
[733]	2.503	2.062	1.779	3.782	1.540	4.512	2.984	4.447	0.349	2.157	0.201	2.454
[745]	1.589	2.478	2.350	0.058	4.784	3.623	0.204	3.961	0.797	2.221	4.447	1.194
[757]	4.915	2.442	3.187	4.636	4.113	1.133	2.756	2.207	2.378	4.655	3.957	3.082
[769]	4.311	4.263	2.267	1.328	1.042	4.172	3.445	4.365	4.477	1.604	1.622	1.859
[781]	1.081	1.576	4.566	1.444	4.637	4.923	1.618	2.666	2.950	0.101	1.083	2.960
[793]	1.034	0.411	4.328	1.905	0.270	4.161	3.428	0.959	2.422	0.132	4.093	0.954
[805]	3.596	0.665	0.466	1.641	4.172	1.132	0.391	4.794	2.899	1.566	4.714	1.115
[817]	3.405	4.001	0.345	2.294	0.222	0.310	4.835	2.153	1.614	3.778	4.774	3.672
[829]	4.958	1.231	4.237	0.085	1.715	1.164	4.928	3.724	1.557	0.289	3.408	0.981
[841]	4.238	4.692	0.867	3.861	0.528	2.382	4.767	2.517	4.459	2.630	1.018	1.778

---

```

[853] 2.468 0.356 4.510 3.169 1.142 0.216 1.799 4.535 1.000 3.582 1.935 0.145
[865] 0.634 1.951 2.458 0.486 4.397 2.562 1.889 2.743 2.619 0.330 0.873 4.676
[877] 2.620 4.429 0.665 0.040 4.344 1.677 0.248 4.808 3.662 1.446 2.049 4.086
[889] 2.523 2.618 0.160 1.486 1.644 3.872 2.540 2.504 1.469 4.167 2.951 3.115
[901] 1.943 0.801 1.524 4.480 3.561 3.906 3.241 2.138 0.806 0.036 0.961 0.654
[913] 1.461 3.150 4.379 3.578 2.158 0.429 1.120 4.089 4.577 4.177 1.699 4.807
[925] 3.658 1.896 1.758 0.268 2.114 1.742 2.966 2.035 4.686 4.975 2.038 2.670
[937] 2.877 2.730 3.204 4.697 2.855 1.448 2.945 1.748 1.032 2.772 0.145 3.947
[949] 1.455 2.349 2.636 1.783 1.035 3.337 4.777 4.222 1.036 2.439 2.078 1.480
[961] 1.662 3.219 0.508 2.976 2.126 3.292 2.830 2.883 3.831 1.422 0.159 2.601
[973] 4.172 2.134 0.541 4.046 1.135 4.472 3.332 4.747 1.376 1.507 1.021 4.635
[985] 2.796 2.967 0.203 2.735 1.123 1.193 3.969 4.254 4.607 1.283 2.885 1.010
[997] 4.530 3.948 4.199 4.238
> min=min(AX);round(min,5)
[1] 0.00103
> max=max(AX);round(max,3)
[1] 4.992
> q_1=quantile(AX,0.25);round(q_1,3)
25%
1.216
> q_2=quantile(AX,0.50);round(q_2,3)
50%
2.423
> q_3=quantile(AX,0.75);round(q_3,3)
75%
3.681
>
> quartis=quantile(AX,c(0.25,0.50,0.75))
> round(quartis,3)
25% 50% 75%
1.216 2.423 3.681
> xb=mean(AX);round(xb,3)
[1] 2.452
>
> ###Vamos estimar sigma^2
> n=1000
> s2=var(AX);s2
[1] 2.099661
>
> ###A variância de  $T_1=2*X_b$  é  $V(T_1)=4*\sigma^2/n=teta^2/(3n)$ 
>
> t_1=2*xb;t_1
[1] 4.904906
> VT1_est=4*s2/n;VT1_est
[1] 0.008398646
> EPT1_est=sqrt(VT1_est);EPT1_est
[1] 0.09164413
>

```

```

>
>
> gama=0.90
> z_gama=qnorm(1-(1-gama)/2);z_gama
[1] 1.644854
>
>
> IC90teta=t_1+c(-1,1)*z_gama*EPT1_est
>
> round(IC90teta,3)
[1] 4.754 5.056
>
> ##T_1 sub estima teta!!!!!!
>
>
> t_2=((n+1)/n)*max;t_2
[1] 4.997014
>
>
> VT2_est= max^2/(n*(n+2));VT2_est
[1] 2.487054e-05
>
> EPT2_est=sqrt(VT2_est);EPT2_est
[1] 0.004987037
>
>
> IC90teta=t_2+c(-1,1)*z_gama*EPT2_est
>
> round(IC90teta,3)
[1] 4.989 5.005
>
> ##Note que teta=5 pertence ao intervalo de confiança obtido.
>
>

```

## 9. EMV na uniforme. Como

$$f(x; \theta) = \frac{1}{\theta} I_A(x), \quad A = [0, \theta].$$

A densidade conjunta da amostra é

$$f(x_1, \dots, x_n; \theta) = \frac{1}{\theta^n} \quad 0 \leq x_i \leq \theta.$$

A função de verossimilhança é dada por:

$$L(\theta) = \frac{1}{\theta^n} I_{[m, \infty)}(\theta), \quad m = \max(x_1, x_2, \dots, x_n).$$



Segue-se que

$$l(\theta) = \ln(L(\theta)) = -n \log(\theta)$$

e derivando e igualando a zero obteremos

$$-\frac{n}{\theta} = 0,$$

ou seja, o EMV de  $\theta$  seria infinito!!!!

Evidentemente, essa não é a resposta.

Na realidade, não podemos simplesmente derivar a verossimilhança (ou o logaritmo dela) para obter o máximo, pois temos as restrições  $0 \leq x_i \leq \theta$ , para todo  $i$ .

Façamos o seguinte.

Considere o gráfico da verossimilhança, como função de  $\theta$ . Como devemos ter

$$0 \leq x_i \leq \theta,$$

para todo  $i$ , o máximo  $M$  dos  $x_i$  deve ser tal que

$$0 \leq M \leq \theta$$

, ou seja, obtemos o gráfico abaixo.

Note que:

1. A função  $L(\theta)$  é uma função decrescente de  $\theta$ .
2. Seu máximo ocorre no limite inferior do domínios da função  $L(\theta)$  é uma função decrescente de  $\theta$ .
3. Obtida a amostra aleatória  $(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$  a estimativa de máxima verossimilhança de  $\theta$  é

$$m = \max(x_1, x_2, \dots, x_n).$$

Ou seja,

$$L(\theta) = 0, \text{ para } \theta \leq M,$$

logo, o máximo da verossimilhança é obtido para  $\theta = M$  e portanto

$$\hat{\theta}_{MV} = M = Y_n = \max(X_1, X_2, \dots, X_n).$$

Esse exemplo mostra que nem sempre obteremos o EMV derivando-se a verossimilhança e igualando-a a zero.




Figura 6:

10. Outro I.C. para  $p$ . Considere

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$$

Logo, com coeficiente de confiança  $\gamma$ , um intervalo de confiança para  $p$  seria:

$$IC(p, \gamma) = \left\{ p : \left| \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \right| \leq z_\gamma \right\}$$

Fazendo

$$z_\gamma = z$$

Daqui segue que

$$(\hat{p} - p)^2 \leq \frac{z^2}{n} p(1 - p).$$

Daí obtenha

$$\hat{p}^2 - 2 \hat{p} p + p^2 \leq \frac{z^2}{n} (p - p^2).$$

Agora obtenha a inequação para  $p$

$$\left(1 + \frac{z^2}{n}\right) p^2 - \left(2 \hat{p} + \frac{z^2}{n}\right) p + \hat{p}^2 \leq 0.$$

Resolva esta inequação para  $p$  e obtenha o I.C.

Se  $\hat{p} = 0,3$  e  $\gamma = 0,95$ , obtenha o correspondente I.C.