

Guia rápido - Inferência Estatística I

License MIT

The MIT License © 2023, Arthur Silva

arthursilva@alu.ufc.br

4r7hu3.github.io

- [O que é Inferência?](#)
 - [Preliminares](#)
 - [Para fixar](#)
 - [Fórmulas](#)
 - [Algumas demonstrações](#)
 - [Eficiência entre estimadores](#)
 - [Família exponencial](#)
 - [Exercícios Resolvidos 1](#)
 - [Mais definições](#)
 - [Exercícios Resolvidos 2](#)
 - [Métodos de estimação](#)
 - [Método dos momentos](#)
 - [Método da máxima verossimilhança](#)
 - [Método dos mínimos quadrados](#)
 - [Exercícios Resolvidos 3](#)
 - [Estimação intervalar](#)
 - [Intervalos Bilaterais](#)
 - [Intervalos Unilaterais](#)
 - [Testes de Hipótese](#)
 - [Métodos](#)
 - [Procedimentos em uma amostra](#)
 - [Procedimentos em duas amostras](#)
 - [Teste mais poderoso](#)
-

O que é Inferência?

A Inferência Estatística busca fazer estimativas, que podem ser intervalares e pontuais, de **parâmetros populacionais** e/ou da distribuição ou forma/lei de um conjunto de dados a partir de uma **amostra**. Um exemplo de uso prático muito importante são as eleições, que buscam inferir — através da coleta de informações de uma amostra de tamanho n — a quantidade X de votos que irão receber candidatos a cargos políticos. Além dessa aplicação, a Inferência trabalha com testes de hipótese (intrinsecamente ligados à estimação), os quais são empregados em praticamente toda a área do conhecimento humano, não limitando-se às áreas de ciências exatas.

Preliminares

Alguns conceitos importantes para a Inferência:

1. *População* - O conjunto universo. O todo;
2. *Amostra* - Qualquer subconjunto da população. Parte da população;
3. *Parâmetro* - Dados que referem-se à **população**;
4. *Estatística* - Dados que referem-se à **amostra**;
5. *Amostra Aleatória Simples* - Conjunto de n variáveis aleatórias independentes e identicamente distribuídas (**I.I.D**);
6. *Espaço Paramétrico* - É o conjunto Θ em cujos os parâmetros variam;
7. *Suporte* - É o conjunto A em cuja a v.a varia;
8. *Estimador* - Função dos valores amostrais para estimar um parâmetro desconhecido^[1];
9. *Estimativa* - Valor estimado propriamente dito;
10. *Viés* - Mede a distância absoluta (erro) da média do estimador em relação ao parâmetro estimado^[2]:
 - 10.1 Estimador **não-viesado**: $E[\hat{\theta}] = \theta, \forall \theta \in \Theta$
 - 10.2 Estimador **viesado**: $E[\hat{\theta}] \neq \theta, \forall \theta \in \Theta$
 - 10.3 Estimador **assintoticamente não viesado**: $\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta$
 - 10.4 Estimador **consistente**: $\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta$ e $\lim_{n \rightarrow \infty} Var[\hat{\theta}] = 0$
11. *Erro Quadrático Médio* - O EQM calcula a expectativa do quadrado do erro do estimador em relação ao parâmetro a ser estimado;
12. *Erro Padrão* - É a raíz quadrada da varância de um estimador;

Definição formal de *Estatística*: função da amostra que **não** depende de parâmetros desconhecidos.

Exemplos:

Seja X_1, X_2, \dots, X_n uma amostra aleatória de tamanho n de uma v.a X .

- $\max(x_1, x_2, \dots, x_n)$ é uma estatística;
- $\min(x_1, x_2, \dots, x_n)$ é uma estatística;
- \bar{X} é uma estatística;
- S^2 é uma estatística.

Note que nenhuma das funções acima depende de parâmetros desconhecidos!

Para fixar

Agora, vamos anotar algumas formas e provas muito importantes para a Inferência:

Fórmulas

- $\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \sim N\left(\mu; \frac{\sigma^2}{n}\right)$
- $Z = \frac{X - \mu}{\sigma} \sim N(0;1)$ e $Z^2 \sim \chi^2_{(1)}$
- $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$
- $\frac{(n - 1)S^2}{\sigma^2} \sim \chi^2_{(n-1)}$
- $\frac{(n - 1)S^2}{n} \sim \chi^2_{(n)}$
- $2\theta S \sim \chi^2_{(2n)}$, com $S \sim Gama(n; \theta)$
- $X = \frac{\frac{U}{n-1}}{\frac{V}{m-1}} \sim F(n - 1; m - 1)$, com $\frac{U}{n - 1} = \frac{S_1^2}{\sigma_1^2}$ e $\frac{V}{m - 1} = \frac{S_2^2}{\sigma_2^2}$
- $G = \frac{1}{X} \sim F(m - 1; n - 1)$
- $\sum_{i=1}^n X_i \sim Gama(n, \theta)$, com $X \sim Exp(\theta)$
- $\sum_{i=1}^n X_i \sim Bin(n; p)$, com $X \sim Ber(p)$

- $B(\hat{\theta}) = E[\hat{\theta}] - \theta$, é o **viés** do estimador $\hat{\theta}$
- $EQM(\theta) = E[(\hat{\theta} - \theta)^2] = Var[\hat{\theta}] + B^2(\hat{\theta})$ é o **erro quadrático médio** do estimador $\hat{\theta}$ ^[3]
- $f(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$ é a **distribuição conjunta da amostra**
- $L(\theta) = \prod_{i=1}^n f(x_i | \theta) I_{\theta}(\theta)$ é a **função de verossimilhança**^[4]
- $\int_0^{\infty} v^{n-1} e^{-bv^c} dv = \frac{\Gamma(\frac{n}{c})}{cb^{\frac{n}{c}}}$ é a **função gama generalizada**
para lembrar:
 1. $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$
 2. $\Gamma(n) = (n - 1)!, \forall n \in \mathbb{Z}^+$
 3. $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

Algumas demonstrações

- \bar{X} é um estimador viesado ou não viesado para μ ? Considere uma v.a $X \sim N(\mu; \sigma^2)$.

Solução: $E[\bar{X}] - \mu = \frac{1}{n} E[\sum_{i=1}^n X_i] - \mu = \frac{1}{n} \times n \times E[X] - \mu = 0$. Portanto, \bar{X} é **não viesado!**

OBS: Note que X_i são n v.a's I.I.D

- S^2 é um estimador viesado ou não viesado para σ^2 ? Considere uma v.a $X \sim N(\mu; \sigma^2)$.

Solução: $\frac{1}{n-1} E[\sum_{i=1}^n (X_i - \bar{X})^2]$.

Temos que $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 - 2X_i \bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$.

Agora temos que $E[\sum_{i=1}^n (X_i - \bar{X})^2] = E[\sum_{i=1}^n X_i^2 - n\bar{X}^2]$

Note que $E[X^2] = Var[X] + E^2[X] = \sigma^2 + \mu^2$, e que $E[\bar{X}^2] = Var[\bar{X}] + E^2[\bar{X}] = \frac{\sigma^2}{n} + \mu^2$

Finalmente: $\frac{1}{n-1} E[\sum_{i=1}^n X_i^2 - n\bar{X}^2] = \frac{1}{n-1} [(n\sigma^2 + n\mu^2) - (\sigma^2 + n\mu^2)] =$

$$\frac{1}{n-1}\sigma^2(n-1) = \sigma^2$$

Portanto, S^2 é **não viesado**!

- $\hat{\sigma}^2$ é um estimador não viesado para σ^2 ? Considere uma v.a $X \sim N(\mu; \sigma^2)$.

Solução: Já sabemos que $E[\sum_{i=1}^n X_i^2 - n\bar{X}^2] = \sigma^2(n-1)$.

Portanto, $\frac{1}{n}E[\sum_{i=1}^n (X_i^2 - n\bar{X}^2)] = \frac{\sigma^2(n-1)}{n} \neq \sigma^2$.

OBS: Note que $B(\hat{\sigma}^2) = -\frac{\sigma^2}{n}$, ou seja, **subestima** o parâmetro!

- Prove que $E[(\hat{\theta} - \theta)^2] = Var[\hat{\theta}] + B^2(\hat{\theta})$.

Solução: Primeiro, vamos considerar $\hat{\theta} - \theta = \hat{\theta} - E[\hat{\theta}] + E[\hat{\theta}] - \theta$.

Então, $(\hat{\theta} - \theta)^2 = (\hat{\theta} - E[\hat{\theta}])^2 + 2(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta) + (E[\hat{\theta}] - \theta)^2$.

Logo, $E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E[\hat{\theta}])^2] + E[(E[\hat{\theta}] - \theta)^2] = Var[\hat{\theta}] + B^2(\hat{\theta})$.

OBS: Note que $E[2(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta)] = 2(E[\hat{\theta}] - E[\hat{\theta}])(E[\hat{\theta}] - E[\theta]) = 0$.

- Encontre a distribuição de S^2 . Considere $W \sim Gama(\alpha; \lambda)$ e utilize sua *f.g.m.* para achar o resultado.

Solução: Sabemos que $S^2 = \frac{\sigma^2 V}{n-1}$, onde $V \sim \chi_{(n-1)}^2$. Usando a função geradora de momentos ficamos com o seguinte:

$$M_{S^2}(t) = E[e^{tS^2}] = E\left[e^{t\frac{\sigma^2 V}{n-1}}\right] = M_V\left(\frac{t\sigma^2}{n-1}\right) = \left[1 - \frac{2t\sigma^2}{n-1}\right]^{-(n-1)/2}.$$

Sabemos que a f.g.m de W pode ser posta na seguinte forma: $\left[\frac{1}{1-\frac{t}{\lambda}}\right]^\alpha = [1 - \frac{t}{\lambda}]^{-\alpha}$.

Analisando atentamente, temos que $\alpha = (n-1)/2$ e $\lambda = \frac{n-1}{2\sigma^2}$.

Logo, $S^2 \sim Gama\left(\frac{n-1}{2}; \frac{n-1}{2\sigma^2}\right)$. Vamos testar?

$$E[S^2] = \frac{\alpha}{\lambda} = \frac{\frac{n-1}{2}}{\frac{n-1}{2\sigma^2}} = \sigma^2.$$

$$Var[S^2] = \frac{\alpha}{\lambda^2} = \frac{\frac{n-1}{2}}{\frac{(n-1)^2}{4\sigma^4}} = \frac{2\sigma^4}{n-1}.$$

Eficiência entre estimadores

Sejam T_1 e T_2 dois estimadores de θ . Se $\forall \theta \in \Theta$ a seguinte desigualdade ocorrer, para pelo menos um valor de θ , então o **melhor estimador** será aquele de **menor EQM**.

$$EQM(T_1) \leq EQM(T_2)$$

Se T_1 e T_2 forem não viesados, o melhor será aquele de **menor variância**.

Família exponencial

A *Família exponencial* constitui um importante grupo de funções (f.d.p e f.m.p) com características bem definidas pelos seguintes critérios:

1. O suporte A da distribuição **não** depende do parâmetro desconhecido, digamos, θ ;
2. $\log(f(x|\theta)) = c(\theta)T(x) + d(\theta) + h(x)$.

É importante destacar que nem sempre as componentes vão estar explícitas na forma acima, por exemplo, há funções onde $h(x) = 0$, sendo assim omitida da equação.

Fatos importantes decorrentes da família exponencial:

1. $E[T(x)] = -\frac{d'(\theta)}{c'(\theta)}$;
2. Seja $S = \sum_{i=1}^n T(X_i)$. S é uma **estatística suficiente e completa** para θ ;
3. $E[S] = nE[T(x)]$ e $Var[S] = nVar[T(x)]$;
4. $M_S(t) = [M_X(t)]^n$, que usamos para encontrar a **distribuição amostral** de S .

Para encontrar o UMVUE de $g(\theta)$, sabendo que a distribuição pertence à família exponencial, encontra-se uma função de S , $h(S)$, de tal forma que $E[h(S)] = g(\theta)$.

Exercícios Resolvidos 1

1. Seja $X \sim Ber(p)$. Mostre que X pertence à família exponencial.

$$1.1. f(x|p) = p^x(1-p)^{1-x}I_{\{0,1\}}(x), \theta = [0, 1]$$

$$1.2. \log f(x|p) = x \log p + \log(1-p) - x \log(1-p) = x[\log p - \log(1-p)] + \log(1-p)$$

$$1.3. T(x) = x; c(p) = \log p - \log(1-p); d(p) = \log(1-p); h(x) = 0$$

Vemos que o suporte da distribuição **independe** de p . Logo, está provado que X pertence à família exponencial.

Além disso, $S = \sum_{i=1}^n x_i$ é uma estatística suficiente e completa para p . Sua distribuição é:
 $M_S(t) = [M_X(t)]^n = [pe^t + (1-p)]^n \sim \text{Bin}(n, p)$

Vamos encontrar o **UMVUE**: $E[S] = np \quad \therefore \quad E\left[\frac{S}{n}\right] = p \quad \therefore \quad \bar{X}$ é o nosso estimador procurado.

2. Seja $X \sim \text{Gama}(3; \theta)$. Essa v.a pertence à família exponencial? Verifique.

$$2.1. f(x|\theta) = \frac{\theta^3}{2} x^2 e^{-\theta x} I_{(0, \infty)}(X), \Theta = (0, \infty)$$

$$2.2. \log f(x|\theta) = 3 \log \theta - \log 2 + 2 \log x - \theta x$$

$$2.2. T(x) = x; c(\theta) = -\theta; d(\theta) = 3 \log \theta; h(x) = 2 \log x - \log 2$$

Podemos ver que o suporte da nossa v.a **independe** do parâmetro. Portanto, provamos que X pertence à família exponencial.

Além disso, $S = \sum_{i=1}^n x_i$ é uma estatística suficiente e completa, com distribuição: $M_S(t) = \left[\frac{\theta}{\theta - t}\right]^{3n}, \text{Gama}(3n; \theta)$

Mais definições

Considere X uma v.a com f.m.p ou f.d.p $f(x|\theta)$, com suporte A independente de θ .

- $V = \frac{\partial \log f(X|\theta)}{\partial \theta}$ é a **função escore**.
OBS: $E[V] = 0$.

- $I_F(\theta) = \text{Var}[V] = E[V^2] = E^2 \left[\frac{\partial \log f(X|\theta)}{\partial \theta} \right] = -E \left[\frac{\partial^2 \log f(X|\theta)}{\partial \theta^2} \right]$ é a **informação de Fisher**.^[5]

Note que como $E[V] = 0$, logo, $\text{Var}[V] = E[V^2]$.

- $LICR(\theta) = \frac{1}{nI_F(\theta)}$ é o **Limite Inferior de Crámer-Rao**, denotado também por LI .
- Se T é um estimador de $g(\theta)$, então $Var[T] \geq \frac{[g'(\theta)]^2}{nI_F(\theta)}$, que é chamada de **desigualdade da informação** (caso geral).
- $e(T) = \frac{LICR(\theta)}{Var[T]}$ é a eficiência do estimador.
Se $e(T) = 1$, então o estimador é dito ser **eficiente**!
- Dizemos que T é uma **estatística suficiente** para θ se, e somente se, a distribuição conjunta da amostra puder ser fatorada dessa forma:
$$\prod_{i=1}^n f(x_i|\theta) = h(x_1, x_2, \dots, x_n) g_\theta(T(x_1, x_2, \dots, x_n))$$
 [6]
- **Teorema de Rao-Blackwell**: Seja S uma estatística suficiente de θ e T um estimador não-viesado de $g(\theta)$. Então $T^* = E[T|S]$ geralmente é o melhor estimador para θ .
- **Teorema de Lehmann-Scheffé**: T^* é o **UMVUE** (uniformly minimum variance unbiased estimator) [7].

Exercícios Resolvidos 2

1. Seja $X \sim Exp(\theta)$. Encontre a função escore e a informação de Fisher.

$$1.1. f(x|\theta) = \theta e^{-\theta x} I_A(x), A = (0, \infty), \Theta = (0, \infty)$$

$$1.2 \log f(x|\theta) = \log \theta - \theta x$$

$$1.3 V = \frac{1}{\theta} - X. \text{ Observe que } E[V] = 0$$

$$1.4 I_F(\theta) = Var[V] = Var\left[\frac{1}{\theta} - X\right] = Var[X] = \frac{1}{\theta^2}$$

2. Seja X uma v.a de seguinte distribuição: $f(x|\theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x), \theta > 0$. Encontre uma estatística suficiente para o parâmetro.

Vemos que o suporte é dependente do parâmetro desconhecido, logo, não podemos usar a família exponencial. Usaremos o critério da fatoração, encontrando $h(\mathbf{x}) = e^{-s}$ e $g(\theta, y_1) = e^{n\theta} I_{(\theta, \infty)}(y_1)$. y_1 é nossa estatística suficiente:

$$L(\theta) = \prod_{i=1}^n e^{-(x_i - \theta)} I_{(\theta, \infty)}(x_i) = e^{-s} e^{n\theta} \prod_{i=1}^n I_{(\theta, \infty)}(x_i)$$

$$I_{(\theta, \infty)}(x_i) = 1 \Leftrightarrow x_1 > \theta; x_2 > \theta; \dots; x_n > \theta$$

$$\vdots$$

$$y_1 = \min(x_1, x_2, \dots, x_n) > \theta$$

$$\vdots$$

$$I_{(\theta, \infty)}(y_1)$$

$$\vdots$$

$$e^{-s} e^{n\theta} I_{(\theta, \infty)}(y_1)$$

3. Seja $T = 2\bar{X}$ um estimador não viesado para θ , parâmetro de $X \sim U[0; \theta]$. Seja o novo estimador $T_1 = E[2X|Y_n]$, onde Y_n é uma estatística suficiente e completa para o parâmetro. Qual nome recebe esse novo estimador?

$E[2X|Y_n]$ é um estimador não viesado que é função de uma estatística suficiente. Logo, pelo teorema de *Lehmann-Sheffé* ou pelo teorema de *Rao-Blackwell*, T_1 é o nosso **UMVUE**.

4. Seja X_1, \dots, X_n uma A.A.S. de $X \sim \text{Bin}(2, \theta)$.

- Encontre o LICR.
- Encontre uma estatística suficiente para θ .
- Obtenha o **UMVUE** para θ .
- Descubra se o estimador é eficiente ou não.

$$4.1. f(X|\theta) = \binom{2}{X} \theta^X (1 - \theta)^{2-X} I_{\{0,1,2\}}(X)$$

$$4.2. \log f(X|\theta) = \log \binom{2}{X} + X \log \theta + (2 - X) \log (1 - \theta)$$

$$4.3. V = \frac{X}{\theta} - \frac{(2 - X)}{(1 - \theta)} = \frac{X(1 - \theta) - \theta(2 - X)}{\theta(1 - \theta)} = \frac{X - 2\theta}{\theta(1 - \theta)}$$

$$4.4. I_F(\theta) = \text{Var}[V] = \frac{2\theta(1 - \theta)}{\theta^2(1 - \theta)^2} = \frac{2}{\theta(1 - \theta)}$$

$$4.5. LICR = \frac{1}{n \frac{2}{\theta(1 - \theta)}} = \frac{\theta(1 - \theta)}{2n}$$

Vamos encontrar a estatística suficiente pelo critério da fatoração (poderia usar família exponencial):

$$L(\theta) = \prod_{i=1}^n \binom{2}{X_i} \theta^{X_i} (1-\theta)^{2-X_i} = \theta^s (1-\theta)^{2n-s} \prod_{i=1}^n \binom{2}{X_i}, \text{ com } s = \sum_{i=1}^n X_i. \\ L(\theta) = \left[\frac{\theta}{(1-\theta)} \right]^s (1-\theta)^{2n} \prod_{i=1}^n \binom{2}{X_i} = g(\theta, s) h(\mathbf{x}).$$

Assim, nossa estatística suficiente é $s = \sum_{i=1}^n X_i$.

4.6. Sabemos que $s \sim \text{Bin}(2n; \theta)$, com $E[s] = 2n\theta$. Então, $E\left[\frac{s}{2n}\right] = \theta = E\left[\frac{\bar{X}}{2}\right]$ é nosso **UMVUE** procurado.

4.7. $\text{Var}\left[\frac{\bar{X}}{2}\right] = \frac{1}{4} \frac{2\theta(1-\theta)}{n} = \frac{\theta(1-\theta)}{2n} = \text{LICR}$. Nosso estimador é eficiente!

Métodos de estimação

Método dos momentos

É o método mais simples e mais antigo já utilizado, e que consiste em igualar o primeiro momento populacional ao primeiro momento amostral. Em outras palavras, basta igualar \bar{X} a μ : $E[X] = \bar{X}$

Método da máxima verossimilhança

Para encontrar o estimador de máxima verossimilhança, em geral, segue-se os seguintes passos:

1. Encontrar $L(\theta)$
2. Encontrar a função log-verossimilhança: $l(\theta) = \log L(\theta)$
3. Derivar $l(\theta)$ em relação a θ e igualar a 0: $\frac{\partial l(\theta)}{\partial \theta} = 0$
4. Derivar novamente para provar que o ponto encontrado no passo 3 é o máximo: $\frac{\partial^2 l(\theta)}{\partial \theta^2} < 0$

Note que, em suma, estamos **maximizando** a função de verossimilhança, de forma que seja o mais provável possível encontrar o ponto em nossa amostra.

Propriedades dos EMV:

- O EMV é sempre função de uma estatística suficiente para o parâmetro
- Se $\hat{\theta}$ é um EMV, então $g(\hat{\theta})$ é o EMV para $g(\theta)$ [8]
- Para grandes amostras: $\sqrt{n} (g(\hat{\theta}) - g(\theta)) \overset{a}{\sim} N\left(0, \frac{[g'(\theta)]^2}{I_F(\theta)}\right)$ [9]

Método dos mínimos quadrados

Ao contrário dos estimadores de máxima verossimilhança, onde queremos maximizar uma função, nos mínimos quadrados, como o próprio nome sugere, vamos **minimizar** uma soma de quadrados, que na

verdade é a soma dos quadrados dos desvios $(X - E[X])^2$. Veja os passos a seguir:

1. Encontre $S(x) = \sum_{i=1}^n (X_i - E[X_i])^2$
2. Faça $S'(x) = 0$
3. Mostre que $S''(x) > 0$ para provar que o ponto encontrado no passo 2 é de mínimo

Exercícios Resolvidos 3

1. Seja $X \sim \text{Exp}(\theta)$. Encontre o estimador pelo método dos momentos.

$$\mu = \bar{X} \quad \therefore \quad \frac{1}{\theta} = \bar{X} \quad \therefore \quad \theta_{MM} = \frac{1}{\bar{X}}$$

2. Seja $X \sim U(0; \theta)$. Encontre o estimador pelo método dos momentos.

$$\mu = \bar{X} \quad \therefore \quad \frac{\theta}{2} = \bar{X} \quad \therefore \quad \theta_{MM} = 2\bar{X}$$

3. Ache o estimador pelo método da máxima verossimilhança para a v.a do item 1.

$$3.1. L(\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta s}$$

com $s = \sum_{i=1}^n X_i$

$$3.2. l(\theta) = \log L(\theta) = n \log \theta - \theta s$$

$$3.3. l'(\theta) = \frac{n}{\theta} - s$$

$$3.4. \frac{n}{\theta} = s \quad \therefore \quad \frac{1}{\theta} = \bar{X} \quad \therefore \quad \theta_{MV} = \frac{1}{\bar{X}}$$

$$3.5. l''(\theta) = -\frac{n}{\theta^2} < 0, \text{ portanto, ponto de máximo}$$

4. Ache o estimador de máxima verossimilhança para a seguinte v.a:

$$f(x|\theta) = \frac{x}{\theta^2} \exp\left(-\frac{x}{\theta}\right) I_A(x), A = (0, \infty), \theta > 0. \text{ Verifique se ele é eficiente.}$$

$$4.1. L(\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \frac{x_i}{\theta^2} \exp\left(-\frac{x_i}{\theta}\right) = \theta^{-2n} e^{-\frac{s}{\theta}} \prod_{i=1}^n x_i, \text{ com } s = \sum_{i=1}^n x_i$$

$$4.2. l(\theta) = -2n \log \theta - \frac{s}{\theta} + \sum_{i=1}^n \log x_i$$

$$4.3. l'(\theta) = \frac{-2n}{\theta} + \frac{s}{\theta^2}$$

$$4.4. \theta_{MV} = \frac{s}{2n} = \frac{\bar{X}}{2}$$

$$4.5. l''(\theta) = \frac{2n}{\theta^2} - \frac{2s}{\theta^3} = \frac{2n}{\theta^2} - \frac{2n\bar{X}}{\theta^3} < 0, \text{ logo, ponto de máximo.}$$

Veremos agora se ele é eficiente:

$$4.6. \log f(x|\theta) = \log X - 2 \log \theta - \frac{x}{\theta}$$

$$4.7. V = -\frac{2}{\theta} + \frac{x}{\theta^2}$$

$$4.8. \text{Var}[V] = \frac{1}{\theta^4} \text{Var}[X] = \frac{2}{\theta^2} = I_F(\theta), \text{ pois } \text{Var}[X] = 2\theta^2; X \sim \text{Gama}(\frac{1}{\theta}, 2)$$

$$4.9. LICR = \frac{1}{n \frac{2}{\theta^2}} = \frac{\theta^2}{2n}$$

$$4.9.1. e\left(\frac{\bar{X}}{2}\right) = \frac{\frac{\theta^2}{2n}}{\text{Var}\left[\frac{\bar{X}}{2}\right]} = 1. \text{ Nosso estimador é eficiente}$$

5. Ache o estimador pelo método dos mínimos quadrados para a v.a do item 1.

$$5.1. S(\theta) = \sum_{i=1}^n (X_i - E[X_i])^2 = \sum_{i=1}^n (X_i - \frac{1}{\theta})^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X}\frac{1}{\theta} + \frac{n}{\theta^2}$$

$$5.2. S'(\theta) = \frac{2n\bar{X}}{\theta^2} - \frac{2n}{\theta^3}$$

$$5.3. \theta_{MM} = \frac{1}{\bar{X}}$$

$$5.4. S''(\theta) = \frac{-4n\bar{X}}{\theta^3} + \frac{6n}{\theta^4} > 0, \text{ portanto, ponto de mínimo}$$

6. Considere o modelo de regressão: $\beta\sqrt{X_i} + u_i, i = 1, 2, n$, com u_i 's independentes. Considere também que $E[u_i] = 0$ e $\text{Var}[u_i] = \sigma^2$. Encontre o EMQ de β .

$S(\beta) = \sum_{i=1}^n (Y_i - E[Y_i])^2$. Vamos encontrar a esperança e variância de Y_i primeiro:

$$6.1. E[Y_i] = E[\beta\sqrt{X_i} + u_i] = E[\beta\sqrt{X_i}] + E[u_i] = \beta\sqrt{X_i}$$

$$6.2. \text{Var}[\beta\sqrt{X_i} + u_i] = \text{Var}[u_i] = \sigma^2$$

Agora, vamos prosseguir.

$$6.3. S(\beta) = \sum_{i=1}^n (Y_i^2 - 2Y_i\beta\sqrt{X_i} + \beta^2 X_i) = \sum_{i=1}^n Y_i^2 - 2\beta \sum_{i=1}^n Y_i\sqrt{X_i} + \beta^2 \sum_{i=1}^n X_i$$

$$6.4. S'(\beta) = -2 \sum_{i=1}^n Y_i\sqrt{X_i} + 2\beta \sum_{i=1}^n X_i \quad \therefore \quad \beta = \frac{\sum_{i=1}^n Y_i\sqrt{X_i}}{\sum_{i=1}^n X_i}$$

$$6.5. S''(\beta) = 2 \sum_{i=1}^n X_i > 0, \text{ logo, ponto de m\u00ednimo}$$

7. Para o item 1., encontre o EMV de $P(X > 2) = g(\theta)$ e sua distribui\u00e7\u00e3o em grandes amostras.

$$7.1. P(X > 2) = 1 - P(X \leq 2) = 1 - [1 - e^{-2\theta}] = e^{-2\theta} = g(\theta)$$

$$7.2. \text{ Pelo princ\u00edpio da invari\u00e2ncia, } g(\hat{\theta}) = g(\theta) \quad \therefore \quad g(\hat{\theta}) = e^{-\frac{2}{\hat{X}}}$$

7.3. J\u00e1 vimos anteriormente que $I_F(\theta) = \frac{1}{\theta^2}$. \u00c9 f\u00e1cil ver tamb\u00e9m que $[g'(\theta)]^2 = 4e^{-4\theta}$. Logo, em grandes amostras:

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \stackrel{a}{\sim} N(0; 4\theta^2 e^{-4\theta})$$

Estima\u00e7\u00e3o intervalar

Estima\u00e7\u00f5es intervalares, ou seja, entre intervalos, s\u00e3o constru\u00eddas atrav\u00e9s do m\u00e9todo da **quantidade pivotal**, que \u00e9 uma vari\u00e1vel aleat\u00f3ria especial, cuja distribui\u00e7\u00e3o **n\u00e3o** depende de par\u00e2metros desconhecidos.

Tais estimativas partem da vertente frequentista da estat\u00edstica, sob a seguinte interpreta\u00e7\u00e3o: para um n\u00famero grande de vezes, e sob as mesmas circunst\u00e2ncias de realiza\u00e7\u00e3o, o par\u00e2metro a ser estimado encontra-se dentro do intervalo encontrado, X% das vezes, onde X \u00e9 o n\u00edvel de confian\u00e7a pr\u00e9-estabelecido.

Geralmente, s\u00e3o estabelecidos n\u00edveis $\gamma = 1 - \alpha$ de confian\u00e7a de 90%, 95% e 99%, onde α \u00e9 o n\u00edvel de signific\u00e2ncia. Por\u00e9m, outros n\u00edveis de confian\u00e7a podem tamb\u00e9m ser utilizados. Entretanto, deve-se observar a influ\u00eancia do mesmo no comprimento do intervalo, como ser\u00e1 visto a seguir.

Intervalos Bilaterais

1. Seja X_1, X_2, \dots, X_n uma A.A com distribui\u00e7\u00e3o $N(\mu, \sigma^2)$.

- o Intervalo de confian\u00e7a para μ , com σ^2 conhecida [\[10\]](#):

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Quantidade pivotal: $Q = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0; 1)$

- Intervalo de confiança para μ , com σ^2 **desconhecida**:

$$\left[\bar{X} - t_{\alpha/2} \frac{S}{\sqrt{n}}; \bar{X} + t_{\alpha/2} \frac{S}{\sqrt{n}} \right]$$

Quantidade pivotal: $Q = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{(n-1)}$

- Intervalo de confiança para σ^2 :

$$\left[\frac{(n-1)S^2}{q_2}; \frac{(n-1)S^2}{q_1} \right]$$

Quantidade pivotal: $Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{(n-1)}$

2. Seja X_1, X_2, \dots, X_n uma A.A com distribuição $Exp(\theta)$.

Intervalo de confiança para θ :

$$\left[\frac{q_1}{2S}; \frac{q_2}{2S} \right]$$

Quantidade pivotal: $Q = 2\theta S \sim \chi_{(2n)}, S = \sum_{i=1}^n X_i \sim Gama(n; \theta)$

3. Seja X_1, X_2, \dots, X_n uma A.A com distribuição $Ber(p)$.

Intervalo de confiança de MV para p :

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

Onde \hat{p} é o estimador de máxima verossimilhança para p .

Quantidade pivotal: $Q = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0; 1)$

É importante salientar que existem outros intervalos para a proporção populacional, como o **conservador** e o de **MV com fator de correção**. Porém, por terem notações muito extensas, não serão colocados aqui.

4. Seja X_1, X_2, \dots, X_n uma A.A de tamanho n com distribuição $N(\mu_1, \sigma_1^2)$. Temos que \bar{X} e S_1^2 são **independentes**. Agora, seja Y_1, Y_2, \dots, Y_m uma A.A de tamanho m com distribuição $N(\mu_2, \sigma_2^2)$. Temos que \bar{Y} e S_2^2 são **independentes**. Temos também que $U = \frac{(n-1)S_1^2}{\sigma_1^2} \sim \chi_{(n-1)}^2$ e $V = \frac{(m-1)S_2^2}{\sigma_2^2} \sim \chi_{(m-1)}^2$. As variáveis \bar{X}, \bar{Y}, U e V são **independentes** entre si. [\[11\]](#)

◦ Intervalo de confiança para $\mu_1 - \mu_2$, com σ_1^2 e σ_2^2 **conhecidas**:

$$\left[(\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}; (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} \right]$$

Quantidade pivotal: $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$

◦ Intervalo de confiança para $\mu_1 - \mu_2$, com $\sigma_1^2 = \sigma_2^2$ **desconhecidas**:

$$\left[(\bar{X} - \bar{Y}) - t_{\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}}; (\bar{X} - \bar{Y}) + t_{\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}} \right]$$

Onde $S_p = \sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}$.

Quantidade pivotal: $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{(n+m-2)}$

- Intervalo de confiança para $\mu_1 - \mu_2$, com $\sigma_1^2 \neq \sigma_2^2$ **desconhecidas**:

$$\left[(\bar{X} - \bar{Y}) - t_{\alpha/2} \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}; (\bar{X} - \bar{Y}) + t_{\alpha/2} \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}} \right]$$

Quantidade pivotal: $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}} \sim t_{(r)}$, onde $r = \frac{(A+B)^2}{\frac{A^2}{n-1} + \frac{B^2}{m-1}}$, com $A = \frac{S_1^2}{n}$

e $B = \frac{S_2^2}{m}$. r é o número inteiro mais próximo.

- Intervalo de confiança para $\frac{\sigma_1^2}{\sigma_2^2}$:

$$\left[f_1 \frac{S_2^2}{S_1^2}; f_2 \frac{S_2^2}{S_1^2} \right]$$

Quantidade pivotal: $Q = \frac{S_1^2}{S_2^2} \frac{\sigma_2^2}{\sigma_1^2} \sim F(n-1; m-1)$

5. Seja $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ uma A.A de $(X, Y) \sim N(\mu_1, \mu_2; \rho, \sigma_1^2, \sigma_2^2)$.

Intervalo de confiança para $D = X - Y$:

$$\left[\bar{D} - t_{\alpha/2} \frac{S_D}{\sqrt{n}}; \bar{D} + t_{\alpha/2} \frac{S_D}{\sqrt{n}} \right]$$

Quantidade pivotal: $Q = \frac{\bar{D} - \mu_D}{S_D/\sqrt{n}} \sim t_{(n-1)}$

Quando temos amostras advindas de processos SEM REPOSIÇÃO, multiplicamos os limites pelo fator de correção $\frac{N-n}{N-1}$. [\[12\]](#)

Note que, nos intervalos para a média populacional, o valor de \bar{X} pode ser encontrado da seguinte forma: $\bar{X} = \frac{li + ls}{2}$

Intervalos Unilaterais

A definição de intervalos de confiança, sejam eles bilaterais ou unilaterais, está intrinsecamente ligada à testes de hipótese, pois é a partir de hipóteses pré formuladas que se constroem tais intervalos.

Há dois tipos de hipóteses: H_0 e H_1 , que correspondem respectivamente à hipótese nula (“principal”) e à hipótese alternativa (“secundária”).

As mesmas ainda podem ser classificadas em duas categorias:

- Simples: quando os valores supostos **são exatos** (ou seja, são iguais a um valor X)
- Compostas: quando os valores **não são exatos** (ou seja, são maiores, menores ou diferentes de um valor X)

O tipo de intervalo que é construído para testar as hipóteses, é baseado na direção da hipótese alternativa.

Quando H_1 é da forma $H_1 : \mu \neq X$, construímos intervalos bilaterais, pois o valor real pode estar tanto acima quanto abaixo do valor suposto em H_0 .

Já quando H_1 é da forma $H_1 : \mu > X$ ou $H_1 : \mu < X$, usamos intervalos unilaterais, pois o valor real só se encontra ou acima ou abaixo do valor suposto em H_0 .

1. Para $H_1 : \mu > X$, temos um intervalo unilateral **à direita** ou **superior**.
2. Para $H_1 : \mu < X$, temos um intervalo unilateral **à esquerda** ou **inferior**.

Para construir esses intervalos, procedemos da mesma forma que os intervalos bilaterais já vistos, com a diferença de que, se a hipótese alternativa for da primeira forma, então temos $IC[-\infty, ls]$. Caso tenhamos a segunda forma, ficamos com $IC[li, \infty]$.

Para proporções, a diferença é que substituímos $-\infty \rightarrow 0$, e $\infty \rightarrow 1$.

Testes de Hipótese

Como visto anteriormente, testes de hipótese estão diretamente relacionados à construção de intervalos de confiança. Porém, para a construção dos mesmos, precisamos estabelecer previamente as hipóteses nula e alternativa, a fim de poder analisar e elucidar um resultado posteriormente.

Entretanto, ao optar por uma hipótese, nos sujeitamos a dois tipos de erro, que são eles:

- *Erro de tipo I*: rejeitar H_0 sendo H_0 verdade
- *Erro de tipo II*: não rejeitar H_0 sendo H_0 falsa

Na Inferência, o cálculo da probabilidade de ambos os erros recebem nomenclaturas especiais, sendo elas:

- α o **tamanho do erro de tipo I**, que é $P(\text{Rejeitar } H_0 | H_0 \text{ verdade})$
- β o **tamanho do erro de tipo II**, que é $P(\text{Não rejeitar } H_0 | H_0 \text{ falsa})$

Note que α também é o *nível de significância*, geralmente fixado em 5%, 2% ou 1%.

Outro fator muito relevante neste conteúdo é o cálculo do *valor-p*, sendo o mesmo a probabilidade de encontrar um valor pelo menos tão extremo quanto o observado na amostra, **respeitando a direção** de H_1 .

Assim, o *valor-p* é, na verdade, o menor nível de significância encontrado, ou seja, pode ser comparado ao α estabelecido para saber se deve-se rejeitar ou não H_0 .

Outra medida importante no estudo dos testes de hipótese é a **função poder**, possuindo a forma $\pi(\theta) = P(\text{Rejeitar } H_0 | \theta)$, sendo θ um valor qualquer para o parâmetro estimado, digamos, θ . Assim:

- $\pi(\theta_0) = \alpha$
- $\pi(\theta_1) = 1 - \beta$

Métodos

A fim de resumir os procedimentos possíveis para se analisar hipóteses, listo a seguir as formas vistas na disciplina.

1. *Intervalos de Confiança*: o valor de H_0 encontra-se dentro ou fora do intervalo encontrado?
2. *Região Crítica (R.C) e Região de Aceitação (R.A)*: a estatística encontra-se na R.C ou na R.A?
3. *Valor-p*: $\alpha > \hat{\alpha}$? Ou $\alpha < \hat{\alpha}$?
4. *Estatística de teste*: $z_{calc} > z_{tab}$? Ou $z_{calc} < z_{tab}$?[\[13\]](#)

Procedimentos em uma amostra

1. $H_0 : \mu = \mu_0, \sigma^2$ conhecida

$$\text{Estatística de teste: } z_0 = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

H_1	Rejeita se
$\mu \neq \mu_0$	$ z_0 > z_{\alpha/2}$
$\mu > \mu_0$	$z_0 > z_\alpha$
$\mu < \mu_0$	$z_0 < -z_\alpha$

2. $H_0 : \mu = \mu_0, \sigma^2$ desconhecida

$$\text{Estatística de teste: } t_0 = \frac{\bar{x} - \mu_0}{S/\sqrt{n}}$$

H_1	Rejeita se
$\mu \neq \mu_0$	$ t_0 > t_{\alpha/2, (n-1)}$
$\mu > \mu_0$	$t_0 > t_{\alpha, (n-1)}$
$\mu < \mu_0$	$t_0 < -t_{\alpha, (n-1)}$

3. $H_0 : \sigma^2 = \sigma_0^2$

$$\text{Estatística de teste: } \chi_0^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

H_1	Rejeita se
$\sigma^2 \neq \sigma_0^2$	$\chi_0^2 > \chi_{\alpha/2}^2, (n-1)$ ou $\chi_0^2 < \chi_{1-\alpha/2}^2, (n-1)$
$\sigma^2 > \sigma_0^2$	$\chi_0^2 > \chi_\alpha^2, (n-1)$
$\sigma^2 < \sigma_0^2$	$\chi_0^2 < \chi_{1-\alpha}^2, (n-1)$

4. $H_0 : p = p_0$

Estatística de teste: $z_0 = \frac{x - np_0}{\sqrt{np_0q_0}}$, onde x é o número de sucessos na amostra

H_1	Rejeita se
$p \neq p_0$	$ z_0 > z_{\alpha/2}$
$p > p_0$	$z_0 > z_\alpha$
$p < p_0$	$z_0 < -z_\alpha$

Procedimentos em duas amostras

1. $H_0 : \mu_1 - \mu_2 = \Delta_0$, σ_1^2 e σ_2^2 conhecidas

Estatística de teste: $z_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$

H_1	Rejeita se
$\mu_1 - \mu_2 \neq \Delta_0$	$ z_0 > z_{\alpha/2}$
$\mu_1 - \mu_2 > \Delta_0$	$z_0 > z_\alpha$
$\mu_1 - \mu_2 < \Delta_0$	$z_0 < -z_\alpha$

2. $H_0 : \mu_1 - \mu_2 = \Delta_0$, $\sigma_1^2 = \sigma_2^2$ desconhecidas

Estatística de teste: $t_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$

H_1	Rejeita se
$\mu_1 - \mu_2 \neq \Delta_0$	$ t_0 > t_{\alpha/2, (n+m-2)}$
$\mu_1 - \mu_2 > \Delta_0$	$t_0 > t_\alpha, (n+m-2)$
$\mu_1 - \mu_2 < \Delta_0$	$t_0 < -t_\alpha, (n+m-2)$

3. $H_0 : \mu_1 - \mu_2 = \Delta_0, \sigma_1^2 \neq \sigma_2^2$ desconhecidas

Estatística de teste:
$$t_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$$

H_1	Rejeita se
$\mu_1 - \mu_2 \neq \Delta_0$	$ t_0 > t_{\alpha/2}, (v)$
$\mu_1 - \mu_2 > \Delta_0$	$t_0 > t_{\alpha}, (v)$
$\mu_1 - \mu_2 < \Delta_0$	$t_0 < -t_{\alpha}, (v)$

Sendo
$$v = \frac{\left(\frac{S_1^2}{n} + \frac{S_2^2}{m}\right)^2}{\frac{(S_1^2/n)^2}{n-1} + \frac{(S_2^2/m)^2}{m-1}}$$

4. $H_0 : \mu_D = 0$ (populações dependentes)

Estatística de teste:
$$t_0 = \frac{\bar{d}}{s_D/\sqrt{n}}$$

H_1	Rejeita se
$\mu_D \neq 0$	$ t_0 > t_{\alpha/2}, (n-1)$
$\mu_D > 0$	$t_0 > t_{\alpha}, (n-1)$
$\mu_D < 0$	$t_0 < -t_{\alpha}, (n-1)$

5. $H_0 : \sigma_1^2 = \sigma_2^2$

Estatística de teste:
$$f_0 = S_1^2/S_2^2$$

H_1	Rejeita se
$\sigma_1^2 \neq \sigma_2^2$	$f_0 > f_{\alpha/2}, (n-1, m-1)$ ou $f_0 < f_{1-\alpha/2}, (n-1, m-1)$

H_1	Rejeita se
$\sigma_1^2 > \sigma_2^2$	$f_0 > f_\alpha, (n-1, m-1)$

6. $H_0 : p_1 = p_2$

Estatística de teste: $z_0 = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}\left[\frac{1}{n} + \frac{1}{m}\right]}}$

H_1	Rejeita se
$p_1 \neq p_2$	$ z_0 > z_{\alpha/2}$
$p_1 > p_2$	$z_0 > z_\alpha$
$p_1 < p_2$	$z_0 < -z_\alpha$

Teste mais poderoso

O lema de Neyman-Pearson nos diz que o teste mais poderoso será aquele de região crítica dada por

$$A^* = \left\{ \mathbf{x}; \frac{L_1(\mathbf{x})}{L_0(\mathbf{x})} \geq c \right\}$$

Caso A^* **não** dependa do parâmetro a ser testado, então dizemos que o teste realizado é, na verdade, o teste uniformemente mais poderoso (**UMP**).

-
1. logo, **todo estimador é uma estatística**, mas nem toda estatística é um estimador. [↵](#)
 2. um estimador pode subestimar ou superestimar um parâmetro. [↵](#)
 3. se o estimador for **não viesado**, então o EQM será a variância do estimador. [↵](#)
 4. é a distribuição conjunta da amostra analisada como função de θ [↵](#)
 5. em algumas situações, é mais fácil usar a última forma, pois a variância torna-se mais difícil de encontrar! [↵](#)
 6. esse resultado é conhecido como **critério da fatoração de Neyman**, e é mais utilizado quando o suporte da distribuição depender do parâmetro; do contrário, encontra-se a estatística suficiente através da família exponencial [↵](#)

7. A ideia é que dado um estimador não-viesado e que seja função de uma estatística suficiente, então, tal estimador é o UMVUE [↵](#)
8. este é o princípio da **invariância** [↵](#)
9. distribuição assintótica dos EMV [↵](#)
10. $e = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ é o erro amostral. Quando o mesmo é especificado e queremos achar o tamanho da amostra, temos o seguinte: $n = \left\lceil \left(\frac{z_{\alpha/2} \sigma}{e} \right)^2 \right\rceil$. A situação é similar quando a variância é desconhecida, ou para quando temos duas populações [↵](#)
11. há uma regra prática para decidir se as variâncias são iguais ou distintas: se $\frac{\max(S_1^2, S_2^2)}{\min(S_1^2, S_2^2)} < 4$, então, considerar **variâncias iguais** [↵](#)
12. nesses casos, para encontrar o tamanho amostral, usamos agora $n = \frac{z_{\alpha/2}^2 \sigma^2 N}{(N-1)e^2 + z_{\alpha/2}^2 \sigma^2}$
para estimar a média, e $n = \frac{z_{\alpha/2}^2 \bar{p} \bar{q} N}{(N-1)e^2 + z_{\alpha/2}^2 \bar{p} \bar{q}}$ para estimar a proporção [↵](#)
13. este é um tipo de região crítica, utilizando a estatística de teste ao invés da estatística observada [↵](#)